



PANEURÓPSKA VYSOKÁ ŠKOLA

Fakulta informatiky

ZADANIE PRÁCE

Meno a priezvisko študenta:

Evidenčné číslo práce:

Študijný odbor:

Študijný program:

Forma a metóda štúdia:

Vedúci práce:

Ústav/katedra:

Dátum zadania práce:

Názov:

Anotácia: Cieľom práce je vytvorenie komplexného systému pre navigáciu v interiéroch s napojením na rozličné webové zdroje s možnosťou ich editovania a návrh shaderov pre ich zobrazenie. Súčasťou práce bude analýza použitia v reálnom nasadení vrátane implementácie a zobrazovania na rozličných dotykových zariadeniach.

.....
RNDr. Ján Lacko, PhD.
vedúci práce

.....
Ing. Juraj Štefanovič, PhD.
vedúci ústavu

Obsah

Obsah	6
Zoznam obrázkov	8
Zoznam skratiek a značiek	9
1 Úvod	10
2 Motivácia	11
3 Ciele a zadanie práce	13
3.1 Uloha	14
4 Návrh riešenia	15
5 Technologické pozadie	17
6 Nanopore	18
6.1 Prekladanie DNa/Mra do signálu	18
7 Dorado Basecaller	20
7.1 Názov podkapitoly	20
8 Metódy spracovania sekvencií	21
8.1 Cluster clover	22
8.2 Viacnásobné zarovnanie sekvencií	23
8.2.1 Základný princíp	23
8.2.2 Význam a využitie	23
8.2.3 Zložitosť problému	23
8.2.4 Skórovacia funkcia	24
8.2.5 Bežné algoritmy	24
9 Vlastná implementácia a experimenty	25
10 Bio Informatics Analysis of Nanopore Sequencing Data Using Dorado Basecaller and Clover Clustering Algorithm	26
10.1 Hľadanie DNA reťazcov	27
10.2 Vlastný algoritmus zarovnania viacerých sekvencií	28
10.2.1 Vysvetlenie Generovanie Kandidátov	30
11 Záver	31

Zoznam obrázkov

Zoznam skratiek a značiek

BPMN	Business Process Model and Notation Notácia pre modelovanie business procesov
DNA	Deoxyribonucleic Acid Deoxyribonucleic Acid - DNA je molekula nesúca genetické informácie používané v rastlinách, zvieratách a väčšine organizmov. Je tvorená dvoma reťazcami nukleotidov, ktoré tvoria dvojité špirálu.
FASTQ	Fast Quality Fast Quality - Formát súboru používaný na ukladanie sekvenčných dát spolu s kvalitatívnymi skóre pre každú bázu.
OCL	Object Constraint Language Jazyk pre špecifikáciu obmedzení, dotazov a vyhľadávacích operácií v UML
RNA	Ribonucleic Acid Ribonucleic Acid - RNA je molekula podobná DNA, ktorá hrá kľúčovú úlohu v procese prepisu a prekladu genetickej informácie. Na rozdiel od DNA je zvyčajne jednovláknová a obsahuje uracil namiesto thymínu.
SNR	Signal-to-Noise Ratio Signal-to-Noise Ratio - Poměr medzi úrovňou požadovaného signálu a úrovňou šumu, ktorý môže ovplyvniť kvalitu dát získaných z nanopórového sekvenovania.
UML	Unified Modeling Language Univerzálny jazyk pre vizuálne modelovanie systémov

1 Úvod

V tejto bakalárskej práci sa venujem problematike ukladania dát do DNA a spracovaniu sekvenačných dát získaných pomocou nanopórového sekvenovania. Práca je rozdelená do niekoľkých kapitol, ktoré postupne predstavujú motiváciu, teoretické východiská, návrh riešenia, implementáciu a vyhodnotenie výsledkov.

3 Ciele a zadanie práce

4 Návrh riešenia

5 Technologické pozadie

Táto časť predstavuje základné technológie a algoritmy použité v práci.

8 Metódy spracovania sekvencií

9 Vlastná implementácia a experimenty

V tejto kapitole popisujem konkrétne kroky, ktoré som vykonal počas riešenia práce, vrátane spracovania dát, aplikácie algoritmov a vyhodnotenia výsledkov.

10.2 Vlastný algoritmus zarovnania viacerých sekvencií

Multiple sequence alignment (MSA) je problém zarovnania viacerých sekvencií, ktorý sa často vyskytuje v bioinformatike. Cieľom MSA je nájsť optimálne zarovnanie medzi viacerými sekvenciami, ktoré minimalizuje počet nesúladov a medzier. V tejto časti popisujem vlastný algoritmus na zarovnanie viacerých sekvencií, ktorý som implementoval v Pythone.

Pre tento Algoritmus predpokladám, že máme k dispozícii sekvencie DNA z zhľukovania od algoritmu clover, ktorý zhľukuje sekvencie, podľa toho, ako začínajú. Takže môžeme predpokladať, že začiatok sekvencií v jednom zhľuku je rovnaký a zarovnanie začína od začiatku a ďalej sa rozvetvuje kvôli chybám, ktoré sa vyskytujú pri citaní dna. Algoritmus využíva prístup podobný beam search, kde pre každú sekvenciu udržiavame množinu možných zarovnaní (vetiev) a iteratívne ich rozširujeme o ďalší znak z konsenzuálnej sekvencie. Pri každom kroku vyberáme najčastejší znak (konsenzus) a generujeme nové vetvy pre každý možný typ chyby (zhoda, zámienka, vloženie, vynechanie). Vetvy sú následne filtrované na základe skóre, aby sme udržali len tie najpravdepodobnejšie zarovnania. Tento proces pokračuje, kým nedosiahneme koniec všetkých sekvencií alebo kým sa sekvencie nezacnú výrazne odlišovať od seba, čo indikuje, že neexistuje jasný konsenzus.

Algorithm 1 Stav jednej vetvy zarovnania

```
record AlignmentState
    score : aktuálne skóre vetvy
    dna : spracovávaná DNA sekvencia
    position : aktuálna pozícia v sekvencii
    backtrack : postupnosť symbolov {=, I, D, M}
function NEXTBASE(state)
    if state.position < |state.dna| then
        return state.dna[state.position]
    end if
    return None
end function
function UPDATESTATE(state, Δscore, advance, symbol)
    state.score ← state.score + Δscore
    if advance then
        state.position ← state.position + 1
    end if
    append symbol to state.backtrack
end function
```

Algorithm 2 Generovanie kandidátov pre jednu vetvu

```
function GENERATECANDIDATES(consensus, state)  
  if NEXTBASE(state) = consensus then  
    UPDATESTATE(state, MatchReward, true, =)  
    return [state]  
  end if  
  mismatch  $\leftarrow$  kópia state  
  UPDATESTATE(mismatch,  $-MismatchPenalty$ , true, M)  
  deletion  $\leftarrow$  kópia state  
  UPDATESTATE(deletion,  $-DeletionGapPenalty$ , false, D)  
  insertion  $\leftarrow$  kópia state  
  while NEXTBASE(insertion)  $\neq$  consensus do  
    UPDATESTATE(insertion,  $-InsertionGapPenalty$ , true, I)  
  end while  
  UPDATESTATE(insertion, MatchReward, true, =)  
  return [mismatch, insertion, deletion]  
end function
```

Algorithm 3 Multi-Alignment

Require: zoznam stavov *lines*

```
while true do  
  bestCandidates  $\leftarrow$  najlepšia vetva pre každú vstupnú sekvenciu v lines  
  consensus  $\leftarrow$  najčastejšia hodnota NEXTBASE(candidate) pre candidate  $\in$   
  bestCandidates  
  newLines  $\leftarrow$  []  
  for all line  $\in$  lines do  
    pridaj všetky prvky z GENERATECANDIDATES(consensus, line) do newLines  
  end for  
  lines  $\leftarrow$  newLines  
  odstráň vetvy, ktoré pre rovnakú sekvenciu a rovnakú pozíciu majú horšie skóre než  
  iná vetva  
  odstráň vetvy so skóre nižším než threshold_score  
  if menej než threshold_ratio z bestCandidates podporuje consensus then  
    return bestCandidates  
  end if  
end while
```

10.2.1 Vysvetlenie Generovanie Kandidátov

Príklad zarovnania DNA sekvencií s konzenzom

Konsenzus: TGAC----TGAC
Sekvencia₁ : TGACgagcTGAC
 ----A-----

Konsenzus: TGACGAGCTGAC
Sekvencia₁ : TGAC----TGAC
 ----A-----

Konsenzus: TGACGAGCTGAC
Sekvencia₁ : TGACtAGCTGAC
 ----A-----

11 Záver

V práci som predstavil možnosti a výzvy spojené s ukladaním dát do DNA a spracovaním sekvenáčnych dát z nanopórového sekvenovania. Navrhnuté a implementované metódy prispievajú k efektívnejšiemu spracovaniu a analýze týchto dát. Cieľ bakalárskej práce bol splnený.

Použitá literatura

1. ZHENG, Peijie; ZHOU, Chuntao; DING, Yuemin; LIU, Bin. Nanopore sequencing technology and its applications. *MedComm*. 2023, roč. 4, č. 4. Dostupné z doi: 10.1002/mco2.316. Published July 2023.
2. LOPEZ, Randolph; CHEN, Yuan-Jyue; ANG, Siena Dumas; YEKHANIN, Sergey; MAKARYCHEV, Konstantin; RACZ, Miklos Z; SEELIG, Georg; STRAUSS, Karin; CEZE, Luis. DNA assembly for nanopore data storage readout. *Nature Communications*. 2019, roč. 10, č. 1, s. 1–9. Dostupné z doi: 10.1038/s41467-019-10978-4.
3. QU, Guanjin; YAN, Zihui; WU, Huaming. Clover: tree structure-based efficient DNA clustering for DNA-based data storage. *Briefings in Bioinformatics*. 2022, roč. 23, č. 5, s. 1–16. Dostupné z doi: 10.1093/bib/bbac336. Corresponding author: Huaming Wu, Center for Applied Mathematics, Tianjin University, Tianjin, 300072, China. E-mail: whming@tju.edu.cn.