

**PANEURÓPSKA VYSOKÁ ŠKOLA
FAKULTA INFORMATIKY**

FI-11145-18967

**Spracovanie údajov pre modelovanie narušenia informácie uchovávané
v pamäti DNA typu nanopor**

Bakalárska práca

2026

Patrik Homola

**PANEURÓPSKA VYSOKÁ ŠKOLA
FAKULTA INFORMATIKY**

**Spracovanie údajov pre modelovanie narušenia informácie uchovávané
v pamäti DNA typu nanopor**

Bakalárska práca

Patrik Homola

Študijný program: Aplikovaná informatika

Študijný odbor: Informatika

Školiace pracovisko: Ústav aplikovanej informatiky

Školiteľ: doc. RNDr. Peter Farkas, PhD.

Konzultant: Mgr. Peter Jarnvars

Bratislava 2026



PANEURÓPSKA VYSOKÁ ŠKOLA

Fakulta informatiky

ZADANIE PRÁCE

Meno a priezvisko študenta:

Evidenčné číslo práce:

Študijný odbor:

Študijný program:

Forma a metóda štúdia:

Vedúci práce:

Ústav/katedra:

Dátum zadania práce:

Názov:

Anotácia: Cieľom práce je vytvorenie komplexného systému pre navigáciu v interiéroch s napojením na rozličné webové zdroje s možnosťou ich editovania a návrh shaderov pre ich zobrazenie. Súčasťou práce bude analýza použitia v reálnom nasadení vrátane implementácie a zobrazovania na rozličných dotykových zariadeniach.

.....
RNDr. Ján Lacko, PhD.
vedúci práce

.....
Ing. Juraj Štefanovič, PhD.
vedúci ústavu

Podakovanie:

Pri vypracovaní tejto práce by som sa rád poďakoval za odbornú pomoc pánovi doc. RNDr. Peter Farkas, PhD., ktorý mi poskytol mnoho cenných rád a konzultácií.

Podakovanie môžete napísať podľa seba.

Čestné prehlásenie:

Čestne vyhlasujem, že záverečnú prácu som vypracoval samostatne a že som uviedol všetku použitú literatúru.

.....

Patrik Homola

Abstrakt

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Integer eu lacus leo. Nulla egestas purus non dignissim tincidunt. In sit amet tellus bibendum, lobortis magna ut, sodales mi. Etiam vel eros efficitur purus ultrices vulputate et quis justo. Nunc ultrices tellus a dui mattis, eget laoreet arcu tempor. Donec vestibulum, magna ac fringilla lacinia, libero risus fringilla arcu, nec consectetur nibh justo vel sem. Quisque gravida sit amet elit ut aliquam.

Abstrakt obsahuje informáciu o cieľoch práce, jej stručnom obsahu a v závere abstraktu sa charakterizuje splnenie cieľa, výsledky a význam celej práce. Súčasťou abstraktu je 3 - 5 kľúčových slov.

Kľúčové slová: Kľúčové slovo 1, Kľúčové slovo 2, Kľúčové slovo 3

Abstract

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Integer eu lacus leo. Nulla egestas purus non dignissim tincidunt. In sit amet tellus bibendum, lobortis magna ut, sodales mi. Etiam vel eros efficitur purus ultrices vulputate et quis justo. Nunc ultrices tellus a dui mattis, eget laoreet arcu tempor. Donec vestibulum, magna ac fringilla lacinia, libero risus fringilla arcu, nec consectetur nibh justo vel sem. Quisque gravida sit amet elit ut aliquam.

Abstrakty v anglickom a slovenskom jazyku sa musia zhodovať.

Keywords: Keyword 1, Keyword 2, Keyword 3

Obsah

Obsah	6
Zoznam obrázkov	8
Zoznam skratiek a značiek	9
1 Úvod	10
2 Motivácia	10
3 Ciele a zadanie práce	11
3.1 Uloha	11
3.1.1 Vstup	11
4 Opis dát	13
4.1 V akom stave sú dáta k dispozícii	13
4.2 Aké sú s tým problémy	13
4.2.1 Kde sa nachádzajú dlhé reťazce	13
4.3 Aký je očakávaný výstup dát a v akej forme majú byť dáta po spracovaní . .	14
4.3.1 Lokálne vyhľadávanie primeru	14
5 Čo bolo potrebné, aby sa riešenie dalo prakticky realizovať	19
5.1 Biologická syntéza DNA	19
5.1.1 Smer reťazca: $5' \rightarrow 3'$ a $3' \rightarrow 5'$	19
5.1.2 Simplexný a duplexný reťazec	19
5.2 Nanopore	20
5.3 Prekladanie DNA/mRNA do signálu	20
5.4 Dorado Basecaller	21
5.4.1 Ako spustiť Dorado	22
5.5 Cluster clover	22
5.6 Spustenie klastrovacieho nástroja Clover	23
5.7 Viacnásobné zarovnanie sekvencií	24
5.7.1 Základný princíp	25
5.7.2 Význam a využitie	25
5.7.3 Zložitosť problému	25
5.7.4 Skórovacia funkcia	25
5.7.5 Bežné algoritmy	26
5.7.6 Vybraný viacnásobný alignment	26

6	Vytvorenie práce	26
6.1	Analýza nanopórových sekvenačných dát pomocou Dorado a Clover	26
6.2	Hľadanie DNA reťazcov	27
6.3	Ako spúšťam proces	27
7	Kritické zhodnotenie a zhrnutie	29
	Použitá literatúra	31

Zoznam obrázkov

1	Dĺžka reťazca vs počet DNA reťazcov	29
---	---	----

Zoznam skratiek a značiek

BPMN	Business Process Model and Notation Notácia pre modelovanie business procesov
DNA	Deoxyribonucleic Acid Deoxyribonucleic Acid - DNA je molekula nesúca genetické informácie používané v rastlinách, zvieratách a väčšine organizmov. Je tvorená dvoma reťazcami nukleotidov, ktoré tvoria dvojité špirálu.
FASTQ	Fast Quality Fast Quality - Formát súboru používaný na ukladanie sekvenčných dát spolu s kvalitatívnymi skóre pre každú bázu.
OCL	Object Constraint Language Jazyk pre špecifikáciu obmedzení, dotazov a vyhľadávacích operácií v UML
RNA	Ribonucleic Acid Ribonucleic Acid - RNA je molekula podobná DNA, ktorá hrá kľúčovú úlohu v procese prepisu a prekladu genetickej informácie. Na rozdiel od DNA je zvyčajne jednovláknová a obsahuje uracil namiesto thymínu.
SNR	Signal-to-Noise Ratio Signal-to-Noise Ratio - Poměr medzi úrovňou požadovaného signálu a úrovňou šumu, ktorý môže ovplyvniť kvalitu dát získaných z nanopórového sekvenovania.
UML	Unified Modeling Language Univerzálny jazyk pre vizuálne modelovanie systémov

1 Úvod

V tejto bakalárskej práci sa venujem problematike ukladania dát do DNA a spracovaniu sekvenčných dát získaných pomocou nanopórového sekvenovania. Práca je rozdelená do piatich hlavných častí: úvod, opis dát, príprava praktickej realizácie, vlastné vytvorenie riešenia a kritické zhodnotenie so zhrnutím.

2 Motivácia

V dnešnej digitálnej dobe sa množstvo generovaných dát exponenciálne zvyšuje, čo vytvára potrebu efektívnych a trvalo udržateľných metód ich ukladania. Tradičné úložné médiá, ako sú pevné disky, SSD disky a magnetické pásky, majú obmedzenú životnosť a kapacitu, čo vedie k častým migráciám dát a zvýšeným nákladom na údržbu. DNA ako médium pre ukladanie dát ponúka niekoľko významných výhod:

- **Vysoká hustota ukladania:** Hustota informácií v DNA je extrémne vysoká. Len 5 gramov DNA obsahuje približne $4 \cdot 10^{21}$ nukleotidov, čo by teoreticky mohlo uchovať $8 \cdot 10^{21}$ bitov, alebo jeden zettabyte [1]. To znamená, že obrovské množstvo informácií môže byť uložené v mimoriadne malom objeme.
- **Dlhodobá stabilita:** DNA je chemicky stabilná molekula, ktorá môže prežiť tisíce rokov za správnych podmienok. Na rozdiel od tradičných médií, ktoré sa môžu degradovať počas niekoľkých dekád, DNA môže uchovávať dáta po veľmi dlhú dobu bez straty integrity.
- **Energetická efektívnosť:** Ukladanie dát do DNA nevyžaduje neustálu energiu na udržiavanie dát, na rozdiel od elektronických úložísk, ktoré potrebujú napájanie na zachovanie informácií. To vedie k výrazným úsporám energie a znižuje ekologickú stopu dátových centier.
- **Ľahká replikácia a prenosnosť:** DNA môže byť ľahko kopírovaná pomocou biologických procesov, čo umožňuje jednoduché zálohovanie a prenos dát medzi rôznymi miestami bez potreby špecializovaného hardvéru.
- **Odolnosť voči technologickému zastaraniu:** Na rozdiel od tradičných úložných médií, ktoré môžu rýchlo zastarať v dôsledku technologického pokroku, DNA ako médium zostáva nezmenené a čitateľné pomocou základných biologických techník.

Napriek uvedeným výhodám proces čítania DNA pomocou nanopórov prináša špecifické výzvy. Pri sekvenovaní DNA cez nanopór sa DNA molekula prechádza cez nanopór po jednotlivých nukleotidoch, pričom elektrický signál identifikuje bázy. Podrobnejšie vysvetlenie tejto technológie bude uvedené v sekcii 5.2. Tento proces je však náchylný na chyby, keďže

DNA sa môže pohybovať rýchlo alebo nepravidelne, čo vedie k nesprávnemu určeniu sekvencie nukleotidov. Tieto chyby v čítaní majú priamy vplyv na integritu uložených dát a vyžadujú sofistikované metódy kódovania a korekcie chýb. S pokračujúcim vývojom technológií nanopórového sekvenovania sa presnosť postupne zvyšuje, čo robí z DNA perspektívnu alternatívu k tradičným metódam ukladania dát. Cieľom tejto práce je prispieť k zefektívneniu procesu ukladania dát do DNA vytvorením modelu narušenia, ktorý popisuje chyby vznikajúce pri čítaní a zápise dát. Pochopením a formalizáciou týchto narušení je možné zvýšiť spoľahlivosť a presnosť ukladania a načítavania informácií, čo je kľúčové pre praktické využitie DNA ako úložného média v budúcnosti.

Model narušenia opisuje pravdepodobnostné správanie chýb, ktoré vznikajú počas syntézy, sekvenovania a uchovávaní DNA molekúl. Tento model zachytáva typy chýb ako substitúcie, inzercie a delécie nukleotidov, čím poskytuje základ pre návrh efektívnych kódovacích a opravných schém pri ukladaní dát do DNA.

3 Ciele a zadanie práce

3.1 Uloha

Cieľom tejto úlohy je simulovať chyby, ktoré vznikajú pri čítaní DNA pomocou nanopórového sekvenovania. Nanopórové sekvenovanie je inovatívna technológia, ktorá umožňuje rýchle a efektívne čítanie genetického materiálu. Úlohou je vytvoriť generátor, ktorý na základe pravdepodobnosti chyby náhodne pridáva chyby do reálneho DNA reťazca. Tento generátor by mal byť schopný simulovať rôzne typy chýb, ako sú záměny báz, vloženia alebo vynechania báz, ktoré sa môžu vyskytnúť počas procesu sekvenovania. Táto simulácia bude slúžiť na testovanie a vyhodnocovanie algoritmov pre spracovanie sekvenačných dát, ktoré musia byť robustné voči týmto chybám. Cieľom je zlepšiť presnosť a spoľahlivosť analýzy genetických informácií získaných pomocou nanopórového sekvenovania.

3.1.1 Vstup

Cieľ výstupu analýzy DNA získaných pomocou nanopórového sekvenovania je určiť vzťah medzi pôvodným DNA reťazcom a jeho pozorovanými čítaniami, ktoré vznikajú počas sekvenovania. Namiesto priameho priradenia konkrétneho referenčného reťazca k jednotlivým čítaniam je zvolený opačný postup: z dostupných nanopórových čítaní sa odhaduje najpravdepodobnejšia pôvodná sekvencia. Tento odhad je založený na identifikácii dostatočne veľkej množiny podobných sekvencií, pri ktorých možno predpokladať spoločný pôvod. Následne sa pre takúto skupinu vypočíta konsenzus, ktorý by mal byť čo najbližšie pôvodnému DNA reťazcu.

Konsenzus je syntetizovaná sekvencia zložená z nukleotidov, ktoré sa v každej pozícii zarovnaných sekvencií vyskytujú s najväčšou frekvenciou. Inými slovami, pre každú pozíciu

v zarovnaní sa vyberie báza (A, C, G alebo T), ktorá sa v danej pozícii objavuje najčastejšie vo všetkých zarovnaných čítaniach. Konsenzus tak reprezentuje najlepší odhad pôvodnej DNA sekvencie na základe dostupných pozorovaní a ich spoľahlivosti.

Keďže DNA reťazce sú dlhé a jednotlivé čítania obsahujú chyby, sekvencie sa môžu navzájom líšiť a byť vzájomne posunuté. Z tohto dôvodu je potrebné vykonať viacnásobné zarovnanie sekvencií (multiple sequence alignment), aby sa konsenzus určoval z nukleotidov nachádzajúcich sa v rovnakých pozíciách.

Takto definovaný výstup umožňuje vytvoriť pravdepodobnostný model čítania DNA k-tíc (k-merov). Tento model sa interpretuje ako komunikačný kanál a vychádza z matematickej teórie komunikácie

Shannon 1948 Communication. Namiesto jedného pevného výsledku sa každej k-tici priraduje rozdelenie možných prečítaných sekvencií. Formálne môžeme písať

$$X = \Sigma^k, \quad Y = \Sigma^*, \quad K(y | x) = \Pr(Y = y | X = x),$$

kde $\Sigma = \{A, C, G, T\}$, $x \in \Sigma^k$ je pôvodná k-tica a $y \in \Sigma^*$ je prečítaná sekvencia. Tá môže mať aj inú dĺžku v dôsledku delécií alebo inzercíí.

Pre konkrétnu k-ticu, napríklad $x = \text{ATCG}$, môže byť rozdelenie nasledovné:

$$\Pr(Y = \text{ATCG} | X = x) = 0.33,$$

$$\Pr(Y = \text{ATTTCG} | X = x) = 0.20,$$

$$\Pr(Y = \text{TCG} | X = x) = 0.10,$$

$$\Pr(Y = \text{AGCG} | X = x) = 0.07.$$

Zvyšná pravdepodobnosť patrí ostatným chybovým variantom tak, aby celkový súčet bol rovný 1. Takýto model zachytáva substitúcie, inzercie a delécie a je kľúčový pre realistickú simuláciu chýb pri generovaní nových DNA sekvencií.

Zároveň platí, že jedna skupina podobných sekvencií spravidla neobsahuje dostatočný počet variácií na spoľahlivý odhad chýb pre všetky možné k-mery. Počet k-tíc rastie exponenciálne podľa 4^k ; napríklad pre $k = 4$ ide o 256 možných 4-merov. Pravdepodobnosť, že všetky tieto varianty budú dostatočne zastúpené v jednej skupine, je nízka, preto je potrebné objaviť viacero sekvenčných skupín.

Požadovaný výstup preto pozostáva z viacerých skupín navzájom zarovnaných DNA sekvencií a zodpovedajúcich konsenzuálnych sekvencií pre každú skupinu. Takto definovaný výstup umožňuje dosiahnuť dostatočné pokrytie variácií čítaní odvodených z toho istého DNA reťazca.

4 Opis dát

4.1 V akom stave sú dáta k dispozícii

Data boli stiahnuté z verejného repozitára, ktorý obsahoval surové sekvenačné dáta vo formáte pod5. Tieto dáta predstavovali čítania DNA reťazcov získané pomocou nanopórového sekvenovania. Dáta boli stiahnuté pomocou nástroja AWS s použitím príkazu `aws s3 sync`, ktorý umožňuje kopírovať súbory z úložiska Amazon S3 do lokálneho prostredia.

```
aws s3 sync --no-sign-request s3://ont-open-data/gm24385_2020.09 /  
media/marek/EAGET/gm24385_2020.09
```

Dáta boli uložené do adresára `/media/marek/EAGET/gm24385_2020.09`. Sťahovanie trvalo približne 2 hodiny, pričom celková veľkosť stiahnutých dát bola približne 10 GB. Data obsahovali čítania DNA reťazcov, ktoré vznikajú počas procesu nanopórového sekvenovania. Tieto čítania sú často dlhé a obsahujú chyby, čo predstavuje výzvu pri ich analýze. Aby bolo možné tieto dáta efektívne analyzovať, bolo potrebné ich prekonvertovať pomocou basecallera Dorado do formátu BAM, ktorý je štandardným formátom pre ukladanie sekvenačných dát a umožňuje efektívne spracovanie a analýzu. Po konverzii do formátu BAM bolo potrebné dáta zoskupiť a zároveň, aby sa identifikovali podobné sekvencie a vytvorili konsenzuálne sekvencie, ktoré by mohli reprezentovať pôvodný DNA reťazec.

4.2 Aké sú s tým problémy

4.2.1 Kde sa nachádzajú dlhé reťazce

Dáta spracované do formátu BAM obsahujú viacero sekvencií DNA, ktoré sa navzájom líšia dĺžkou aj obsahom. Každý riadok reprezentuje jedno čítanie z nanopórovej sekvenácie. Dĺžka DNA čítaní sa pohybuje približne od 100 nukleotidov až po 1 000 000 nukleotidov. Jedným z možných dôvodov výskytu veľmi dlhých čítaní je, že zariadenie môže postupne načítavať viac DNA sekvencií za sebou, pričom nástroj Dorado ich neoddelí a spracuje ich ako jednu sekvenciu. Zároveň možno predpokladať, že v rámci jedného čítania sa tá istá sekvencia môže vyskytovať opakovane. Tento jav môže súvisieť s biosyntézou DNA, pri ktorej dochádza k replikácii a vzniku viacerých kópií tej istej sekvencie. Tá istá sekvencia bude pravdepodobne načítaná viackrát, avšak s odlišnými chybami, keďže nanopórové sekvenovanie je chybovejšie. Okrem toho sa sekvencia môže načítavať v opačnej orientácii, pretože molekula vstupuje do nanopóru z rôznych koncov. Sekvenciu preto možno získať v smere $3' \rightarrow 5'$ alebo $5' \rightarrow 3'$.

V dôsledku biosyntézy vzniká aj komplementárna sekvencia DNA, v ktorej sú bázy nahradené podľa pravidiel párovania ($A \rightarrow T$, $T \rightarrow A$, $G \rightarrow C$, $C \rightarrow G$). Aj komplementárna sekvencia môže byť čítaná v oboch smeroch. Pre každú pôvodnú sekvenciu sa teda môžu vyskytnúť až štyri varianty: pôvodná sekvencia v smere $3' \rightarrow 5'$ a $5' \rightarrow 3'$, a jej komplement v

smere $3' \rightarrow 5'$ a $5' \rightarrow 3'$. Ďalším javom je fragmentácia DNA, pri ktorej vznikajú kratšie sekvencie zodpovedajúce iba časti pôvodnej sekvencie. Ich dĺžky sa líšia podľa miesta pretrhnutia. Zároveň sa môže stať, že niektoré sekvencie sa replikujú častejšie ako iné. Napriek uvedeným komplikáciám bolo možné predpokladať, že v dlhých čítaniach bude možné identifikovať dostatočne dlhé opakujúce sa úseky, ktoré reprezentujú tú istú pôvodnú DNA sekvenciu. Na základe tohto predpokladu bol identifikovaný klaster obsahujúci viac ako 37 000 sekvencií DNA. Spočiatku sa zdalo, že ide o opakované čítanie jednej sekvencie, čo by mohlo viesť k získaniu kvalitného konsenzu. Podrobnejšia analýza však ukázala, že spoločná zhoda medzi sekvenciami bola obmedzená iba na úvodný úsek s dĺžkou 43 nukleotidov.

Keďže 43 nukleotidov predstavuje príliš krátky úsek na spoľahlivú reprezentáciu celého DNA reťazca, no zároveň je príliš dlhý na náhodne sa vyskytujúci úsek, pôvodná hypotéza o prítomnosti dostatočne dlhého spoločného jadra nebola potvrdená. Na základe tohto zistenia bola formulovaná nová hypotéza: spoločný úvodný úsek pravdepodobne zodpovedá DNA primeru prítomnému na začiatku sekvenovaných fragmentov.

Nasledujúcim krokom preto bolo lokálne hľadanie primeru v jednotlivých čítaniach. Primer sa nevyhľadával iba na začiatku reťazca, ale v celom rozsahu každého čítania, aby sa zachytili aj prípady jeho posunu alebo výskytu vo vnútri sekvencie.

4.3 Aký je očakávaný výstup dát a v akej forme majú byť dáta po spracovaní

4.3.1 Lokálne vyhľadávanie primeru

Na základe zistenia, že spoločná zhoda medzi sekvenciami bola obmedzená iba na úvodný úsek s dĺžkou 43 nukleotidov, bol tento úsek označený ako primer a bolo rozhodnuté vyhľadať ho v každom čítaní. Vyhľadávanie sa neobmedzilo len na jeho výskyt na začiatku sekvencie, ale zahŕňalo celý rozsah každého čítania, aby boli zachytené aj prípady, kde sa primer nachádza posunutý alebo vo vnútri sekvencie. Súbor obsahujúci čítania z Dorado vo formáte FASTA bol načítaný do pamäte a následne bol použitý algoritmus z knižnice Biopython, ktorý umožňuje vyhľadávať lokálne zarovnanie medzi primerom a jednotlivými čítaniami.

Funkcia `aligner.align(primer, read)` vracia všetky lokálne zarovnania medzi primerom a daným čítaním, zoradené podľa skóre zarovnania. Každé zarovnanie obsahuje informácie o pozícii zarovnania v celkovom reťazci aj o lokálne zarovnanom úseku, ktorý v tomto prípade zodpovedá primeru. Výstup je reprezentovaný dvojicou riadkov a sadou fragmentov, z ktorých je možné určiť začiatok a koniec zarovnaného úseku v pôvodnom čítaní. Na určenie pozícií, v ktorých sa lokálne zarovnaný reťazec zhoduje s primerom, sa využívajú hodnoty `aligned[1][0][0]` a `aligned[1][-1][1]`.

Výpis 1: Finding occurrences of a primer in reads

```
def findOcurences(primer: str, reads: List[str]):
```



```

aligner = Align.PairwiseAligner()
aligner.mode = 'local'

aligner.match_score = 2
aligner.mismatch_score = -1
aligner.open_gap_score = -2
aligner.extend_gap_score = -0.5

threshold = len(primer) * 1. # tune this!

sizeOfReads = len(reads)

PrimersFound = []
for read_id, read in enumerate(reads):
    read = read.strip()

    alignments = aligner.align(primer, read)
    lastIds = set()
    for i, aln in enumerate(alignments):
        if i >= 100:
            break
        if aln.score < threshold:
            # print(aln.score)
            break

        # extract positions
        # print(aln)
        aligned = aln.aligned
        read_start = aligned[1][0][0]

        read_end = aligned[1][-1][1]

        lastIds.add(read_end)
        # print(f"Read {read_id}: {read_start}-{read_end},
            score={aln.score}")
    if read_id % 1000 == 0:
        print(f"Read {read_id}/ {sizeOfReads}:{lastIds}")
    PrimersFound.append(lastIds)
return PrimersFound

```

Pozície nájdených primerov boli uložené do poľa v tvare:

```
[[], [65], [55], [], [64], [], [55], [74, 73], [64], [75], ...]
```

Každý prvok poľa zodpovedá jednému čítaniu a obsahuje pozície, na ktorých sa primer nachádza v danom čítaní. Z výsledkov vyplýva, že v nie každom reťazci bol primer identifikovaný, zatiaľ čo v niektorých čítaniach sa vyskytol viackrát. Tento jav môže byť spôsobený tým, že niektoré čítania obsahujú komplementárnu sekvenciu alebo boli prečítané v opačnom smere. Ďalším dôvodom môže byť pretrhnutie DNA reťazca v rôznych miestach alebo príliš nízka podobnosť primeru vzhľadom na nastavený prah zarovnania.

Výpis 2: Stripping primers from Clover input

```
with open(clover_input_path, "r") as f:
    lines = f.readlines()

with open(PrimersPath, "r") as f:
    datas = f.read()

primers = ast.literal_eval(datas)

newLines = []
for (line, linePrimes) in zip(lines, primers):
    prevValue = -1
    for prime in linePrimes:
        if (prevValue != -1):
            if prevValue - prime < 50:
                continue
            newline = line[prime:prevValue]
            if (len(newline) < 50):
                continue
            newLines.append(newline)
            prevValue = prime

WriteLines = []
for (i, line) in enumerate(newLines):
    WriteLines.append(f"{i} {line}\n")

with open("PrimersStripClover.txt", "w") as f:
    f.writelines(WriteLines)
```

Následne boli extrahované úseky za primerom a zapísané do nového súboru, ktorý obsahuje čítania od primeru až po koniec reťazca, prípadne po ďalší primer, ak sa v čítaní nachádzal viackrát. Tieto dáta boli následne znovu zoskupené pomocou algoritmu Clover, pričom tentoraz boli použité iba zvyšné časti sekvencií bez DNA primerov. Výsledkom bolo, že vytvorené klastre obsahovali sekvencie, ktoré mali zhodu nielen na začiatku, ale aj v ďalších

častiach reťazca. To naznačovalo, že sekvencie pochádzajú z toho istého DNA reťazca v správnom smere, a nie z opačne orientovaného alebo komplementárneho reťazca. Na klastre bolo aplikované viacnásobné zarovnanie.

Výpis 3: Clustering without primers

```
ClusterFile = TextFileM(path="clusters_output.txt")
ClusterFile = ClusterFile.load()
ClusterFile = parse_tuple_file(ClusterFile)
ClusterFile = get_clusters(ClusterFile)
clusters = ClusterFile.data

#ClusterFile = pick_largest_cluster(ClusterFile)
#LargestCluster = []
#LargestCluster = ClusterFile.data

clusters = [l for l in clusters if len(l) > 10]
count=1
for clust in clusters:
    ClusterFile.data=clust
    ClusterFile = retrieve_dna_lines(ClusterFile, clover_input_path
    )
    DataToBeAligned = ClusterFile.data

    ClusterSize = len(DataToBeAligned)
    (Aligned, Unaligned) = DataBeamAlgorithmSplit(DataToBeAligned,
    10)
    dist = len(Aligned[0].replace("_", ""))
    if len(Aligned[0].replace("_", ""))<10:
        continue

    Aligned.insert(0, str(clust))

    TextFileM(data=Aligned).write_data_to_file(f"GeneratedData/
    Aligned_dnaSize-{dist}num-{ClusterSize}id-{count}.txt")
    count+=1
```

Ukázalo sa, že klastre obsahovali sekvencie, ktoré mali zhodu nielen na začiatku, ale aj ďalej v reťazci. Niektoré klastre obsahovali sekvencie, ktoré sa zhodovali až do dĺžky 100 nukleotidov, čo predstavuje výrazne dlhší úsek než pôvodný primer. Cieľ výstupu analýzy DNA získaných pomocou nanopórového sekvenovania je určiť vzťah medzi pôvodným DNA reťazcom a jeho pozorovanými čítaniami, ktoré vznikajú počas sekvenovania. Namiesto priameho priradenia konkrétneho referenčného reťazca k jednotlivým čítaniam je zvolený opačný postup:

z dostupných nanopórových čítaní sa odhaduje najpravdepodobnejšia pôvodná sekvencia. Tento odhad je založený na identifikácii dostatočne veľkej množiny podobných sekvencií, pri ktorých možno predpokladať spoločný pôvod. Následne sa pre takúto skupinu vypočíta konsenzus, ktorý by mal byť čo najbližšie pôvodnému DNA reťazcu.

Konsenzus je syntetizovaná sekvencia zložená z nukleotidov, ktoré sa v každej pozícii zarovnaných sekvencií vyskytujú s najväčšou frekvenciou. Inými slovami, pre každú pozíciu v zarovnaní sa vyberie báza (A, C, G alebo T), ktorá sa v danej pozícii objavuje najčastejšie vo všetkých zarovnaných čítaniach. Konsenzus tak reprezentuje najlepší odhad pôvodnej DNA sekvencie na základe dostupných pozorovaní a ich spoľahlivosti.

Keďže DNA reťazce sú dlhé a jednotlivé čítania obsahujú chyby, sekvencie sa môžu navzájom líšiť a byť vzájomne posunuté. Z tohto dôvodu je potrebné vykonať viacnásobné zarovnanie sekvencií (multiple sequence alignment), aby sa konsenzus určoval z nukleotidov nachádzajúcich sa v rovnakých pozíciách.

Takto definovaný výstup umožňuje vytvoriť pravdepodobnostný model čítania DNA k-tíc (k-merov). Tento model sa interpretuje ako komunikačný kanál a vychádza z matematickej teórie komunikácie

Shannon 1948 Communication. Namiesto jedného pevného výsledku sa každej k-tici priraduje rozdelenie možných prečítaných sekvencií. Formálne môžeme písať

$$X = \Sigma^k, \quad Y = \Sigma^*, \quad K(y | x) = \Pr(Y = y | X = x),$$

kde $\Sigma = \{A, C, G, T\}$, $x \in \Sigma^k$ je pôvodná k-tica a $y \in \Sigma^*$ je prečítaná sekvencia. Tá môže mať aj inú dĺžku v dôsledku delécií alebo inzercíí.

Pre konkrétnu k-ticu, napríklad $x = \text{ATCG}$, môže byť rozdelenie nasledovné:

$$\Pr(Y = \text{ATCG} | X = x) = 0.33,$$

$$\Pr(Y = \text{ATTTCG} | X = x) = 0.20,$$

$$\Pr(Y = \text{TCG} | X = x) = 0.10,$$

$$\Pr(Y = \text{AGCG} | X = x) = 0.07.$$

Zvyšná pravdepodobnosť patrí ostatným chybovým variantom tak, aby celkový súčet bol rovný 1. Takýto model zachytáva substitúcie, inzercie a delécie a je kľúčový pre realistickú simuláciu chýb pri generovaní nových DNA sekvencií.

Zároveň platí, že jedna skupina podobných sekvencií spravidla neobsahuje dostatočný počet variácií na spoľahlivý odhad chýb pre všetky možné k-mery. Počet k-tíc rastie exponenciálne podľa 4^k ; napríklad pre $k = 4$ ide o 256 možných 4-merov. Pravdepodobnosť, že všetky tieto varianty budú dostatočne zastúpené v jednej skupine, je nízka, preto je potrebné objaviť viacero sekvenčných skupín.

Požadovaný výstup preto pozostáva z viacerých skupín navzájom zarovnaných DNA sekvencií a zodpovedajúcich konsenzuálnych sekvencií pre každú skupinu. Takto definovaný výstup umožňuje dosiahnuť dostatočné pokrytie variácií čítaní odvodených z toho istého DNA reťazca.

5 Čo bolo potrebné, aby sa riešenie dalo prakticky realizovať

5.1 Biologická syntéza DNA

Biologická syntéza DNA je proces, pri ktorom DNA polymeráza vytvára nový reťazec na základe templátového vlákna, pričom syntéza prebieha výlučne v smere $5' \rightarrow 3'$. Kľúčovou podmienkou začatia syntézy je prítomnosť primeru, teda krátkeho komplementárneho oligonukleotidu, ktorý sa naviaže na templát a poskytne voľnú $3'$ -OH skupinu potrebnú pre katalytickú aktivitu polymerázy. Po naviazaní primeru polymeráza postupne inkorporuje deoxyribonukleotidy podľa pravidiel komplementárneho párovania báz (A–T, G–C), čím predlžuje vznikajúci reťazec DNA. Tento proces je nevyhnutný pre replikáciu DNA, ktorá je základom prenosu genetickej informácie.

5.1.1 Smer reťazca: $5' \rightarrow 3'$ a $3' \rightarrow 5'$

DNA reťazec má chemickú polaritu — jeden koniec reťazca má voľnú fosfátovú skupinu na $5'$ uhlíku cukru ($5'$ koniec) a druhý koniec má voľnú hydroxylovú skupinu na $3'$ uhlíku ($3'$ koniec).

- **Smer $5' \rightarrow 3'$** — smer, v ktorom DNA polymeráza syntetizuje nový reťazec. Polymeráza číta templát v smere $3' \rightarrow 5'$ a zapisuje nový reťazec v smere $5' \rightarrow 3'$.
- **Smer $3' \rightarrow 5'$** — smer čítania templátového vlákna počas syntézy. Nie je možné syntetizovať reťazec v tomto smere priamo.

Táto polarita má priamy dopad na nanopórové sekvenovanie — tá istá DNA molekula môže vstúpiť do nanopóru z ľubovoľného konca, čím vznikajú čítania v oboch smeroch (forward aj reverse). Pri spracovaní dát je preto potrebné uvažovať s oboma orientáciami.

5.1.2 Simplexný a duplexný reťazec

- **Simplex (ssDNA)** — jednoreťazcová DNA. Obsahuje iba jedno vlákno nukleotidov. Vyskytuje sa napríklad počas replikácie alebo pri niektorých vírusoch. V kontexte nanopórového sekvenovania sa čítanie vykonáva práve na jednoreťazcovej forme.

- **Duplex (dsDNA)** — dvojreťazcová DNA. Dve komplementárne vlákna sú navzájom spojené vodíkovými väzbami medzi párami báz (A–T, G–C) a tvoria charakteristickú dvojité špirálu (double helix). Toto je štandardná forma, v ktorej je DNA uložená v bunke.

Pri biosyntéze DNA vzniká z jednoreťazcového templátu nový komplementárny reťazec — výsledkom je duplexná DNA. Pre každý pôvodný reťazec tak existuje komplementárny reťazec s opačnou polaritou. To znamená, že pri nanopórovom sekvenovaní sa môžu vyskytnúť štyri varianty toho istého úseku DNA:

1. pôvodný reťazec v smere $5' \rightarrow 3'$,
2. pôvodný reťazec v smere $3' \rightarrow 5'$ (reverzný),
3. komplementárny reťazec v smere $5' \rightarrow 3'$,
4. komplementárny reťazec v smere $3' \rightarrow 5'$ (reverzný komplement).

Tieto štyri varianty sú kľúčovým zdrojom komplikácií pri klastrovacích algoritmoch — sekvencie reprezentujúce rovnaký úsek DNA môžu byť sekvenované prečítané v rôznych formách a bez primerov ich nie je možné jednoducho stotožniť.

5.2 Nanopore

Nanopore sekvenovanie je technológia používaná na sekvenovanie DNA a RNA molekúl [2]. Táto metóda umožňuje čítanie genetického materiálu tým, že molekuly prechádzajú cez nanometrové póry (nanopóry), čo vedie k zmene elektrického prúdu, ktorý je následne analyzovaný na určenie sekvencie nukleotidov [2]. Je to revolučná technológia v oblasti genetiky, ktorá umožňuje rýchle a presné sekvenovanie s minimálnymi nákladmi a zariadeniami prenosných veľkostí [2]. Aplikácie nanopórového sekvenovania zahŕňajú diagnostiku chorôb, výskum genetických porúch a monitorovanie environmentálnych vzoriek [2]. Nanopórové sekvenovanie je obzvlášť užitočné pre jeho schopnosť čítať dlhé sekvencie DNA, čo zjednodušuje zostavovanie genómov a identifikáciu štruktúrnych variácií [2, 3]. Funguje na princípe detekcie zmien v elektrickom prúde, keď molekula prechádza cez nanopór, čo umožňuje priame čítanie sekvencií bez potreby amplifikácie alebo značenia [2]. DNA alebo RNA molekuly sú vedené cez nanopór pomocou elektrického poľa, pričom každá báza spôsobuje charakteristickú zmenu prúdu, ktorá je zaznamenaná a analyzovaná softvérom na určenie sekvencie [2].

5.3 Prekladanie DNA/mRNA do signálu

Prekladanie DNA alebo RNA sekvencií do elektrického signálu v nanopórovom sekvenovaní [2] zahŕňa niekoľko kľúčových krokov:

- **Príprava vzorky:** DNA alebo RNA molekuly sú pripravené na sekvenovanie, často zahŕňajúce fragmentáciu a pridanie adaptérnych sekvencií.
- **Vedenie cez nanopór:** Molekuly sú vedené cez nanopór pomocou elektrického poľa, ktoré spôsobuje ich pohyb [2].
- **Detekcia prúdu:** Keď molekula prechádza cez nanopór, každá báza spôsobuje charakteristickú zmenu v elektrickom prúde, ktorý je zaznamenaný ako časová séria dát [2].
- **Analýza signálu:** Zaznamenaný elektrický signál je analyzovaný pomocou algoritmov na identifikáciu sekvencie nukleotidov na základe zmien prúdu [2].
- **Preklad do sekvencie:** Softvér prekladá analyzovaný signál späť do sekvencie DNA alebo RNA, čo umožňuje výskumníkom získať genetické informácie z pôvodnej molekuly [2].

Výstupom z procesu nanopórového sekvenovania je sekvencia nukleotidov (A, T, C, G pre DNA alebo A, U, C, G pre RNA) reprezentujúca genetickú informáciu pôvodnej molekuly [2]. Tento výstup je často vo forme textového súboru (napríklad FASTQ formát), ktorý obsahuje sekvencie spolu s kvalitatívnymi skóre pre každú bázu [2]. Vzhľadom na technické obmedzenia a variabilitu v procese sekvenovania je bežné, že jednotlivé DNA alebo RNA retiazce sú prečítané niekoľkokrát (tzv. "coverage" alebo "depth of coverage") [2]. Toto opakovanie zvyšuje spoľahlivosť a presnosť výslednej sekvencie, pretože umožňuje korekciu chýb a identifikáciu variácií v genetickom materiáli [2, 3]. No napriek tomu, že sa retiazce čítajú viackrát, stále môže dôjsť k nepresnostiam v sekvencii kvôli šumu v signáli [2]. Retiazce DNA alebo RNA môžu byť čítané rôznou rýchlosťou počas nanopórového sekvenovania, čo môže ovplyvniť kvalitu a presnosť zaznamenaného signálu [2]. Rýchlosť prechodu molekuly cez nanopór je ovplyvnená viacerými faktormi, vrátane veľkosti molekuly, jej konformácie, interakcií s nanopórom a podmienok prostredia (napríklad teplota a iónová sila) [2].

Keďže DNA a RNA molekuly sú veľmi malé, signál zaznamenaný počas nanopórového sekvenovania odráža interakcie jednotlivých nukleotidov (báz) s nanopórom [2]. Každá báza má jedinečný tvar a elektrické vlastnosti, ktoré ovplyvňujú spôsob, akým mení elektrický prúd pri prechode cez nanopór [2]. Preto je možné získať signál pre každú jednotlivú bázu v molekule, čo umožňuje presné čítanie sekvencie [2].

5.4 Dorado Basecaller

Dorado je pokročilý basecaller vyvinutý spoločnosťou Oxford Nanopore Technologies (ONT) na prekladanie surového elektrického signálu získaného z nanopórového sekvenovania na sekvenciu nukleotidov (A, T, C, G pre DNA alebo A, U, C, G pre RNA). Je navrhnutý tak,

aby poskytoval vysokú presnosť a rýchlosť pri spracovaní sekvenačných dát, čo je kľúčové pre rôzne aplikácie v oblasti genomics a bioinformatiky.

5.4.1 Ako spustiť Dorado

Pred spustením bolo potrebné stiahnuť model pomocou príkazu:

```
dorado download --list  
dorado download --model dna_r10.4.1_e8.2_400bps_hac@v4.2.0
```

Dorado podporuje viacero módov spracovania:

- fast — rýchlejší, ale menej presný
- hac — pomalší, ale kvalitnejší (High Accuracy)
- sup — najpomalší, najvyššia presnosť (Super Accuracy)

Na spustenie basecallera bol použitý nasledujúci príkaz:

```
dorado basecaller hac <adresar_s_pod5> --recursive --max-reads 100 > Calls.bam
```

Parameter `-recursive` je potrebný na spracovanie všetkých súborov v adresári a jeho podadresároch. Dorado je dôležité spúšťať s prístupom k GPU — bez neho je spracovanie veľmi pomalé. Aj s GPU je spracovanie pomerne pomalé, preto je vhodné pri testovaní používať parameter `-max-reads`, čo ušetrí veľa času pri práci s miliónmi sekvencií.

[4]

5.5 Cluster clover

Klastrovací algoritmus je metóda, ktorá rozdeľuje množinu dát do skupín (klastrov) tak, aby dáta v rámci jednej skupiny boli si navzájom podobné a dáta z rôznych skupín boli odlišné [5]. Tieto algoritmy sa často používajú v bioinformatike na analýzu sekvencií DNA alebo iných biologických dát. Clover algoritmus je efektívny klastrovač navrhnutý špeciálne pre DNA sekvencie v oblasti DNA-based data storage. Využíva stromovú štruktúru na rýchle a presné zoskupovanie sekvencií podľa ich podobnosti, čím zvyšuje efektivitu a škálovateľnosť procesu [5]. Clover umožňuje efektívne spracovanie veľkých množín sekvencií a je vhodný pre moderné aplikácie v oblasti ukladania dát do DNA. Clover algoritmus klastruje sekvencie DNA na základe ich počiatkových úsekov a usporadúva ich do stromovej štruktúry podobnej trie. Trie funguje ako hierarchická usporiadaná stromová štruktúra, kde každý uzol reprezentuje spoločný prefix a vetvy vedú k sekvenciám, ktoré sa líšia v nasledujúcich pozíciách.

Nástroj Clover prijíma dáta vo formáte, v ktorom každý riadok obsahuje identifikátor a DNA sekvenciu, napríklad: fasta alebo txt súbor s formátom "ID sekvencia".

5.6 Spustenie klastrovacieho nástroja Clover

Na spustenie klastrovacieho nástroja bolo potrebné previesť dáta z formátu BAM do textového formátu.

Výpis 4: Bam to Txt Conversion

```
def ConvertBamToTxt(bam, out):  
    for i, read in enumerate(bam):  
        seq = read.query_sequence # the DNA sequence  
        out.write(f"{i} {seq}\n")
```

Následne bol klastrovací nástroj spustený s nasledujúcim nastavením:

Výpis 5: Spustenie klastrovacieho nástroja

```
python -m clover.main -I output.txt -O example.txt -L 150 -P 2  
--no-tag
```

Pri spustení bol použitý vstupný súbor `output.txt` (-I) a výstupný súbor `example.txt` (-O). Parametre majú nasledujúci význam:

- -I [input_file]: vstupný súbor. Aktuálne sú podporované formáty `txt`, `fasta` a `fastq`. Každý riadok má tvar [index], [read].
- -O [output_file_name]: názov výstupného súboru. Výstupný súbor bude uložený v priečinku Clover.
- -L [int]: dĺžka čítania (length of read).
- -P [int]: voľba režimu spracovania. P=0 znamená jednovláknové/jeden proces; P=1 a P=2 znamenajú 4, resp. 16 procesov.
- -no-tag: tento prepínač je potrebné pridať, ak je vstupný súbor v „untagged“ formáte.

Clover vrátil súbor so štruktúrou poľa, ktoré obsahovalo dvojice celých čísel, kde prvé číslo reprezentovalo identifikátor sekvencie a druhé číslo reprezentovalo identifikátor prvej sekvencie, ku ktorej bola daná sekvencia zaradená.

Výpis 6: Clustering Data

```
tuples = m.data  
data_sorted = sorted(tuples, key=lambda x: x[1])  
groups = []  
  
for k, g in itertools.groupby(data_sorted, key=lambda x: x[1]):  
    groups.append([k] + [a[0] for a in g])  
return groups
```

Uvedený skript načíta výstup z nástroja Clover a prevedie ho do dátovej štruktúry vhodnej na ďalšie spracovanie. Konkrétne spracuje dvojice identifikátorov tak, aby bolo možné jednoducho zistiť, do ktorého klastra jednotlivé sekvencie patria. Následne bol vybraný najväčší klaster a použitý na analýzu.

Výpis 7: Picking the largest cluster

```
def pick_largest_cluster(m: TextFileM):  
    cluster = max(m.data, key=len)
```

Tento skript prejde všetky vytvorené klastre, spočíta ich veľkosti a vyberie najväčší klaster. Vybraný klaster bol následne použitý ako reprezentatívna množina sekvencií pre ďalšie kroky analýzy. Následne bol tento klaster použitý na získanie DNA sekvencií určených pre ďalší program.

Výpis 8: Retrieving DNA sequences from a cluster

```
def retrieve_dna_lines(cluster_m: TextFileM, path):  
    cluster = cluster_m.data  
    result = []  
    with open(path, "r") as f:  
        lines = f.readlines()  
  
    for idx in cluster:  
        if idx < len(lines):  
            parts = lines[idx].split(" ", 1)  
            if idx != int(parts[0]):  
                print("IndexError")  
            if len(parts) > 1:  
                result.append(parts[1].strip())  
    return result
```

Posledný skript podľa ID sekvencií z vybraného klastra dohľadá zodpovedajúce DNA sekvencie a uloží ich vo formáte vhodnom pre nasledujúci nástroj. Tým sa uzatvára príprava dát po klastrovaní.

5.7 Viacnásobné zarovnanie sekvencií

Viacnásobné zarovnanie sekvencií (Multiple Sequence Alignment, MSA) je proces usporiadania troch alebo viacerých biologických sekvencií (DNA, RNA alebo proteínov) tak, aby boli identifikované podobné regióny medzi nimi. Tieto podobnosti môžu odhaliť štrukturálne, funkčné alebo evolučné vzťahy medzi sekvenciami.

5.7.1 Základný princíp

Pri viacnásobnom zarovnaní sekvencií hľadáme také usporiadanie, ktoré maximalizuje podobnosť medzi všetkými sekvenciami súčasne. Do sekvencií sú vkladane medzery (gap characters, značené pomlčkou '-'), aby sa zodpovedajúce pozície dostali do rovnakých stĺpcov.

subsubsection Príklad zarovnania Majme tri jednoduché sekvencie:

- Sekvencia 1: ACGT
- Sekvencia 2: AGT
- Sekvencia 3: ACCT

Ich zarovnanie môže vyzeráť nasledovne:

Seq1: A C G T

Seq2: A - G T

Seq3: A C C T

5.7.2 Význam a využitie

Viacnásobné zarovnanie má niekoľko dôležitých aplikácií:

- **Fylogenéza** – konštrukcia evolučných stromov
- **Identifikácia konzervovaných motívov** – nálezenie funkčne dôležitých oblastí
- **Predikcia štruktúry** – ododenie sekundárnej a terciárnej štruktúry proteínov
- **Homológia** – určenie príbuznosti medzi sekvenciami

5.7.3 Zložitosť problému

Viacnásobné zarovnanie je výpočtovo náročný problém. Presné riešenie pomocou dynamickeho programovania má časovú zložitosť $O(L^n)$, kde L je dĺžka sekvencií a n je ich počet. Preto sa v praxi používajú heuristické algoritmy.

5.7.4 Skórovacia funkcia

Kvalita zarovnania sa hodnotí pomocou skórovacej funkcie, ktorá typicky obsahuje:

- **Match score** – bodovanie zhody medzi znakmi
- **Mismatch penalty** – penalizácia za nezhodu
- **Gap penalty** – penalizácia za medzery (môže byť lineárna alebo afinná)

5.7.5 Bežné algoritmy

Medzi najpoužívanejšie algoritmy pre MSA patria:

- **ClustalW/ClustalOmega** – progresívne zarovnanie pomocou sprievodného stromu
- **MUSCLE** – rýchly progresívny algoritmus s iteratívnym spresňovaním
- **T-Coffee** – kombinuje párové zarovnania do finálneho MSA
- **MAFFT** – využíva FFT pre rýchle nájdenie homológnych oblastí

5.7.6 Vybraný viacnásobný alignment

V tejto práci bol implementovaný vlastný algoritmus pre viacnásobné zarovnanie sekvencií. Algoritmus ako vstup berie množinu DNA sekvencií, ktoré sú zo začiatku podobné, a postupne ich zarovnáva dokým sú dostatočne podobné. Výstupom algoritmu sú zarovnané sekvencie a informácia o tom, do akej dĺžky boli zarovnávané.

6 Vytvorenie práce

V tejto časti popisujem konkrétne kroky, ktoré som vykonal počas riešenia práce, vrátane spracovania dát, aplikácie algoritmov a vyhodnotenia výsledkov.

6.1 Analýza nanopórových sekvenačných dát pomocou Dorado a Clover

Najprv bol stiahnutý potrebný dataset z verejného repozitára. Následne bol na dané dáta aplikovaný basecaller Dorado, ktorý slúži na preklad surových súborov vo formáte pod5 do formátu BAM. Transformácia bola vykonaná pomocou nasledujúceho príkazu v termináli:

```
dorado basecaller --input-format pod5 --output-format bam --input /cesta/k/data
```

V ďalšom kroku bol stiahnutý a nainštalovaný nástroj Dorado. Na základe vlastností datasetu pod5 bol zvolený vhodný model Dorado určený na spracovanie daného datasetu. Výber modelu vychádzal z typu nanopórového zariadenia, pomocou ktorého bol dataset získaný. Po spracovaní basecallerom Dorado vznikol BAM súbor obsahujúci preložené sekvencie. Spracovanie trvalo približne X hodín, v závislosti od veľkosti datasetu a výpočtovej kapacity použitého hardvéru. Následne bol použitý algoritmus Clover, ktorý zoskupil sekvencie do jednotlivých klastrov na základe ich podobnosti. Problém spočíval v tom, že Clover neprijíma ako vstup súbory vo formáte BAM, ale vyžaduje textový formát FASTA alebo FASTQ. Preto bolo najprv potrebné previesť BAM súbory do textového formátu pomocou nástroja samtools. Po prevode bol spustený nástroj Clover, ktorý zoskupil sekvencie do jednotlivých klastrov na základe ich podobnosti. Nástroj Clover vrátil súbor so štruktúrou poľa obsahujúceho dvojice

celých čísel, kde prvé číslo reprezentovalo identifikátor sekvencie a druhé číslo reprezentovalo identifikátor referenčnej sekvencie klastra, do ktorého bola sekvencia zaradená. Zo všetkých vytvorených klastrov boli vybrané tie, ktoré boli dostatočne veľké na ďalšiu analýzu. Ukázalo sa však, že DNA sekvencie v klastroch sa zhodovali iba v úvodnom úseku dlhom niekoľko nukleotidov, čo znamenalo, že klastrovanie nebolo dostatočne presné. Neskôr sa zistilo, že Clover vykonáva zarovnanie iba podľa začiatku reťazca a neberie do úvahy zhodu v ďalších častiach sekvencie. V jednom klastri sa preto mohli nachádzať sekvencie, ktoré mali zhodu iba na začiatku a ďalej sa výrazne rozchádzali. Jeden klaster obsahoval viac ako 37 000 sekvencií, čo predstavovalo neobvykle veľký počet čítaní. Spoločná zhoda týchto sekvencií mala dĺžku iba 43 nukleotidov, pričom takýto jav sa javil ako málo pravdepodobný pri náhodnom výskyte. Vznikla hypotéza, že identifikovaný spoločný úsek zodpovedá DNA primeru. Po vytvorení konsenzu prvých 43 nukleotidov bol pripravený vlastný skript v jazyku Python s využitím knižnice Biopython. Skript bol aplikovaný na všetky sekvencie a slúžil na oddelenie DNA primerov od zvyšku sekvencií. Takto upravené sekvencie boli následne znovu zoskupené pomocou Clover, pričom tentoraz boli použité iba zvyšné časti sekvencií bez DNA primerov. Dáta očistené od DNA primerov sa znovu rozdelili do klastrov, ktoré už obsahovali sekvencie so zhodou nielen na začiatku, ale aj v ďalších častiach reťazca.

6.2 Hľadanie DNA reťazcov

Hľadanie DNA reťazcov v nanopórových dátach je komplexný proces, ktorý zahŕňa niekoľko krokov. Najprv sa surové dáta získané z nanopórového sekvenovania prekladajú pomocou basecallera Dorado do formátu BAM, ktorý umožňuje ďalšie spracovanie. Následne sa použije klastrovací algoritmus Clover na zoskupenie sekvencií do klastrov na základe ich podobnosti na začiatku reťazca. Zo všetkých vytvorených klastrov je vybraný najväčší klaster, na ktorý sa aplikuje vlastný multialignment algoritmus. Výsledkom je konsenzuálna sekvencia pre daný klaster. Tento konsenzus slúži ako primer, ktorý sa následne používa na vyhľadávanie v jednotlivých čítaniach. Pre každý read sa potom vyhľadá lokálne zarovnanie s primerom a vyberie sa sekvencia, ktorá nasleduje za primerom. Tieto sekvencie sa následne zoskupia pomocou Cloveru, čím vzniknú nové klastre. Na každý z týchto klastrov sa opäť aplikuje multialignment a zarovnané sekvencie sa použijú na vytvorenie konsenzuálnej sekvencie pre každý klaster. Týmto spôsobom sa získajú dlhé reťazce, z ktorých je možné filtrovať tie, ktoré sú dostatočne dlhé a zároveň dostatočne konzistentné.

6.3 Ako spúšťam proces

Celý pipeline spracovania dát sa skladá z nasledujúcich krokov, ktoré vykonávam postupne. Každý skript po spustení otvorí dialógové okno, v ktorom vyberiem vstupný súbor a určím, kam sa uloží výstup.

Krok 1 — Preklad nanopórových dát pomocou Dorado

Surové nanopórové dáta preložím pomocou basecallera Dorado do formátu .bam:

```
dorado basecaller <model> <pod5_vstup> > vystup.bam
```

Krok 2 — Konverzia BAM súboru do textového formátu

Spustím skript `CloverGenerateFyle.py`. Skript otvorí tkinter dialóg na výber BAM súboru a dialóg na určenie miesta uloženia výstupného .txt súboru, ktorý následne môžem použiť ako vstup pre Clover:

```
python CloverGenerateFyle.py
```

Krok 3 — Nájdenie primeru

Zavolám skript `GettingPrimer.py`. Skript otvorí dialóg na výber textového súboru, zavolá Clover, nájde najväčší klaster a na neho zavolá vlastný multi-alignment algoritmus. Výsledkom je konsenzuálna sekvencia primeru uložená do súboru `primerFound.txt`:

```
python GettingPrimer.py
```

Krok 4 — Rozdelenie sekvencií podľa primeru

Spustím skript `splitDnaByPrimer.py`. Skript otvorí dialóg na výber vstupného textového súboru a súboru `primerFound.txt`. Nájdene sekvencie s primerom sa ukladajú do adresára `PrimersFound`:

```
python splitDnaByPrimer.py
```

Krok 5 — Vyčistenie sekvencií od primeru

Zavolám skript `SelectFromPrimer.py`. Skript otvorí dialóg na výber vstupného súboru a vytvorí nový .txt súbor s DNA sekvenciami očistenými od primeru:

```
python SelectFromPrimer.py
```

Krok 6 — Záverečné klastrovanie a zarovnanie

Nakoniec zavolám skript `postPrimerClover.py`. Skript otvorí dialóg na výber vyčistených dát, zavolá Clover, nájde klastre a zarovná sekvencie. Pokiaľ nájde klastre požadovanej veľkosti (viac ako 10 nukleotidov), výsledky uloží do súborov vo formáte:


```
Aligned_dnaSize-{dist}num-{ClusterSize}id-{count}.txt
```

```
python postPrimerClover.py
```

Každý krok nadväzuje na výstup predchádzajúceho, pričom finálnym výsledkom sú zarovnané DNA reťazce roztriedené do klastrov.

7 Kritické zhodnotenie a zhrnutie

V práci som predstavil možnosti a výzvy spojené s ukladaním dát do DNA a spracovaním sekvenančných dát z nanopórového sekvenovania. Navrhnuté a implementované metódy prispievajú k efektívnejšiemu spracovaniu a analýze týchto dát. Cieľ bakalárskej práce bol splnený. Cieľom tejto bakalárskej práce bolo spracovanie dát získaných z Nanopore sekvenovania DNA za účelom modelovania narušenia informácie uchováanej v DNA pamäti. V rámci práce bol implementovaný celý pipeline spracovania dát — od stiahnutia surových signálov zo sekvenovacieho zariadenia, cez basecalling pomocou nástroja **Dorado**, až po zarovnanie a klastrovanie sekvencií pomocou algoritmu **Clover**. Na základe zarovnaných reťazcov bol navrhnutý a implementovaný vlastný multi-alignment algoritmus inšpirovaný beam search prístupom, ktorý umožňuje určenie konsenzu pre skupiny DNA sekvencií. Graf „Dĺžka reťazca vs počet DNA reťazcov“ prezentuje rozloženie dĺžok zarovnaných DNA reťazcov a ich zastúpenie v spracovaných dátach.



Obr. 1: Dĺžka reťazca vs počet DNA reťazcov

Pri vyhodnotení výsledkov boli použité nasledovné kritériá:

- dĺžka reťazca nad 100 bázových párov považovaná za dostatočnú,
- počet DNA reťazcov nad 10 ako prijateľný základ pre výpočet konsenzu,
- počet DNA reťazcov nad 50 ako veľmi silné zastúpenie zaručujúce spoľahlivý konsenzus.

Analýza ukázala, že v spracovaných dátach sa nachádzajú dostatočne dlhé reťazce s dostatočným zastúpením, čo umožňuje spoľahlivý výpočet konsenzu a následné modelovanie chybovosti Nanopore čítania. Získané výsledky tvoria základ pre ďalší výskum v oblasti DNA pamätí, konkrétne pre charakterizáciu chybových modelov pri Nanopore sekvenovaní.

Použitá literatura

1. SHOMORONY, Ilan; HECKEL, Reinhard. Information-Theoretic Foundations of DNA Data Storage. *Foundations and Trends in Communications and Information Theory*. 2022, roč. 19, č. 1, s. 1–106. Dostupné z doi: 10.1561/0100000117. Preprint of a monograph published in Foundations and Trends in Communications and Information Theory.
2. ZHENG, Peijie; ZHOU, Chuntao; DING, Yuemin; LIU, Bin. Nanopore sequencing technology and its applications. *MedComm*. 2023, roč. 4, č. 4. Dostupné z doi: 10.1002/mco2.316. Published July 2023.
3. LOPEZ, Randolph; CHEN, Yuan-Jyue; ANG, Siena Dumas; YEKHANIN, Sergey; MAKARYCHEV, Konstantin; RACZ, Miklos Z; SEELIG, Georg; STRAUSS, Karin; CEZE, Luis. DNA assembly for nanopore data storage readout. *Nature Communications*. 2019, roč. 10, č. 1, s. 1–9. Dostupné z doi: 10.1038/s41467-019-10978-4.
4. OXFORD NANOPORE TECHNOLOGIES. *Dorado Basecaller Documentation* [online]. [cit. 2026-05-03]. Dostupné z : https://software-docs.nanoporetech.com/dorado/latest/basecaller/basecall_overview/.
5. QU, Guanjin; YAN, Zihui; WU, Huaming. Clover: tree structure-based efficient DNA clustering for DNA-based data storage. *Briefings in Bioinformatics*. 2022, roč. 23, č. 5, s. 1–16. Dostupné z doi: 10.1093/bib/bbac336. Corresponding author: Huaming Wu, Center for Applied Mathematics, Tianjin University, Tianjin, 300072, China. E-mail: whming@tju.edu.cn.