

**PANEURÓPSKA VYSOKÁ ŠKOLA
FAKULTA INFORMATIKY**

FI-11145-18967

**Spracovanie údajov pre modelovanie narušenia informácie uchovávané
v pamäti DNA typu nanopor**

Bakalárska práca

2026

Patrik Homola

**PANEURÓPSKA VYSOKÁ ŠKOLA
FAKULTA INFORMATIKY**

**Spracovanie údajov pre modelovanie narušenia informácie uchovávané
v pamäti DNA typu nanopor**

Bakalárska práca

Patrik Homola

Študijný program: Aplikovaná informatika

Študijný odbor: Informatika

Školiace pracovisko: Ústav aplikovanej informatiky

Školiteľ: doc. RNDr. Peter Farkas, PhD.

Konzultant: Mgr. Peter Jarnvars

Bratislava 2026



PANEURÓPSKA VYSOKÁ ŠKOLA

Fakulta informatiky

ZADANIE PRÁCE

Meno a priezvisko študenta:

Evidenčné číslo práce:

Študijný odbor:

Študijný program:

Forma a metóda štúdia:

Vedúci práce:

Ústav/katedra:

Dátum zadania práce:

Názov:

Anotácia: Cieľom práce je vytvorenie komplexného systému pre navigáciu v interiéroch s napojením na rozličné webové zdroje s možnosťou ich editovania a návrh shaderov pre ich zobrazenie. Súčasťou práce bude analýza použitia v reálnom nasadení vrátane implementácie a zobrazovania na rozličných dotykových zariadeniach.

.....
RNDr. Ján Lacko, PhD.
vedúci práce

.....
Ing. Juraj Štefanovič, PhD.
vedúci ústavu

Podakovanie:

Pri vypracovaní tejto práce by som sa rád poďakoval za odbornú pomoc pánovi doc. RNDr. Peter Farkas, PhD., ktorý mi poskytol mnoho cenných rád a konzultácií.

Podakovanie môžete napísať podľa seba.

Čestné prehlásenie:

Čestne vyhlasujem, že záverečnú prácu som vypracoval samostatne a že som uviedol všetku použitú literatúru.

.....

Patrik Homola

Abstrakt

Táto bakalárska práca sa zaoberá spracovaním sekvenačných dát z nanopórového sekvenovania s cieľom vytvoriť nástroje a metódy na získanie DNA reťazcov vhodných pre modelovanie narušenia informácie v DNA kanáloch. Práca opisuje navrhnutý a implementovaný pipeline, ktorý transformuje surové elektrické signály vo formáte pod5 na zarovnané a zklasifikované DNA sekvencie. Kľúčovými komponentmi riešenia sú konverzia dát z formátu BAM do textovej podoby, viacnásobné zarovnanie sekvencií pomocou vlastného algoritmu inšpirovaného beam search prístupom a identifikácia primeru bez predchádzajúcej znalosti jeho presnej sekvencie. Práca demonštruje, že zo surového signálu je možné získať relevantné DNA reťazce, ktoré tvoria spoľahlivý základ pre charakterizáciu chybovosti nanopórového čítania. Navrhnutý metodický a implementačný rámec umožňuje pokračovať v ďalšom výskume smerom k presnejšiemu modelovaniu narušenia informácie v DNA pamätiach.

Kľúčové slová: nanopórové sekvenovanie, spracovanie DNA dát, zarovnanie sekvencií, DNA pamäť, modelovanie chýb

Abstract

This bachelor thesis addresses the processing of sequencing data from nanopore sequencing with the goal of creating tools and methods to obtain DNA sequences suitable for modeling information perturbation in DNA channels. The thesis describes a proposed and implemented pipeline that transforms raw electrical signals in pod5 format into aligned and classified DNA sequences. Key components of the solution are conversion of data from BAM format to text representation, multiple sequence alignment using a custom algorithm inspired by the beam search approach, and primer identification without prior knowledge of its exact sequence. The work demonstrates that from raw signal it is possible to obtain relevant DNA sequences that form a reliable basis for characterizing the error rate of nanopore reading. The proposed methodological and implementation framework enables further research towards more accurate modeling of information perturbation in DNA storage systems.

Keywords: nanopore sequencing, DNA data processing, sequence alignment, DNA storage, error modeling

Obsah

Obsah	6
Zoznam obrázkov	8
Zoznam skratiek a značiek	9
1 Úvod	10
2 Motivácia	10
3 Ciele a zadanie práce	11
3.1 Uloha	11
3.1.1 Cieľový výstup analýzy DNA sekvenčných dát	11
4 Opis dát	13
4.1 V akom stave sú dáta k dispozícii	13
4.2 Aké sú s tým problémy	13
4.2.1 Dátový formát	13
4.2.2 Kde sa nachádzajú dlhé reťazce	14
5 Teoretické okienko	15
5.1 Biologická syntéza DNA	15
5.1.1 Smer reťazca: $5' \rightarrow 3'$ a $3' \rightarrow 5'$	15
5.1.2 Simplexný a duplexný reťazec	16
5.2 Nanopore	16
5.3 Prekladanie DNA/mRNA do signálu	17
5.3.1 Primer a štartovací úsek	18
5.4 Viacnásobné zarovnanie sekvencií	18
5.4.1 Základný princíp	18
5.4.2 Význam a využitie	19
5.4.3 Zložitosť problému	19
5.4.4 Skórovacia funkcia	19
5.4.5 Bežné algoritmy	19
6 Výber nástrojov a metód na realizáciu práce	20
6.1 Dorado Basecaller	20
6.1.1 Ako spustiť Dorado	20
6.2 Clover	20
6.2.1 Vybraný viacnásobný alignment	21

6.3	Python a BioPython	21
7	Praktická realizácia	21
7.1	Spustenie Dorado basecallera a prvé klastrovanie	22
7.1.1	Stiahnutie a spustenie Dorado basecallera	22
7.1.2	Príprava dát a konverzia BAM na text	22
7.2	Spustenie klastrovacieho nástroja Clover	22
7.2.1	Konverzia dát na textový formát	22
7.2.2	Spustenie Clover nástroja	22
7.2.3	Parametre a konfigurácia klastrovania	23
7.2.4	Analýza výstupov Clover nástroja	23
7.2.5	Identifikácia najväčšieho klastra	23
7.2.6	Extrahovanie sekvencií z klastra	24
7.3	Hľadanie primeru pomocou Lokálneho zarovnania	24
7.3.1	Výber kandidáta primeru z najväčšieho klastra	24
7.3.2	Lokálne zarovnanie pomocou Biopythonu	24
7.3.3	Určenie pozícií primeru v jednotlivých čítaniach	25
7.3.4	Interpretácia a spracovanie nálezov	26
7.3.5	Extrahovanie sekvencií za primermi	26
7.3.6	Zarovnanie klastra za primermi	27
7.4	Ukladanie a zhrnutie spracovaných dát	28
7.4.1	Prehľad kompletného pipeline procesu	28
7.4.2	Krok 1: Spustenie Dorado basecallera	29
7.4.3	Krok 2: Konverzia BAM na textový formát	29
7.4.4	Krok 3: Hľadanie primeru	29
7.4.5	Krok 4: Rozdelenie sekúncií za primermi	30
7.4.6	Krok 5: Čistenie a spracovanie dát	30
7.4.7	Krok 6: Finálne klastrovanie	30
7.4.8	Ukladanie výsledkov do výstupného priečinka	30
8	Kritické zhodnotenie a zhrnutie	30
	Použitá literatúra	33

Zoznam obrázkov

1	Príklad surového signálu z nanopore senzoru - signal trace pre jeden kanál. Graf ukazuje elektrický prúd (v pA) meraný v čase počas prechodu DNA molekuly nanopórou.	14
2	Príklad zarovnania DNA sekúncií z jedného klastra. Obrázok ukazuje konzistentné výsledky viacnásobného zarovnania s viditeľnými zhodami v sekvenciách.	29
3	Dĺžka reťazca vs počet DNA reťazcov	31

Zoznam skratiek a značiek

BPMN	Business Process Model and Notation Notácia pre modelovanie business procesov
DNA	Deoxyribonucleic Acid Deoxyribonucleic Acid - DNA je molekula nesúca genetické informácie používané v rastlinách, zvieratách a väčšine organizmov. Je tvorená dvoma reťazcami nukleotidov, ktoré tvoria dvojité špirálu.
FASTQ	Fast Quality Fast Quality - Formát súboru používaný na ukladanie sekvenčných dát spolu s kvalitatívnymi skóre pre každú bázu.
OCL	Object Constraint Language Jazyk pre špecifikáciu obmedzení, dotazov a vyhľadávacích operácií v UML
RNA	Ribonucleic Acid Ribonucleic Acid - RNA je molekula podobná DNA, ktorá hrá kľúčovú úlohu v procese prepisu a prekladu genetickej informácie. Na rozdiel od DNA je zvyčajne jednovláknová a obsahuje uracil namiesto thymínu.
SNR	Signal-to-Noise Ratio Signal-to-Noise Ratio - Poměr medzi úrovňou požadovaného signálu a úrovňou šumu, ktorý môže ovplyvniť kvalitu dát získaných z nanopórového sekvenovania.
UML	Unified Modeling Language Univerzálny jazyk pre vizuálne modelovanie systémov

1 Úvod

V tejto bakalárskej práci sa venujem problematike ukladania dát do DNA a spracovaniu sekvenačných dát získaných pomocou nanopórového sekvenovania. Práca je rozdelená do piatich hlavných častí: úvod, opis dát, príprava praktickej realizácie, vlastné vytvorenie riešenia a kritické zhodnotenie so zhrnutím.

2 Motivácia

V dnešnej digitálnej dobe sa množstvo generovaných dát exponenciálne zvyšuje, čo vytvára potrebu efektívnych a trvalo udržateľných metód ich ukladania. Tradičné úložné médiá, ako sú pevné disky, SSD disky a magnetické pásky, majú obmedzenú životnosť a kapacitu, čo vedie k častým migráciám dát a zvýšeným nákladom na údržbu. DNA ako médium pre ukladanie dát ponúka niekoľko významných výhod:

- **Vysoká hustota ukladania:** Hustota informácií v DNA je extrémne vysoká. Len 5 gramov DNA obsahuje približne $4 \cdot 10^{21}$ nukleotidov, čo by teoreticky mohlo uchovať $8 \cdot 10^{21}$ bitov, alebo jeden zettabyte [1]. To znamená, že obrovské množstvo informácií môže byť uložené v mimoriadne malom objeme.
- **Dlhodobá stabilita:** DNA je chemicky stabilná molekula, ktorá môže prežiť tisíce rokov za správnych podmienok. Na rozdiel od tradičných médií, ktoré sa môžu degradovať počas niekoľkých dekád, DNA môže uchovávať dáta po veľmi dlhú dobu bez straty integrity.
- **Energetická efektívnosť:** Ukladanie dát do DNA nevyžaduje neustálu energiu na udržiavanie dát, na rozdiel od elektronických úložísk, ktoré potrebujú napájanie na zachovanie informácií. To vedie k výrazným úsporám energie a znižuje ekologickú stopu dátových centier.
- **Ľahká replikácia a prenosnosť:** DNA môže byť ľahko kopírovaná pomocou biologických procesov, čo umožňuje jednoduché zálohovanie a prenos dát medzi rôznymi miestami bez potreby špecializovaného hardvéru.
- **Odolnosť voči technologickému zastaraniu:** Na rozdiel od tradičných úložných médií, ktoré môžu rýchlo zastarať v dôsledku technologického pokroku, DNA ako médium zostáva nezmenené a čitateľné pomocou základných biologických techník.

Napriek uvedeným výhodám proces čítania DNA pomocou nanopórov prináša špecifické výzvy. Pri sekvenovaní DNA cez nanopór sa DNA molekula prechádza cez nanopór po jednotlivých nukleotidoch, pričom elektrický signál identifikuje bázy. Podrobnejšie vysvetlenie tejto technológie bude uvedené v sekcii 5.2. Tento proces je však náchylný na chyby, keďže

DNA sa môže pohybovať rýchlo alebo nepravidelne, čo vedie k nesprávnemu určeniu sekvencie nukleotidov. Tieto chyby v čítaní majú priamy vplyv na integritu uložených dát a vyžadujú sofistikované metódy kódovania a korekcie chýb. S pokračujúcim vývojom technológií nanopórového sekvenovania sa presnosť postupne zvyšuje, čo robí z DNA perspektívnu alternatívu k tradičným metódam ukladania dát. Cieľom tejto práce je prispieť k zefektívneniu procesu ukladania dát do DNA vytvorením modelu narušenia, ktorý popisuje chyby vznikajúce pri čítaní a zápise dát. Pochopením a formalizáciou týchto narušení je možné zvýšiť spoľahlivosť a presnosť ukladania a načítavania informácií, čo je kľúčové pre praktické využitie DNA ako úložného média v budúcnosti.

Model narušenia opisuje pravdepodobnostné správanie chýb, ktoré vznikajú počas syntézy, sekvenovania a uchovávaní DNA molekúl. Tento model zachytáva typy chýb ako substitúcie, inzercie a delécie nukleotidov, čím poskytuje základ pre návrh efektívnych kódovacích a opravných schém pri ukladaní dát do DNA.

3 Ciele a zadanie práce

V tejto kapitole sú definované hlavné ciele a zadanie bakalárskej práce.

3.1 Uloha

Cieľom tejto úlohy je simulovať chyby, ktoré vznikajú pri čítaní DNA pomocou nanopórového sekvenovania. Nanopórové sekvenovanie je inovatívna technológia, ktorá umožňuje rýchle a efektívne čítanie genetického materiálu. Úlohou je vytvoriť generátor, ktorý na základe pravdepodobnosti chyby náhodne pridáva chyby do reálneho DNA reťazca. Tento generátor by mal byť schopný simulovať rôzne typy chýb, ako sú záměny báz, vloženia alebo vynechania báz, ktoré sa môžu vyskytnúť počas procesu sekvenovania. Táto simulácia bude slúžiť na testovanie a vyhodnocovanie algoritmov pre spracovanie sekvenačných dát, ktoré musia byť robustné voči týmto chybám. Cieľom je zlepšiť presnosť a spoľahlivosť analýzy genetických informácií získaných pomocou nanopórového sekvenovania.

3.1.1 Cieľový výstup analýzy DNA sekvenčných dát

Cieľ výstupu analýzy DNA získaných pomocou nanopórového sekvenovania je určiť vzťah medzi pôvodným DNA reťazcom a jeho pozorovanými čítaniami, ktoré vznikajú počas sekvenovania. Namiesto priameho priradenia konkrétneho referenčného reťazca k jednotlivým čítaniam je zvolený opačný postup: z dostupných nanopórových čítaní sa odhaduje najpravdepodobnejšia pôvodná sekvencia. Tento odhad je založený na identifikácii dostatočne veľkej množiny podobných sekvencií, pri ktorých možno predpokladať spoločný pôvod. Následne sa pre takúto skupinu vypočíta konsenzus, ktorý by mal byť čo najbližšie pôvodnému DNA reťazcu.

Konsenzus je syntetizovaná sekvencia zložená z nukleotidov, ktoré sa v každej pozícii zarovnaných sekvencií vyskytujú s najväčšou frekvenciou. Inými slovami, pre každú pozíciu v zarovnaní sa vyberie báza (A, C, G alebo T), ktorá sa v danej pozícii objavuje najčastejšie vo všetkých zarovnaných čítaniach. Konsenzus tak reprezentuje najlepší odhad pôvodnej DNA sekvencie na základe dostupných pozorovaní a ich spoľahlivosti.

Keďže DNA reťazce sú dlhé a jednotlivé čítania obsahujú chyby, sekvencie sa môžu navzájom líšiť a byť vzájomne posunuté. Z tohto dôvodu je potrebné vykonať viacnásobné zarovnanie sekvencií (multiple sequence alignment), aby sa konsenzus určoval z nukleotidov nachádzajúcich sa v rovnakých pozíciách.

Takto definovaný výstup umožňuje vytvoriť pravdepodobnostný model čítania DNA k-tíc (k-merov). Tento model sa interpretuje ako komunikačný kanál a vychádza z matematickej teórie komunikácie

Shannon 1948 Communication. Namiesto jedného pevného výsledku sa každej k-tici priraduje rozdelenie možných prečítaných sekvencií. Formálne môžeme písať

$$X = \Sigma^k, \quad Y = \Sigma^*, \quad K(y | x) = \Pr(Y = y | X = x),$$

kde $\Sigma = \{A, C, G, T\}$, $x \in \Sigma^k$ je pôvodná k-tica a $y \in \Sigma^*$ je prečítaná sekvencia. Tá môže mať aj inú dĺžku v dôsledku delécií alebo inzercíí.

Pre konkrétnu k-ticu, napríklad $x = \text{ATCG}$, môže byť rozdelenie nasledovné:

$$\Pr(Y = \text{ATCG} | X = x) = 0.33,$$

$$\Pr(Y = \text{ATTTCG} | X = x) = 0.20,$$

$$\Pr(Y = \text{TCG} | X = x) = 0.10,$$

$$\Pr(Y = \text{AGCG} | X = x) = 0.07.$$

Zvyšná pravdepodobnosť patrí ostatným chybovým variantom tak, aby celkový súčet bol rovný 1. Takýto model zachytáva substitúcie, inzercie a delécie a je kľúčový pre realistickú simuláciu chýb pri generovaní nových DNA sekvencií.

Zároveň platí, že jedna skupina podobných sekvencií spravidla neobsahuje dostatočný počet variácií na spoľahlivý odhad chýb pre všetky možné k-mery. Počet k-tíc rastie exponenciálne podľa 4^k ; napríklad pre $k = 4$ ide o 256 možných 4-merov. Pravdepodobnosť, že všetky tieto varianty budú dostatočne zastúpené v jednej skupine, je nízka, preto je potrebné objaviť viacero sekvenčných skupín.

Požadovaný výstup preto pozostáva z viacerých skupín navzájom zarovnaných DNA sekvencií a zodpovedajúcich konsenzuálnych sekvencií pre každú skupinu. Takto definovaný výstup umožňuje dosiahnuť dostatočné pokrytie variácií čítaní odvodených z toho istého DNA reťazca.

4 Opis dát

V tejto kapitole sa zameriavam na charakteristiku dát, ktoré sú k dispozícii pre túto prácu, a na problémy spojené s ich spracovaním.

4.1 V akom stave sú dáta k dispozícii

Data boli stiahnuté z verejného repozitára, ktorý obsahoval surové sekvenačné dáta vo formáte pod5. Tieto dáta predstavovali čítania DNA reťazcov získané pomocou nanopórového sekvenovania. Dáta boli stiahnuté pomocou nástroja AWS s použitím príkazu `aws s3 sync`, ktorý umožňuje kopírovať súbory z úložiska Amazon S3 do lokálneho prostredia.

```
aws s3 sync --no-sign-request s3://ont-open-data/gm24385_2020.09 /  
media/marek/EAGET/gm24385_2020.09
```

Dáta boli uložené do adresára `/media/marek/EAGET/gm24385_2020.09`. Sťahovanie trvalo približne 2 hodiny, pričom celková veľkosť stiahnutých dát bola približne 10 GB. Data obsahovali čítania DNA reťazcov, ktoré vznikajú počas procesu nanopórového sekvenovania. Tieto čítania sú často dlhé a obsahujú chyby, čo predstavuje výzvu pri ich analýze. Aby bolo možné tieto dáta efektívne analyzovať, bolo potrebné ich prekonvertovať pomocou basecallera Dorado do formátu BAM, ktorý je štandardným formátom pre ukladanie sekvenačných dát a umožňuje efektívne spracovanie a analýzu. Po konverzii do formátu BAM bolo potrebné dáta zoskupiť a zarovnať, aby sa identifikovali podobné sekvencie a vytvorili konsenzuálne sekvencie, ktoré by mohli reprezentovať pôvodný DNA reťazec.

4.2 Aké sú s tým problémy


4.2.1 Dátový formát

Jedným z hlavných problémov pri spracovaní sekvenačných dát je rozdiel medzi formátom, v ktorom sú dáta publikované, a formátom vhodným na ďalšiu analýzu. Vstupné dáta boli dostupné najmä vo formáte pod5, ktorý obsahuje surový elektrický signál z nanopórového sekvenovania. Tento surový signál je potrebné preložiť do DNA sekvencií, ktoré sú následne použiteľné pre klastrovanie a viacnásobné zarovnanie.

Po preklade signálu nástrojom Dorado vzniká výstup vo formáte BAM, ktorý síce obsahuje prečítané sekvencie, ale pre ďalšie kroky bolo potrebné údaje transformovať do jednoduchšieho textového tvaru.

Taktiež dáta spracované klastrovaním algoritmom Clover poskytovali výstup v špecifickom formáte, ktorý je potrebné ďalej spracovať, aby bolo možné získať samotné klastre a následne ich zarovnať a získať konsenzus.

Samotné dáta boli rozsiahle, ich sťahovanie trvalo dlhý čas a spracovanie nástrojom Dorado basecallerom trvalo pol dňa v najrýchlejšom režime. Tiež bolo potrebné stiahnuť



Obr. 1: Príklad surového signálu z nanopore senzoru - signal trace pre jeden kanál. Graf ukazuje elektrický prúd (v pA) meraný v čase počas prechodu DNA molekuly nanopórou.

predinštalovaný nástroj Dorado, ktorý zaberal veľa miesta v pamäti.

4.2.2 Kde sa nachádzajú dlhé reťazce

Dáta spracované do formátu BAM obsahujú viacero sekvencií DNA, ktoré sa navzájom líšia dĺžkou aj obsahom. Každý riadok reprezentuje jedno čítanie z nanopórovej sekvenácie. Dĺžka DNA čítaní sa pohybuje približne od 100 nukleotidov až po 1 000 000 nukleotidov. Jedným z možných dôvodov výskytu veľmi dlhých čítaní je, že zariadenie môže postupne načítať viac DNA sekvencií za sebou, pričom nástroj Dorado ich neoddelí a spracuje ich ako jednu sekvenciu. Zároveň možno predpokladať, že v rámci jedného čítania sa tá istá sekvencia môže vyskytovať opakovane. Tento jav môže súvisieť s biosyntézou DNA, pri ktorej dochádza k replikácii a vzniku viacerých kópií tej istej sekvencie. Tá istá sekvencia bude pravdepodobne načítaná viackrát, avšak s odlišnými chybami, keďže nanopórové sekvenovanie je chybovejšie. Okrem toho sa sekvencia môže načítať v opačnej orientácii, pretože molekula vstupuje do nanopóru z rôznych koncov. Sekvenciu preto možno získať v smere $3' \rightarrow 5'$ alebo $5' \rightarrow 3'$.

V dôsledku biosyntézy vzniká aj komplementárna sekvencia DNA, v ktorej sú bázy nahradené podľa pravidiel párovania ($A \rightarrow T$, $T \rightarrow A$, $G \rightarrow C$, $C \rightarrow G$). Aj komplementárna sekvencia môže byť čítaná v oboch smeroch. Pre každú pôvodnú sekvenciu sa teda môžu vyskytnúť až štyri varianty: pôvodná sekvencia v smere $3' \rightarrow 5'$ a $5' \rightarrow 3'$, a jej komplement v smere $3' \rightarrow 5'$ a $5' \rightarrow 3'$. Ďalším javom je fragmentácia DNA, pri ktorej vznikajú kratšie sekvencie zodpovedajúce iba časti pôvodnej sekvencie. Ich dĺžky sa líšia podľa miesta pretrhnutia. Zároveň sa môže stať, že niektoré sekvencie sa replikujú častejšie ako iné. Napriek uvedeným komplikáciám bolo možné predpokladať, že v dlhých čítaniach bude možné identifikovať dostatočne dlhé opakujúce sa úseky, ktoré reprezentujú tú istú pôvodnú DNA sekvenciu. Na základe tohto predpokladu bol identifikovaný klaster obsahujúci viac ako 37 000 sekvencií DNA. Spočiatku sa zdalo, že ide o opakované čítanie jednej sekvencie, čo by mohlo viesť k získaniu kvalitného konsenzu. Podrobnejšia analýza však ukázala, že spoločná zhoda medzi

sekvenciami bola obmedzená iba na úvodný úsek s dĺžkou 43 nukleotidov.

Keďže 43 nukleotidov predstavuje príliš krátky úsek na spoľahlivú reprezentáciu celého DNA reťazca, no zároveň je príliš dlhý na náhodne sa vyskytujúci úsek, pôvodná hypotéza o prítomnosti dostatočne dlhého spoločného jadra nebola potvrdená. Na základe tohto zistenia bola formulovaná nová hypotéza: spoločný úvodný úsek pravdepodobne zodpovedá DNA primeru prítomnému na začiatku sekvenovaných fragmentov.

Nasledujúcim krokom preto bolo lokálne hľadanie primeru v jednotlivých čítaniach. Primer sa nevyhľadával iba na začiatku reťazca, ale v celom rozsahu každého čítania, aby sa zachytili aj prípady jeho posunu alebo výskytu vo vnútri sekvencie.

5 Teoretické okienko

V tejto kapitole sa zameriavam na teoretické základy, ktoré sú nevyhnutné pre pochopenie praktickej realizácie práce s nanopórovými dátami a viacnásobným zarovnaním sekvencií. Táto časť poskytuje prehľad o biologických procesoch, technológiách a algoritmoch, ktoré sú relevantné pre spracovanie a analýzu DNA sekvencií v kontexte tejto práce.

5.1 Biologická syntéza DNA

Biologická syntéza DNA je proces, pri ktorom DNA polymeráza vytvára nový reťazec na základe templátového vlákna, pričom syntéza prebieha výlučne v smere $5' \rightarrow 3'$. Kľúčovou podmienkou začatia syntézy je prítomnosť primeru, teda krátkeho komplementárneho oligonukleotidu, ktorý sa naviaže na templát a poskytne voľnú $3'$ -OH skupinu potrebnú pre katalytickú aktivitu polymerázy. Po naviazaní primeru polymeráza postupne inkorporuje deoxyribonukleotidy podľa pravidiel komplementárneho párovania báz (A–T, G–C), čím predlžuje vznikajúci reťazec DNA. Tento proces je nevyhnutný pre replikáciu DNA, ktorá je základom prenosu genetickej informácie.

5.1.1 Smer reťazca: $5' \rightarrow 3'$ a $3' \rightarrow 5'$

DNA reťazec má chemickú polaritu — jeden koniec reťazca má voľnú fosfátovú skupinu na $5'$ uhlíku cukru ($5'$ koniec) a druhý koniec má voľnú hydroxylovú skupinu na $3'$ uhlíku ($3'$ koniec).

- **Smer $5' \rightarrow 3'$** — smer, v ktorom DNA polymeráza syntetizuje nový reťazec. Polymeráza číta templát v smere $3' \rightarrow 5'$ a zapisuje nový reťazec v smere $5' \rightarrow 3'$.
- **Smer $3' \rightarrow 5'$** — smer čítania templátového vlákna počas syntézy. Nie je možné syntetizovať reťazec v tomto smere priamo.

Táto polarita má priamy dopad na nanopórové sekvenovanie — tá istá DNA molekula môže vstúpiť do nanopóru z ľubovoľného konca, čím vznikajú čítania v oboch smeroch (forward aj reverse). Pri spracovaní dát je preto potrebné uvažovať s oboma orientáciami.

5.1.2 Simplexný a duplexný reťazec

- **Simplex (ssDNA)** — jednoreťazcová DNA. Obsahuje iba jedno vlákno nukleotidov. Vyskytuje sa napríklad počas replikácie alebo pri niektorých vírusoch. V kontexte nanopórového sekvenovania sa čítanie vykonáva práve na jednoreťazcovej forme.
- **Duplex (dsDNA)** — dvojureťazcová DNA. Dve komplementárne vlákna sú navzájom spojené vodíkovými väzbami medzi párami báz (A–T, G–C) a tvoria charakteristickú dvojité špirálu (double helix). Toto je štandardná forma, v ktorej je DNA uložená v bunke.

Pri biosyntéze DNA vzniká z jednoreťazcového templátu nový komplementárny reťazec — výsledkom je duplexná DNA. Pre každý pôvodný reťazec tak existuje komplementárny reťazec s opačnou polaritou. To znamená, že pri nanopórovom sekvenovaní sa môžu vyskytnúť štyri varianty toho istého úseku DNA:

1. pôvodný reťazec v smere $5' \rightarrow 3'$,
2. pôvodný reťazec v smere $3' \rightarrow 5'$ (reverzný),
3. komplementárny reťazec v smere $5' \rightarrow 3'$,
4. komplementárny reťazec v smere $3' \rightarrow 5'$ (reverzný komplement).

Tieto štyri varianty sú kľúčovým zdrojom komplikácií pri klastrovacích algoritmoch — sekvencie reprezentujúce rovnaký úsek DNA môžu byť sekvenom prečítané v rôznych formách a bez primerov ich nie je možné jednoducho stotožniť.

5.2 Nanopore

Nanopore sekvenovanie je technológia používaná na sekvenovanie DNA a RNA molekúl [2]. Táto metóda umožňuje čítanie genetického materiálu tým, že molekuly prechádzajú cez nanometrové póry (nanopóry), čo vedie k zmene elektrického prúdu, ktorý je následne analyzovaný na určenie sekvencie nukleotidov [2]. Je to revolučná technológia v oblasti genetiky, ktorá umožňuje rýchle a presné sekvenovanie s minimálnymi nákladmi a zariadeniami prenosných veľkostí [2]. Aplikácie nanopórového sekvenovania zahŕňajú diagnostiku chorôb, výskum genetických porúch a monitorovanie environmentálnych vzoriek [2]. Nanopórové sekvenovanie je obzvlášť užitočné pre jeho schopnosť čítať dlhé sekvencie DNA, čo zjednodušuje zostavovanie genómov a identifikáciu štruktúrnych variácií [2, 3]. Funguje na princípe

detekcie zmien v elektrickom prúde, keď molekula prechádza cez nanopór, čo umožňuje priame čítanie sekvencií bez potreby amplifikácie alebo značenia [2]. DNA alebo RNA molekuly sú vedené cez nanopór pomocou elektrického poľa, pričom každá báza spôsobuje charakteristickú zmenu prúdu, ktorá je zaznamenaná a analyzovaná softvérom na určenie sekvencie [2].

5.3 Prekladanie DNA/mRNA do signálu

Prekladanie DNA alebo RNA sekvencií do elektrického signálu v nanopórovom sekvenovaní [2] zahŕňa niekoľko kľúčových krokov:

- **Príprava vzorky:** DNA alebo RNA molekuly sú pripravené na sekvenovanie, často zahŕňajúce fragmentáciu a pridanie adaptérnych sekvencií.
- **Vedenie cez nanopór:** Molekuly sú vedené cez nanopór pomocou elektrického poľa, ktoré spôsobuje ich pohyb [2].
- **Detekcia prúdu:** Keď molekula prechádza cez nanopór, každá báza spôsobuje charakteristickú zmenu v elektrickom prúde, ktorý je zaznamenaný ako časová séria dát [2].
- **Analýza signálu:** Zaznamenaný elektrický signál je analyzovaný pomocou algoritmov na identifikáciu sekvencie nukleotidov na základe zmien prúdu [2].
- **Preklad do sekvencie:** Softvér prekladá analyzovaný signál späť do sekvencie DNA alebo RNA, čo umožňuje výskumníkom získať genetické informácie z pôvodnej molekuly [2].

Výstupom z procesu nanopórového sekvenovania je sekvencia nukleotidov (A, T, C, G pre DNA alebo A, U, C, G pre RNA) reprezentujúca genetickú informáciu pôvodnej molekuly [2]. Tento výstup je často vo forme textového súboru (napríklad FASTQ formát), ktorý obsahuje sekvencie spolu s kvalitatívnymi skóre pre každú bázu [2]. Vzhľadom na technické obmedzenia a variabilitu v procese sekvenovania je bežné, že jednotlivé DNA alebo RNA retiazce sú prečítané niekoľkokrát (tzv. "coverage" alebo "depth of coverage") [2]. Toto opakované čítanie zvyšuje spoľahlivosť a presnosť výslednej sekvencie, pretože umožňuje korekciu chýb a identifikáciu variácií v genetickom materiáli [2, 3]. No napriek tomu, že sa retiazce čítajú viackrát, stále môže dôjsť k nepresnostiam v sekvencii kvôli šumu v signáli [2]. Retiazce DNA alebo RNA môžu byť čítané rôznou rýchlosťou počas nanopórového sekvenovania, čo môže ovplyvniť kvalitu a presnosť zaznamenaného signálu [2]. Rýchlosť prechodu molekuly cez nanopór je ovplyvnená viacerými faktormi, vrátane veľkosti molekuly, jej konformácie, interakcií s nanopórom a podmienok prostredia (napríklad teplota a iónová sila) [2].

Keďže DNA a RNA molekuly sú veľmi malé, signál zaznamenaný počas nanopórového sekvenovania odráža interakcie jednotlivých nukleotidov (báz) s nanopórom [2]. Každá báza

má jedinečný tvar a elektrické vlastnosti, ktoré ovplyvňujú spôsob, akým mení elektrický prúd pri prechode cez nanopór [2]. Preto je možné získať signál pre každú jednotlivú bázu v molekule, čo umožňuje presné čítanie sekvencie [2].

5.3.1 Primer a štartovací úsek

Primer je krátky úsek DNA so známou sekvenciou, ktorý sa viaže na komplementárnu časť templátu a určuje miesto, od ktorého sa začína syntéza alebo analýza reťazca. V biologickom kontexte poskytuje voľnú 3'-OH skupinu pre DNA polymerázu, čím umožňuje predlžovanie nového vlákna.

V tejto práci primer predstavuje zároveň praktický orientačný bod pri spracovaní nanopórových čítaní. Jeho detekcia umožňuje určiť štartovací úsek reťazca, zjednotiť orientáciu čítaní a odseparovať relevantnú časť sekvencie od technických alebo menej informatívnych oblastí. Vďaka tomu je možné získať homogennejšie vstupy pre klastrovanie a následné viacnásobné zarovnanie.

Keďže primer sa nemusí nachádzať presne na začiatku každého čítania, vyhľadáva sa lokálne v celom reťazci. Tento prístup je robustnejší voči posunu, inzerciám, deléciám a substitúciám, ktoré sú pri nanopórovom sekvenovaní bežné.

5.4 Viacnásobné zarovnanie sekvencií

Viacnásobné zarovnanie sekvencií (Multiple Sequence Alignment, MSA) je proces usporiadania troch alebo viacerých biologických sekvencií (DNA, RNA alebo proteínov) tak, aby boli identifikované podobné regióny medzi nimi. Tieto podobnosti môžu odhaliť štrukturálne, funkčné alebo evolučné vzťahy medzi sekvenciami.

5.4.1 Základný princíp

Pri viacnásobnom zarovnaní sekvencií hľadáme také usporiadanie, ktoré maximalizuje podobnosť medzi všetkými sekvenciami súčasne. Do sekvencií sú vkladane medzery (gap characters, značené pomlčkou '-'), aby sa zodpovedajúce pozície dostali do rovnakých stĺpcov.

subsubsection Príklad zarovnania Majme tri jednoduché sekvencie:

- Sekvencia 1: ACGT
- Sekvencia 2: AGT
- Sekvencia 3: ACCT

Ich zarovnanie môže vyzeráť nasledovne:

Seq1: A C G T

Seq2: A - G T

Seq3: A C C T

5.4.2 Význam a využitie

Viacnásobné zarovnanie má niekoľko dôležitých aplikácií:

- **Fylogenéza** – konštrukcia evolučných stromov
- **Identifikácia konzervovaných motívov** – nálezenie funkčne dôležitých oblastí
- **Predikcia štruktúry** – odvodenie sekundárnej a terciárnej štruktúry proteínov
- **Homológia** – určenie príbuznosti medzi sekvenciami

5.4.3 Zložitosť problému

Viacnásobné zarovnanie je výpočtovo náročný problém. Presné riešenie pomocou dynamickeho programovania má časovú zložitosť $O(L^n)$, kde L je dĺžka sekvencií a n je ich počet. Preto sa v praxi používajú heuristické algoritmy.

5.4.4 Skórovacia funkcia

Kvalita zarovnania sa hodnotí pomocou skórovacej funkcie, ktorá typicky obsahuje:

- **Match score** – bodovanie zhody medzi znakmi
- **Mismatch penalty** – penalizácia za nezhodu
- **Gap penalty** – penalizácia za medzery (môže byť lineárna alebo afinná)

5.4.5 Bežné algoritmy

Medzi najpoužívanejšie algoritmy pre MSA patria:

- **ClustalW/ClustalOmega** – progresívne zarovnanie pomocou sprievodného stromu
- **MUSCLE** – rýchly progresívny algoritmus s iteratívnym spresňovaním
- **T-Coffee** – kombinuje párové zarovnania do finálneho MSA
- **MAFFT** – využíva FFT pre rýchle nálezenie homológnych oblastí

6 Výber nástrojov a metód na realizáciu práce

v tejto kapitole sú predstavené nástroje a metódy, ktoré boli vybrané pre realizáciu praktickej časti práce, vrátane ich základných charakteristík a dôvodov výberu.

6.1 Dorado Basecaller

Dorado je pokročilý basecaller vyvinutý spoločnosťou Oxford Nanopore Technologies (ONT) na prekladanie surového elektrického signálu získaného z nanopórového sekvenovania na sekvenciu nukleotidov (A, T, C, G pre DNA alebo A, U, C, G pre RNA). Je navrhnutý tak, aby poskytoval vysokú presnosť a rýchlosť pri spracovaní sekvenačných dát, čo je kľúčové pre rôzne aplikácie v oblasti genomiky a bioinformatiky.

6.1.1 Ako spustiť Dorado

Pred spustením bolo potrebné stiahnuť model pomocou príkazu:

```
dorado download --list  
dorado download --model dna_r10.4.1_e8.2_400bps_hac@v4.2.0
```

Dorado podporuje viacero módov spracovania:

- fast — rýchlejší, ale menej presný
- hac — pomalší, ale kvalitnejší (High Accuracy)
- sup — najpomalší, najvyššia presnosť (Super Accuracy)

Na spustenie basecallera bol použitý nasledujúci príkaz:

```
dorado basecaller hac <adresar_s_pod5> --recursive --max-reads 100 > Calls.bam
```

Parameter `-recursive` je potrebný na spracovanie všetkých súborov v adresári a jeho podadresároch.

Parameter `-max-reads` bol nastavený na 100, ktorý limituje počet čítaní, ktoré Dorado spracuje. Tento limit je dobrý na testovanie a ladenie procesu, keďže spracovanie miliónov čítaní by zabralo príliš veľa času. Pre finálne spracovanie by tento parameter mal byť odstranенý alebo nastavený na vyššiu hodnotu, aby sa spracovali všetky dostupné dáta. [4]

6.2 Clover

Klastrovací algoritmus je metóda, ktorá rozdeľuje množinu dát do skupín (klastrov) tak, aby dáta v rámci jednej skupiny boli si navzájom podobné a dáta z rôznych skupín boli odlišné [5]. Tieto algoritmy sa často používajú v bioinformatike na analýzu sekvencií DNA alebo iných

biologických dát. Clover algoritmus je efektívny klastrovač navrhnutý špeciálne pre DNA sekvencie v oblasti DNA-based data storage. Využíva stromovú štruktúru na rýchle a presné zoskupovanie sekvencií podľa ich podobnosti, čím zvyšuje efektívnosť a škálovateľnosť procesu [5]. Clover umožňuje efektívne spracovanie veľkých množín sekvencií a je vhodný pre moderné aplikácie v oblasti ukladania dát do DNA. Clover algoritmus klastruje sekvencie DNA na základe ich počiatočných úsekov a usporadúva ich do stromovej štruktúry podobnej trie. Trie funguje ako hierarchická usporiadaná stromová štruktúra, kde každý uzol reprezentuje spoločný prefix a vetvy vedú k sekvenciám, ktoré sa líšia v nasledujúcich pozíciách.

Nástroj Clover prijíma dáta vo formáte, v ktorom každý riadok obsahuje identifikátor a DNA sekvenciu, napríklad: fasta alebo txt súbor s formátom `ĎD sekvencia`".

6.2.1 Vybraný viacnásobný alignment

V tejto práci bol implementovaný vlastný algoritmus pre viacnásobné zarovnanie sekvencií. Algoritmus ako vstup berie množinu DNA sekvencií, ktoré sú zo začiatku podobné, a postupne ich zarovnáva, dokým sú dostatočne podobné. Tento algoritmus funguje dobre pre početnejšie množiny podobných sekvencií. Výstupom algoritmu sú zarovnané sekvencie a informácia o tom, do akej dĺžky boli zarovnávané.

6.3 Python a BioPython

Python je vysokoúrovňový programovací jazyk, ktorý sa vyznačuje jednoduchou syntaxou a širokou škálou knižníc, čo ho činí ideálnym nástrojom pro bioinformatické analýzy.

BioPython je rozsiahla knižnica pre biologické výpočty v Pythone, ktorá poskytuje nástroje na prácu s biologickými dátami, vrátane sekvencií DNA, RNA. V tejto práci bol Python použitý na implementáciu rôznych krokov spracovania a analýzy DNA sekvencií, vrátane lokalizácie primerov, klastrovania a viacnásobného zarovnania. BioPython bol použitý hlavne pre vyhľadávanie primerov a zarovnanie sekvencií pomocou modulu `Bio.Align`. Knižnica `Py-Sam` bola použitá pre prácu s BAM súbormi, ktoré vznikajú po preklade nanopórových čítaní nástrojom Dorado. Z knižnice `tkinter` bolo použité `filedialog` pre vytvorenie jednoduchého grafického rozhrania na výber súborov, čo zjednodušilo interakciu počas spracovania dát.

7 Praktická realizácia

V tejto časti popisujem konkrétne kroky, ktoré boli vykonané počas riešenia práce, vrátane spracovania dát, aplikácie algoritmov a vyhodnotenia výsledkov.

7.1 Spustenie Dorado basecallera a prvé klastrovanie

7.1.1 Stiahnutie a spustenie Dorado basecallera

Najprv bol stiahnutý potrebný dataset z verejného repozitára. Následne bol na dané dáta aplikovaný basecaller Dorado, ktorý slúži na preklad surových súborov vo formáte pod5 do formátu BAM. Transformácia bola vykonaná pomocou nasledujúceho príkazu v termináli:

```
dorado basecaller fast <pod5_vstup> > vystup.bam
```

7.1.2 Príprava dát a konverzia BAM na text

V ďalšom kroku bol stiahnutý a nainštalovaný nástroj Dorado. Na základe vlastností datasetu pod5 bol zvolený vhodný model Dorado určený na spracovanie daného datasetu. Výber modelu vychádzal z typu nanopórového zariadenia, pomocou ktorého bol dataset získaný. Po spracovaní basecallerom Dorado vznikol BAM súbor obsahujúci preložené sekvencie. Spracovanie trvalo približne 3-6 hodín. Následne bol tento BAM súbor konvertovaný do jednoduchšieho textového formátu Vhodného pre Klastrovací algoritmus Clover, ktorý bol použitý v ďalšom kroku.

7.2 Spustenie klastrovacieho nástroja Clover

7.2.1 Konverzia dát na textový formát

Na spustenie klastrovacieho nástroja bolo potrebné previesť dáta z formátu BAM do textového formátu.

Výpis 1: Bam to Txt Conversion

```
def ConvertBamToTxt(bam, out):  
    for i, read in enumerate(bam):  
        seq = read.query_sequence # the DNA sequence  
        out.write(f"{i} {seq}\n")
```

7.2.2 Spustenie Clover nástroja

Následne bol klastrovací nástroj spustený s nasledujúcim nastavením:

Výpis 2: Spustenie klastrovacieho nástroja

```
python -m clover.main -I output.txt -O example.txt -L 150 -P 2  
--no-tag
```


7.2.3 Parametre a konfigurácia klastrovania

Pri spustení bol použitý vstupný súbor `output.txt` (-I) a výstupný súbor `example.txt` (-O). Parametre majú nasledujúci význam:

- -I [input_file]: vstupný súbor. Aktuálne sú podporované formáty `txt`, `fasta` a `fastq`. Každý riadok má tvar [index], [read].
- -O [output_file_name]: názov výstupného súboru. Výstupný súbor bude uložený v priečinku Clover.
- -L [int]: dĺžka čítania (length of read).
- -P [int]: voľba režimu spracovania. P=0 znamená jednovláknové/jeden proces; P=1 a P=2 znamenajú 4, resp. 16 procesov.
- -no-tag: tento prepínač je potrebné pridať, ak je vstupný súbor v „untagged“ formáte.

7.2.4 Analýza výstupov Clover nástroja

Clover vrátil súbor so štruktúrou poľa, ktoré obsahovalo dvojice celých čísel, kde prvé číslo reprezentovalo identifikátor sekvencie a druhé číslo reprezentovalo identifikátor prvej sekvencie, ku ktorej bola daná sekvencia zaradená.

Výpis 3: Clustering Data

```
tuples = m.data
data_sorted = sorted(tuples, key=lambda x: x[1])
groups = []

for k, g in itertools.groupby(data_sorted, key=lambda x: x[1]):
    groups.append([k] + [a[0] for a in g])
return groups
```

Uvedený skript načíta výstup z nástroja Clover a prevedie ho do dátovej štruktúry vhodnej na ďalšie spracovanie. Konkrétne spracuje dvojice identifikátorov tak, aby bolo možné jednoducho zistiť, do ktorého klastra jednotlivé sekvencie patria.

7.2.5 Identifikácia najväčšieho klastra

Následne bol vybraný najväčší klaster a použitý na analýzu.

Výpis 4: Picking the largest cluster

```
def pick_largest_cluster(m: TextFileM):
    cluster = max(m.data, key=len)
```

Tento skript prejde všetky vytvorené klastre, spočíta ich veľkosti a vyberie najväčší klastre. Vybraný klastre bol následne použitý ako reprezentatívna množina sekvencií pre ďalšie kroky analýzy.

7.2.6 Extrahovanie sekvencií z klastra

Následne bol tento klastre použitý na získanie DNA sekvencií určených pre ďalší program.

Výpis 5: Retrieving DNA sequences from a cluster

```
def retrieve_dna_lines(cluster_m: TextFileM, path):
    cluster = cluster_m.data
    result = []
    with open(path, "r") as f:
        lines = f.readlines()

    for idx in cluster:
        if idx < len(lines):
            parts = lines[idx].split(" ", 1)
            if idx != int(parts[0]):
                print("IndexError")
            if len(parts) > 1:
                result.append(parts[1].strip())
    return result
```

Posledný skript podľa ID sekvencií z vybraného klastra dohľadá zodpovedajúce DNA sekvencie a uloží ich vo formáte vhodnom pre nasledujúci nástroj. Tým sa uzatvára príprava dát po klastrovaní.

7.3 Hľadanie primeru pomocou Lokálneho zarovnania

7.3.1 Výber kandidáta primeru z najväčšieho klastra

Na základe zistenia, že spoločná zhoda medzi sekvenciami bola obmedzená iba na úvodný úsek s dĺžkou 43 nukleotidov, bol tento úsek označený ako primer a bolo rozhodnuté vyhľadať ho v každom čítaní. Vyhľadávanie sa neobmedzilo len na jeho výskyt na začiatku sekvencie, ale zahŕňalo celý rozsah každého čítania, aby boli zachytené aj prípady, kde sa primer nachádza posunutý alebo vo vnútri sekvencie.

7.3.2 Lokálne zarovnanie pomocou Biopythonu

Súbor obsahujúci čítania z Dorado vo formáte FASTA bol načítaný do pamäte a následne bol použitý algoritmus z knižnice Biopython, ktorý umožňuje vyhľadávať lokálne zarovnania medzi primerom a jednotlivými čítaniami.

Funkcia `aligner.align(primer, read)` vracia všetky lokálne zarovnanie medzi primerom a daným čítaním, zoradené podľa skóre zarovnanie. Každé zarovnanie obsahuje informácie o pozícii zarovnanie v celkovom reťazci aj o lokálne zarovnanom úseku, ktorý v tomto prípade zodpovedá primeru. Výstup je reprezentovaný dvojicou riadkov a sadou fragmentov, z ktorých je možné určiť začiatok a koniec zarovnaného úseku v pôvodnom čítaní.

7.3.3 Určenie pozícií primeru v jednotlivých čítaniach

Na určenie pozícií, v ktorých sa lokálne zarovnaný reťazec zhoduje s primerom, sa využívajú hodnoty `aligned[1][0][0]` a `aligned[1][-1][1]`.

Výpis 6: Finding occurrences of a primer in reads

```
def findOcurences(primer: str, reads: List[str]):
    aligner = Align.PairwiseAligner()
    aligner.mode = 'local'

    aligner.match_score = 2
    aligner.mismatch_score = -1
    aligner.open_gap_score = -2
    aligner.extend_gap_score = -0.5

    threshold = len(primer) * 1. # tune this!

    sizeOfReads = len(reads)

    PrimersFound = []
    for read_id, read in enumerate(reads):
        read = read.strip()

        alignments = aligner.align(primer, read)
        lastIds = set()
        for i, aln in enumerate(alignments):
            if i >= 100:
                break
            if aln.score < threshold:
                # print(aln.score)
                break

            # extract positions
            # print(aln)
            aligned = aln.aligned
            read_start = aligned[1][0][0]
```

```

        read_end = aligned[1][-1][1]

        lastIds.add(read_end)
        # print(f"Read {read_id}: {read_start}-{read_end},
        #       score={aln.score}")
    if read_id % 1000 == 0:
        print(f"Read {read_id}/ {sizeOfReads}:{lastIds}")
    PrimersFound.append(lastIds)
return PrimersFound

```

7.3.4 Interpretácia a spracovanie nálezov

Pozície nájdených primerov boli uložené do poľa v tvare:

```
[[[]], [65], [55], [], [64], [], [55], [74, 73], [64], [75], ...]
```

Každý prvok poľa zodpovedá jednému čítaniu a obsahuje pozície, na ktorých sa primer nachádza v danom čítaní. Z výsledkov vyplýva, že v nie každom reťazci bol primer identifikovaný, zatiaľ čo v niektorých čítaniach sa vyskytol viackrát. Tento jav môže byť spôsobený tým, že niektoré čítania obsahujú komplementárnu sekvenciu alebo boli prečítané v opačnom smere. Ďalším dôvodom môže byť pretrhnutie DNA reťazca v rôznych miestach alebo príliš nízka podobnosť primeru vzhľadom na nastavený prah zarovnania.

7.3.5 Extrahovanie sekvencií za primermi

Výpis 7: Stripping primers from Clover input

```

with open(clover_input_path, "r") as f:
    lines = f.readlines()

with open(PrimersPath, "r") as f:
    datas = f.read()

primers = ast.literal_eval(datas)

newLines = []
for (line, linePrimes) in zip(lines, primers):
    prevValue = -1
    for prime in linePrimes:
        if (prevValue != -1 ):
            if prevValue - prime < 50:

```

```

        continue
    newline = line[prime:prevValue]
    if(len(newline)<50):
        continue
    newLines.append(newline)
    prevValue = prime

WriteLines=[]
for (i,line) in enumerate(newLines):
    WriteLines.append(f"{i} {line}\n")

with open("PrimersStripClover.txt", "w") as f:
    f.writelines(WriteLines)

```

Následne boli extrahované úseky za primerom a zapísané do nového súboru, ktorý obsahuje čítania od primeru až po koniec reťazca, prípadne po ďalší primer, ak sa v čítaní nachádzal viackrát. Tieto dáta boli následne znovu zoskupené pomocou algoritmu Clover, pričom tentoraz boli použité iba zvyšné časti sekvencií bez DNA primerov. Výsledkom bolo, že vytvorené klastre obsahovali sekvencie, ktoré mali zhodu nielen na začiatku, ale aj v ďalších častiach reťazca. To naznačovalo, že sekvencie pochádzajú z toho istého DNA reťazca v správnom smere, a nie z opačne orientovaného alebo komplementárneho reťazca.

7.3.6 Zarovnanie klastra za primermi

Na klastre bolo aplikované viacnásobné zarovnanie.

Výpis 8: Clustering without primers

```

ClusterFile = TextFileM(path="clusters_output.txt")
ClusterFile = ClusterFile.load()
ClusterFile = parse_tuple_file(ClusterFile)
ClusterFile = get_clusters(ClusterFile)
clusters = ClusterFile.data

#ClusterFile = pick_largest_cluster(ClusterFile)
#LargestCluster = []
#LargestCluster = ClusterFile.data

clusters = [l for l in clusters if len(l) > 10]
count=1
for clust in clusters:
    ClusterFile.data=clust

```

```

ClusterFile = retrieve_dna_lines(ClusterFile, clover_input_path
    )
DataToBeAligned = ClusterFile.data

ClusterSize = len(DataToBeAligned)
(Aligned, Unaligned) = DataBeamAlgorithmSplit(DataToBeAligned,
    10)
dist = len(Aligned[0].replace("_", ""))
if len(Aligned[0].replace("_", "")) < 10:
    continue

Aligned.insert(0, str(clust))

TextFileM(data=Aligned).write_data_to_file(f"GeneratedData/
    Aligned_dnaSize-{dist}num-{ClusterSize}id-{count}.txt")
count+=1

```

Filtrovaním klastrov na viacšie ako 10 sekvencií bolo dosiahnuté, že sa zarovnávali iba klastre s dostatočným počtom sekvencií, čo umožnilo získať robustnejšie výsledky. Taktiež bolo odfiltrované zarovnanie klastrov, ktoré obsahovali sekvencie s dĺžkou kratšou ako 10 nukleotidov, aby sa zabezpečilo, že zarovnávané sekvencie budú dostatočne dlhé na získanie zmysluplných výsledkov. Ukázalo sa, že klastre obsahovali sekvencie, ktoré mali zhodu nielen na začiatku, ale aj ďalej v reťazci. Niektoré klastre obsahovali sekvencie, ktoré sa zhodovali až do dĺžky 100 nukleotidov, čo predstavuje výrazne dlhší úsek než pôvodný primer.

Príklad získaného zarovnania

Na obrázku 2 je zobrazený príklad jedného z mnohých nájdených zarovnaných klastrov. Vidno, že jednotlivé čítania obsahujú spoločné úseky, ktoré boli úspešne zarovnané, čo potvrdzuje správnosť detekcie primeru a klastrovania.

7.4 Ukladanie a zhrnutie spracovaných dát

7.4.1 Prehľad kompletného pipeline procesu

Celý pipeline spracovania dát sa skladá z nasledujúcich krokov, ktoré vykonávam postupne. Každý skript po spustení otvorí dialógové okno, v ktorom vyberiem vstupný súbor a určím, kam sa uloží výstup.

Obr. 2: Príklad zarovnania DNA sekúncií z jedného klastra. Obrázok ukazuje konzenzuálne výsledky viacnásobného zarovnania s viditeľnými zhodami v sekvenciách.

7.4.5 Krok 4: Rozdelenie sekúncií za primermi

Krok 4 — Rozdelenie sekvencií podľa primeru

Spustím skript `splitDnaByPrimer.py`. Skript otvorí dialóg na výber vstupného textového súboru a súboru `primerFound.txt`. Nájdene sekvencie s primerom sa ukladajú do adresára `PrimersFound`:

```
python splitDnaByPrimer.py
```

7.4.6 Krok 5: Čistenie a spracovanie dát

Krok 5 — Vyčistenie sekvencií od primeru

Zavolám skript `SelectFromPrimer.py`. Skript otvorí dialóg na výber vstupného súboru a vytvorí nový `.txt` súbor s DNA sekvenciami očistenými od primeru:

```
python SelectFromPrimer.py
```

7.4.7 Krok 6: Finálne klastrovanie

Krok 6 — Záverečné klastrovanie a zarovnanie

Nakoniec zavolám skript `postPrimerClover.py`. Skript otvorí dialóg na výber vyčistených dát, zavolá Clover, nájde klastre a zarovná sekvencie. Pokiaľ nájde klastre požadovanej veľkosti (viac ako 10 nukleotidov), výsledky uloží do súborov vo formáte:

```
Aligned_dnaSize-{dist}num-{ClusterSize}id-{count}.txt
```

```
python postPrimerClover.py
```


7.4.8 Ukladanie výsledkov do výstupného priečinka

Každý krok nadväzuje na výstup predchádzajúceho, pričom finálnym výsledkom sú zarovnané DNA reťazce roztriedené do klastrov.

8 Kritické zhodnotenie a zhrnutie

V práci boli predstavené možnosti a výzvy spojené s ukladáním dát do DNA a spracovaním sekvenačných dát z nanopórového sekvenovania. Navrhnuté a implementované metódy prispievajú k efektívnejšiemu spracovaniu a analýze týchto dát. Cieľ bakalárskej práce bol splnený. Cieľom tejto bakalárskej práce bolo navrhnúť a implementovať pomocné algoritmy a metódy na spracovanie dát získaných z nanopórového sekvenovania. Tieto postupy boli zamerané na vytvorenie spoľahlivého podkladu pre modelovanie narušenia informácie v DNA

reťazcoch. V rámci práce bol implementovaný celý pipeline spracovania dát — od stiahnutia surových signálov zo sekvenovacieho zariadenia, cez basecalling pomocou nástroja **Dorado**, až po zarovnanie a klastrovanie sekvencií pomocou algoritmu **Clover**. Na základe zarovnaných reťazcov bol navrhnutý a implementovaný vlastný multi-alignment algoritmus inšpirovaný beam search prístupom, ktorý umožňuje určenie konsenzu pre skupiny DNA sekvencií. Graf „Dĺžka reťazca vs počet DNA reťazcov“ prezentuje rozloženie dĺžok zarovnaných DNA reťazcov a ich zastúpenie v spracovaných dátach.



Obr. 3: Dĺžka reťazca vs počet DNA reťazcov

Pri vyhodnotení výsledkov boli použité nasledovné kritériá:

- dĺžka reťazca nad 100 báзовých párov považovaná za dostatočnú,
- počet DNA reťazcov nad 10 ako prijateľný základ pre výpočet konsenzu,
- počet DNA reťazcov nad 50 ako veľmi silné zastúpenie zaručujúce spoľahlivý konsenzus.

Analýza ukázala, že v spracovaných dátach sa nachádzajú dostatočne dlhé reťazce s dostatočným zastúpením, čo umožňuje spoľahlivý výpočet konsenzu a následné modelovanie chybovosti Nanopore čítania. Získané výsledky tvoria základ pre ďalší výskum v oblasti DNA pamätí, konkrétne pre charakterizáciu chybových modelov pri Nanopore sekvenovaní. Za kľúčový výsledok možno považovať skutočnosť, že zo surového signálu vo formáte pod5 bolo možné získať viacero zarovnaných klastrov jedného čítania, pričom pipeline spoľahlivo pokrýva vstupné aj výstupné štádiá spracovania dát. Zároveň bolo možné identifikovať

primer bez predchádzajúcej explicitnej informácie o jeho presnej sekvencii. Medzi hlavné obmedzenia práce patrila najmä náročnosť spracovania výstupov vo formáte BAM a následná identifikácia reálnych dlhých reťazcov v dátach. Významnou praktickou výzvou bolo aj určenie, v ktorých častiach dát sa tieto reťazce skutočne vyskytujú, pričom identifikácia primeru predstavovala kľúčový bod pre stabilizáciu ďalších krokov analýzy. Výsledky práce zároveň vytvárajú priestor pre nadväzujúci výskum zameraný na modelovanie narušenia DNA kanála, rozšírenie množiny analyzovaných dát a presnejšiu charakterizáciu chýb. Ďalším smerom je vyhľadávanie a klastrovanie reverzných a komplementárnych reťazcov, ktoré môže viesť k získaniu dodatočných informácií pre robustnejšie modelovanie. Práca vytvorila metodický a implementačný rámec, ktorý umožňuje pokračovať smerom k presnejšej charakterizácii chýb v nanopórovom čítaní.

Použitá literatura

1. SHOMORONY, Ilan; HECKEL, Reinhard. Information-Theoretic Foundations of DNA Data Storage. *Foundations and Trends in Communications and Information Theory*. 2022, roč. 19, č. 1, s. 1–106. Dostupné z doi: 10.1561/0100000117. Preprint of a monograph published in Foundations and Trends in Communications and Information Theory.
2. ZHENG, Peijie; ZHOU, Chuntao; DING, Yuemin; LIU, Bin. Nanopore sequencing technology and its applications. *MedComm*. 2023, roč. 4, č. 4. Dostupné z doi: 10.1002/mco2.316. Published July 2023.
3. LOPEZ, Randolph; CHEN, Yuan-Jyue; ANG, Siena Dumas; YEKHANIN, Sergey; MAKARYCHEV, Konstantin; RACZ, Miklos Z; SEELIG, Georg; STRAUSS, Karin; CEZE, Luis. DNA assembly for nanopore data storage readout. *Nature Communications*. 2019, roč. 10, č. 1, s. 1–9. Dostupné z doi: 10.1038/s41467-019-10978-4.
4. OXFORD NANOPORE TECHNOLOGIES. *Dorado Basecaller Documentation* [online]. [cit. 2026-05-03]. Dostupné z : https://software-docs.nanoporetech.com/dorado/latest/basecaller/basecall_overview/.
5. QU, Guanjin; YAN, Zihui; WU, Huaming. Clover: tree structure-based efficient DNA clustering for DNA-based data storage. *Briefings in Bioinformatics*. 2022, roč. 23, č. 5, s. 1–16. Dostupné z doi: 10.1093/bib/bbac336. Corresponding author: Huaming Wu, Center for Applied Mathematics, Tianjin University, Tianjin, 300072, China. E-mail: whming@tju.edu.cn.