

**PANEURÓPSKA VYSOKÁ ŠKOLA
FAKULTA INFORMATIKY**

FI-11145-18967

**Spracovanie udajov pre modelovanie narušenia informácie uchovavanej
v DNA pamäti typu nanopor**

Bakalárska práca

2026

Patrik Homola

**PANEURÓPSKA VYSOKÁ ŠKOLA
FAKULTA INFORMATIKY**

**Spracovanie udajov pre modelovanie narušenia informácie uchovavanej
v DNA pamäti typu nanopor**

Bakalárska práca

Patrik Homola

Študijný program: Aplikovaná informatika

Študijný odbor: Informatika

Školiace pracovisko: Ústav aplikovanej informatiky

Školiteľ: doc. RNDr. Peter Farkas, PhD.

Konzultant: Mgr. Peter Jarnvars

Bratislava 2026



PANEURÓPSKA VYSOKÁ ŠKOLA

Fakulta informatiky

ZADANIE PRÁCE

Meno a priezvisko študenta:

Evidenčné číslo práce:

Študijný odbor:

Študijný program:

Forma a metóda štúdia:

Vedúci práce:

Ústav/katedra:

Dátum zadania práce:

Názov:

Anotácia: Cieľom práce je vytvorenie komplexného systému pre navigáciu v interiéroch s napojením na rozličné webové zdroje s možnosťou ich editovania a návrh shaderov pre ich zobrazenie. Súčasťou práce bude analýza použitia v reálnom nasadení vrátane implementácie a zobrazovania na rozličných dotykových zariadeniach.

.....
RNDr. Ján Lacko, PhD.
vedúci práce

.....
Ing. Juraj Štefanovič, PhD.
vedúci ústavu

Podakovanie:

Pri vypracovaní tejto práce by som sa rád poďakoval za odbornú pomoc pánovi doc. RNDr. Peter Farkas, PhD., ktorý mi poskytol mnoho cenných rád a konzultácií.

Podakovanie môžete napísať podľa seba.

Čestné prehlásenie:

Čestne vyhlasujem, že záverečnú prácu som vypracoval samostatne a že som uviedol všetku použitú literatúru.

.....

Patrik Homola

Abstrakt

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Integer eu lacus leo. Nulla egestas purus non dignissim tincidunt. In sit amet tellus bibendum, lobortis magna ut, sodales mi. Etiam vel eros efficitur purus ultrices vulputate et quis justo. Nunc ultrices tellus a dui mattis, eget laoreet arcu tempor. Donec vestibulum, magna ac fringilla lacinia, libero risus fringilla arcu, nec consectetur nibh justo vel sem. Quisque gravida sit amet elit ut aliquam.

Abstrakt obsahuje informáciu o cieľoch práce, jej stručnom obsahu a v závere abstraktu sa charakterizuje splnenie cieľa, výsledky a význam celej práce. Súčasťou abstraktu je 3 - 5 kľúčových slov.

Kľúčové slová: Kľúčové slovo 1, Kľúčové slovo 2, Kľúčové slovo 3

Abstract

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Integer eu lacus leo. Nulla egestas purus non dignissim tincidunt. In sit amet tellus bibendum, lobortis magna ut, sodales mi. Etiam vel eros efficitur purus ultrices vulputate et quis justo. Nunc ultrices tellus a dui mattis, eget laoreet arcu tempor. Donec vestibulum, magna ac fringilla lacinia, libero risus fringilla arcu, nec consectetur nibh justo vel sem. Quisque gravida sit amet elit ut aliquam.

Abstrakty v anglickom a slovenskom jazyku sa musia zhodovať.

Keywords: Keyword 1, Keyword 2, Keyword 3

Obsah

Obsah	6
Zoznam obrázkov	8
Zoznam skratiek a značiek	9
1 Úvod	10
2 Motivácia	11
3 Ciele a zadanie práce	13
3.1 Uloha	14
3.1.1 Vstup	14
4 Opis dát	15
4.1 V akom stave sú dáta k dispozícii	15
4.2 Aké sú s tým problémy	17
4.3 Aký je očakávaný výstup dát a v akej forme majú byť dáta po spracovaní . .	22
5 Čo bolo potrebné, aby sa riešenie dalo prakticky realizovať	24
6 Nanopore	25
6.1 Prekladanie DNa/Mra do signálu	25
7 Dorado Basecaller	27
7.1 Názov podkapitoly	27
7.2 Cluster clover	28
7.3 Viacnásobné zarovnanie sekvencií	31
7.3.1 Základný princíp	31
7.3.2 Význam a využitie	31
7.3.3 Zložitosť problému	31
7.3.4 Skórovacia funkcia	32
7.3.5 Bežné algoritmy	32
8 Vytvorenie práce	33
9 Bio Informatics Analysis of Nanopore Sequencing Data Using Dorado Basecaller and Clover Clustering Algorithm	34
9.1 Hľadanie DNA reťazcov	35
10 Kritické zhodnotenie a zhrnutie	36

Zoznam obrázkov

1	Dĺžka reťazca vs počet DNA reťazcov	37
---	---	----

Zoznam skratiek a značiek

BPMN	Business Process Model and Notation Notácia pre modelovanie business procesov
DNA	Deoxyribonucleic Acid Deoxyribonucleic Acid - DNA je molekula nesúca genetické informácie používané v rastlinách, zvieratách a väčšine organizmov. Je tvorená dvoma reťazcami nukleotidov, ktoré tvoria dvojité špirálu.
FASTQ	Fast Quality Fast Quality - Formát súboru používaný na ukladanie sekvenčných dát spolu s kvalitatívnymi skóre pre každú bázu.
OCL	Object Constraint Language Jazyk pre špecifikáciu obmedzení, dotazov a vyhľadávacích operácií v UML
RNA	Ribonucleic Acid Ribonucleic Acid - RNA je molekula podobná DNA, ktorá hrá kľúčovú úlohu v procese prepisu a prekladu genetickej informácie. Na rozdiel od DNA je zvyčajne jednovláknová a obsahuje uracil namiesto thymínu.
SNR	Signal-to-Noise Ratio Signal-to-Noise Ratio - Poměr medzi úrovňou požadovaného signálu a úrovňou šumu, ktorý môže ovplyvniť kvalitu dát získaných z nanopórového sekvenovania.
UML	Unified Modeling Language Univerzálny jazyk pre vizuálne modelovanie systémov

1 Úvod

V tejto bakalárskej práci sa venujem problematike ukladania dát do DNA a spracovaniu sekvenačných dát získaných pomocou nanopórového sekvenovania. Práca je rozdelená do piatich hlavných častí: úvod, opis dát, príprava praktickej realizácie, vlastné vytvorenie riešenia a kritické zhodnotenie so zhrnutím.

2 Motivácia

V dnešnej digitálnej dobe sa množstvo generovaných dát exponenciálne zvyšuje, čo vytvára potrebu efektívnych a trvalo udržateľných metód ich ukladania. Tradičné úložné médiá, ako sú pevné disky, SSD disky a magnetické pásky, majú obmedzenú životnosť a kapacitu, čo vedie k častým migráciám dát a zvýšeným nákladom na údržbu. Naopak, DNA ako médium pre ukladanie dát ponúka niekoľko významných výhod:

- **Vysoká hustota ukladania:** DNA má neuveriteľne vysokú hustotu ukladania dát, kde jeden gram DNA môže teoreticky uložiť až 215 petabajtov (215 miliónov gigabajtov) dát. To znamená, že obrovské množstvo informácií môže byť uložené v mimoriadne malom objeme.
- **Dlhodobá stabilita:** DNA je chemicky stabilná molekula, ktorá môže prežiť tisíce rokov za správnych podmienok. Na rozdiel od tradičných médií, ktoré sa môžu degradovať počas niekoľkých dekád, DNA môže uchovávať dáta po veľmi dlhú dobu bez straty integrity.
- **Energetická efektívnosť:** Ukladanie dát do DNA nevyžaduje neustálu energiu na udržiavanie dát, na rozdiel od elektronických úložísk, ktoré potrebujú napájanie na zachovanie informácií. To vedie k výrazným úsporám energie a znižuje ekologickú stopu dátových centier.
- **Ľahká replikácia a prenosnosť:** DNA môže byť ľahko kopírovaná pomocou biologických procesov, čo umožňuje jednoduché zálohovanie a prenos dát medzi rôznymi miestami bez potreby špecializovaného hardvéru.
- **Odolnosť voči technologickému zastaraniu:** Na rozdiel od tradičných úložných médií, ktoré môžu rýchlo zastarať v dôsledku technologického pokroku, DNA ako médium zostáva nezmenené a čitateľné pomocou základných biologických techník.

Napriek týmto výhodám, proces čítania DNA pomocou nanopórov prináša špecifické výzvy. Pri sekvenovaní DNA cez nanopór sa DNA molekula prechádza cez nanopór po jednotlivých nukleotidoch, pričom elektrický signál identifikuje bázy. Tento proces je však náchylný na chyby, keďže DNA sa môže pohybovať rýchlo alebo nepravidelne, čo vedie k nesprávnemu určeniu sekvencie nukleotidov. Tieto chyby v čítaní majú priamy vplyv na integritu uložených dát a vyžadujú sofistikované metódy kódovania a korekcie chýb. Avšak s pokračujúcim vývojom technológií nanopórového sekvenovania sa presnosť postupne zvyšuje, čo robí z DNA perspektívnu alternatívu k tradičným metódam ukladania dát.

Cieľom tejto práce je prispieť k zefektívneniu procesu ukladania dát do DNA vytvorením DNA kanála s lepšími vlastnosťami pre čítanie a zápis dát. Optimalizáciou týchto procesov môžeme zvýšiť rýchlosť a presnosť ukladania a načítavania informácií, čo je kľúčové pre praktické využitie DNA ako úložného média v budúcnosti.

DNA kanál predstavuje špecifický spôsob, akým sú dáta kódované a ukladané do DNA molekúl. Tento kanál zahŕňa výber vhodných sekvencií nukleotidov, ktoré minimalizujú chyby pri čítaní a zápise dát, ako aj optimalizáciu procesov syntézy a sekvenovania DNA.

3 Ciele a zadanie práce

3.1 Uloha

Cieľom tejto úlohy je simulovať chyby, ktoré vznikajú pri čítaní DNA pomocou nanopórového sekvenovania. Nanopórové sekvenovanie je inovatívna technológia, ktorá umožňuje rýchle a efektívne čítanie genetického materiálu. Úlohou je vytvoriť generátor, ktorý na základe pravdepodobnosti chyby náhodne pridáva chyby do reálneho DNA reťazca. Tento generátor by mal byť schopný simulovať rôzne typy chýb, ako sú záměny báz, vloženia alebo vynechania báz, ktoré sa môžu vyskytnúť počas procesu sekvenovania.

Táto simulácia bude slúžiť na testovanie a vyhodnocovanie algoritmov pre spracovanie sekvenačných dát, ktoré musia byť robustné voči týmto chybám. Cieľom je zlepšiť presnosť a spoľahlivosť analýzy genetických informácií získaných pomocou nanopórového sekvenovania.

3.1.1 Vstup

Cieľ výstupu analýzy DNA získaných pomocou nanopórového sekvenovania je určiť vzťah medzi pôvodným DNA reťazcom a jeho pozorovanými čítaniami, ktoré vznikajú počas sekvenovania. Namiesto priameho priradovania konkrétneho referenčného reťazca k jednotlivým čítaniam je zvolený opačný postup: z dostupných nanopórových čítaní sa odhaduje najpravdepodobnejšia pôvodná sekvencia. Tento odhad je založený na identifikácii dostatočne veľkej množiny podobných sekvencií, pri ktorých možno predpokladať spoločný pôvod. Následne sa pre takúto skupinu vypočíta konsenzuálna sekvencia, ktorá by mala byť čo najbližšia pôvodnému DNA reťazcu.

Keďže DNA reťazce sú dlhé a jednotlivé čítania obsahujú chyby, sekvencie sa môžu navzájom líšiť a byť vzájomne posunuté. Z tohto dôvodu je potrebné vykonať viacnásobné zarovnanie sekvencií (multiple sequence alignment), aby sa konsenzus určoval z nukleotidov nachádzajúcich sa v rovnakých pozíciách.

Takto definovaný výstup umožňuje vytvoriť mapu katic (k-merov) na ich výstupný signál, čo nám umožní analyzovať pravdepodobnosti rôznych typov chýb pre každú bázu v reálnom reťazci. Táto mapa je kľúčová pre simuláciu chýb pri generovaní nových DNA sekvencií. A však da sa predpokladať, že jedna skupina podobných sekvencií nebude obsahovať dostatočné množstvo variácií Dna nukleotidov, kompletných katic, aby sme mohli spoľahlivo odhadnúť pravdepodobnosti chýb pre všetky možné k-mery. keďže 4^k je veľmi veľké číslo ktoré sa zväčšuje exponencialne a pri $k = 4$ je to 256. sanca ze 256 unikatnych 4-merov bude v jednej sekvencii je veľmi mála. preto je potrebné zoskupiť viacero sekvecnich skupín.

Požadovaný výstup preto pozostáva z viacerých skupín navzájom zarovnaných DNA sekvencií a zodpovedajúcich konsenzuálnych sekvencií pre každú skupinu. Takto definovaný výstup umožňuje dosiahnuť dostatočné pokrytie variácií čítaní odvodených z toho istého DNA reťazca.

4 Opis dát

4.1 V akom stave sú dáta k dispozícii

Data boli stiahnuté z verejného repozitára, ktorý obsahoval surové sekvenačné dáta vo formáte pod5. Tieto dáta predstavovali čítania DNA reťazcov získané pomocou nanopórového sekvenovania. Data boli stiahnuté pomocou nástroja aws s použitím príkazu aws s3 cp, ktorý umožňuje kopírovať súbory z Amazon S3 úložiska do lokálneho prostredia.

```
aws s3 sync --no-sign-request s3://ont-open-data/gm24385_2020.09 /  
media/marek/EAGET/gm24385_2020.09
```

Dáta sa stiahli do adresára /media/marek/EAGET/gm24385_2020.09, a sťahovanie trvalo približne 2 hodiny, pričom celková veľkosť stiahnutých dát bola okolo x GB.

Data obsahovali čítania DNA reťazcov, ktoré vznikajú počas procesu nanopórového sekvenovania. Tieto čítania sú často dlhé a obsahujú chyby, čo predstavuje výzvu pri ich analýze. Aby bolo možné tieto dáta efektívne analyzovať, bolo potrebné ich prekonvertovať pomocou basecallera Dorado do formátu BAM, ktorý je štandardným formátom pre ukladanie sekvenačných dát a umožňuje efektívne spracovanie a analýzu. Po konverzii do formátu BAM bolo potrebné dáta zoskupiť a zarovnať, aby sa identifikovali podobné sekvencie a vytvorili konsenzuálne sekvencie, ktoré by mohli reprezentovať pôvodný DNA reťazec.

4.2 Aké sú s tým problémy

Dáta spracované do formátu BAM obsahujú viacero sekvencií DNA, ktoré sa navzájom líšia dĺžkou aj obsahom. Každý riadok reprezentuje jedno čítanie z nanopórovej sekvenácie. Dĺžka DNA čítaní sa pohybuje približne od 100 nukleotidov až po 1 000 000 nukleotidov.

Jedným z možných dôvodov výskytu veľmi dlhých čítaní je, že zariadenie môže postupne načítať viac DNA sekvencií za sebou, pričom nástroj Dorado ich neoddelí a spracuje ich ako jednu sekvenciu. Zároveň možno predpokladať, že v rámci jedného čítania sa tá istá sekvencia môže vyskytovať opakovane. Môže to súvisieť s biosyntézou DNA, pri ktorej dochádza k replikácii a vzniku viacerých kópií tej istej sekvencie.

Tá istá sekvencia môže byť načítaná viackrát, avšak s odlišnými chybami, keďže nanopórové sekvenovanie je chybovejšie. Okrem toho sa sekvencia môže čítať v opačnej orientácii, pretože molekula vstupuje do nanopóru z rôznych koncov. Sekvenciu preto možno získať v smere $3' \rightarrow 5'$ alebo $5' \rightarrow 3'$.

V dôsledku biosyntézy vzniká aj komplementárna sekvencia DNA, v ktorej sú bázy nahradené podľa pravidiel párovania ($A \rightarrow T$, $T \rightarrow A$, $G \rightarrow C$, $C \rightarrow G$). Aj komplementárna sekvencia môže byť čítaná v oboch smeroch. Pre každú pôvodnú sekvenciu sa teda môžu vyskytnúť až štyri varianty: pôvodná sekvencia v smere $3' \rightarrow 5'$ a $5' \rightarrow 3'$, a jej komplement v smere $3' \rightarrow 5'$ a $5' \rightarrow 3'$.

Ďalším javom je fragmentácia DNA, pri ktorej vznikajú kratšie sekvencie zodpovedajúce iba časti pôvodnej sekvencie. Ich dĺžky sa líšia podľa miesta pretrhnutia. Zároveň sa môže stať, že niektoré sekvencie sa replikujú častejšie ako iné.

Napriek uvedeným komplikáciám som predpokladal, že v dlhých čítaniach bude možné identifikovať dostatočne dlhé opakujúce sa úseky, ktoré reprezentujú tú istú pôvodnú DNA sekvenciu. Na základe tohto predpokladu som identifikoval klaster obsahujúci viac ako 37 000 sekvencií DNA. Spočiatku sa zdalo, že ide o opakované čítanie jednej sekvencie, čo by mohlo viesť k získaniu kvalitného konsenzu. Podrobnejšia analýza však ukázala, že spoločná zhoda medzi sekvenciami bola obmedzená iba na úvodný úsek s dĺžkou 43 nukleotidov.

Keďže 43 nukleotidov predstavuje príliš krátky úsek na spoľahlivú reprezentáciu celého DNA reťazca no zároveň je príliš dlhý na náhodne sa vyskytujúci úsek, vznikla, pôvodná hypotéza o prítomnosti dostatočne dlhého spoločného jadra nebola potvrdená. Na základe tohto zistenia bola formulovaná nová hypotéza: spoločný úvodný úsek pravdepodobne zodpovedá DNA primeru prítomnému na začiatku sekvenovaných fragmentov.

Nasledujúcim krokom preto bolo lokálne hľadanie primeru v jednotlivých čítaniach. Primer sa nevyhľadával iba na začiatku reťazca, ale v celom rozsahu každého čítania, aby sa zachytili aj prípady jeho posunu alebo výskytu vo vnútri sekvencie.

Pomocou 47 nukleidov dlhy úvodný úsek som prehlasil ako primer a rozhodol som sa ho vyhľadať v každom čítaní, nielen na začiatku sekvencie, ale aj v jej ďalších častiach, aby som zachytil aj prípady jeho posunu alebo výskytu vo vnútri sekvencie.

subor obsahujuci citania z dorada v formate fasta som načítal do pamäti a následne som použil algoritmus z bioAlignments knižnice Biopython, ktorý umožňuje vyhľadávať lokálne zarovnania medzi primerom a jednotlivými čítaniami.

`aligner.align(primer, read)` vracia všetky lokálne zarovnania medzi primerom a daným čítaním zoradené podľa skóre zarovnania. kazdy alignment obsahuje informácie o pozícii zarovnania v celkovom reťazci a lokalne zarovnanom reťazci, ktorý zodpovedá v nasom prípade primeru. je zapísaný v 3 dimenzionálnom formáte, 2 N 2, kde 1 riadok obsahuje lokalne zarovnaný reťazec, 2 riadok obsahuje celkový reťazec. potom kazde pole obsahuje zarvnaie odkiaľ pokiaľ je časť zarovnaná a je to rozdelené na N fragmentov, kde N je počet zarovnaných úsekov ten sa zhoduje s počtom fragmentov v lokalne zarovnanom reťazci.

Nato aby sme zistili odkiaľ pokiaľ sa lokalne zarovnaný reťazec zhoduje s primerom tak data najdeme tu `aligned[1][0][0]` a `aligned[1][-1][1]` /inputchapters/CodeSnippets/snippets/python-find-occurrences.tex

primery uloží do formátu `[], [65], [55], [], [64], [], [55], [74, 73], [64], [75], [72, 70], [], [], [75], [39], [75], [], [], [72]`.. kde každý element zodpovedá jednému čítaniu a obsahuje pozície, kde sa primer nachádza v danom čítaní. Ako je vidno nie v každom reťazci sa primer nachádza, ale v niektorých sa nachádza viac krát. je to zdvodu buď ostatné citania obsahovali komplementárnu sekvenciu alebo sa precítali v opačnom smere, alebo sa primer nenachádza zdvodu pretrhnutia dna reťazca v rôznych miestach alebo sa nachádza ale je príliš odlišný ze sa dostal pod mojím nastaveným thresholdom pre zarovnanie teda ho ignorujem.

Výpis 1: Stripping primers from Clover input

```
with open(clover_input_path, "r") as f:
    lines = f.readlines()

with open(PrimersPath, "r") as f:
    datas = f.read()

primers = ast.literal_eval(datas)

newLines = []
for (line, linePrimes) in zip(lines, primers):
    prevValue = -1
    for prime in linePrimes:
        if (prevValue != -1 ):
            if prevValue - prime < 50:
                continue
```

```

        newline = line[prime:prevValue]
        if(len(newline)<50):
            continue
        newLines.append(newline)
        prevValue = prime

WriteLines=[]
for (i,line) in enumerate(newLines):
    WriteLines.append(f"{i} {line}\n")

with open("PrimersStripClover.txt", "w") as f:
    f.writelines(WriteLines)

```

Tak som zobral useky za primerom a zapisal ich do noveho suboru, ktory obsahuje citania od primeru az po koniec retazca. Alebo do dalsieho primeru ak sa nachadzal viac krat. Tieto data som následne znovu zoskupil pomocou algoritmu Clover, ale tentokrát som použil iba zvyšné časti sekvencií bez DNA primerov. Co spôsobilo ze tentokrát klastre obsahovali sekvencie, ktoré mali zhodu nielen na začiatku, ale aj ďalej v reťazci, co indikovalo ze sa sekvencie pochadzaju z nasledkom polymerizacie z toho isteho dna retazca v spravnom smere a nie z toho isteho dna retazca v opacnom smere alebo z komplementarneho retazca.

Na Klastre som aplikoval viacnásobné zarovnanie.

Výpis 2: Clustering without primers

```

ClusterFile = TextFileM(path="clusters_output.txt")
ClusterFile = ClusterFile.load()
ClusterFile = parse_tuple_file(ClusterFile)
ClusterFile = get_clusters(ClusterFile)
clusters = ClusterFile.data

#ClusterFile = pick_largest_cluster(ClusterFile)
#LargestCluster = []
#LargestCluster = ClusterFile.data

clusters = [l for l in clusters if len(l) > 10]
count=1
for clust in clusters:
    ClusterFile.data=clust
    ClusterFile = retrieve_dna_lines(ClusterFile, clover_input_path
    )
    DataToBeAligned = ClusterFile.data

    ClusterSize = len(DataToBeAligned)

```

```

(Aligned, Unaligned) = DataBeamAlgorithmSplit(DataToBeAligned,
10)
dist = len(Aligned[0].replace("_", ""))
if len(Aligned[0].replace("_", "")) < 10:
    continue

Aligned.insert(0, str(clust))

TextFileM(data=Aligned).write_data_to_file(f"GeneratedData/
    Aligned_dnaSize-{dist}num-{ClusterSize}id-{count}.txt")
count+=1

```

Ukázalo sa, že klastre obsahovali sekvencie, ktoré mali zhodu nielen na začiatku, ale aj ďalej v reťazci. Niektoré klastre obsahovali sekvencie, ktoré sa zhodovali až do dĺžky 100 nukleotidov, čo je výrazne ďalší úsek než pôvodný primer.

4.3 Aký je očakávaný výstup dát a v akej forme majú byť dáta po spracovaní

Cieľ výstupu analýzy DNA získaných pomocou nanopórového sekvenovania je určiť vzťah medzi pôvodným DNA reťazcom a jeho pozorovanými čítaniami, ktoré vznikajú počas sekvenovania. Namiesto priameho priradovania konkrétneho referenčného reťazca k jednotlivým čítaniam je zvolený opačný postup: z dostupných nanopórových čítaní sa odhaduje najpravdepodobnejšia pôvodná sekvencia. Tento odhad je založený na identifikácii dostatočne veľkej množiny podobných sekvencií, pri ktorých možno predpokladať spoločný pôvod. Následne sa pre takúto skupinu vypočíta konsenzuálna sekvencia, ktorá by mala byť čo najbližšia pôvodnému DNA reťazcu.

Keďže DNA reťazce sú dlhé a jednotlivé čítania obsahujú chyby, sekvencie sa môžu navzájom líšiť a byť vzájomne posunuté. Z tohto dôvodu je potrebné vykonať viacnásobné zarovnanie sekvencií (multiple sequence alignment), aby sa konsenzus určoval z nukleotidov nachádzajúcich sa v rovnakých pozíciách.

Takto definovaný výstup umožňuje vytvoriť mapu katic (k-merov) na ich výstupný signál, čo nám umožní analyzovať pravdepodobnosti rôznych typov chýb pre každú bázu v reálnom reťazci. Táto mapa je kľúčová pre simuláciu chýb pri generovaní nových DNA sekvencií. A však da sa predpokladať, že jedna skupina podobných sekvencií nebude obsahovať dostatočné množstvo variácií Dna nukleotidov, kompletných katic, aby sme mohli spoľahlivo odhadnúť pravdepodobnosti chýb pre všetky možné k-mery. keďže 4^k je veľmi veľké číslo ktoré sa zväčšuje exponencialne a pri $k = 4$ je to 256. sanca ze 256 unikatnych 4-merov bude v jednej sekvencii je veľmi mála. preto je potrebné zoskupiť viacero sekvencnich skupín.

Požadovaný výstup preto pozostáva z viacerých skupín navzájom zarovnaných DNA sekvencií a zodpovedajúcich konsenzuálnych sekvencií pre každú skupinu. Takto definovaný výstup umožňuje dosiahnuť dostatočné pokrytie variácií čítaní odvodených z toho istého DNA reťazca.

5 Čo bolo potrebné, aby sa riešenie dalo prakticky realizovať

6 Nanopore

Nanopore sekvenovanie je technológia používaná na sekvenovanie DNA a RNA molekúl [1]. Táto metóda umožňuje čítanie genetického materiálu tým, že molekuly prechádzajú cez nanometrové póry (nanopóry), čo vedie k zmene elektrického prúdu, ktorý je následne analyzovaný na určenie sekvencie nukleotidov [1]. Je to revolučná technológia v oblasti genomiky, ktorá umožňuje rýchle a presné sekvenovanie s minimálnymi nákladmi a zariadeniami prenosných veľkostí [1]. Aplikácie nanopórového sekvenovania zahŕňajú diagnostiku chorôb, výskum genetických porúch a monitorovanie environmentálnych vzoriek [1].

Nanopórové sekvenovanie je obzvlášť užitočné pre jeho schopnosť čítať dlhé sekvencie DNA, čo zjednodušuje zostavovanie genómov a identifikáciu štruktúrnych variácií [1, 2]. Funguje na princípe detekcie zmien v elektrickom prúde, keď molekula prechádza cez nanopór, čo umožňuje priame čítanie sekvencií bez potreby amplifikácie alebo značenia [1]. DNA alebo RNA molekuly sú vedené cez nanopór pomocou elektrického poľa, pričom každá báza spôsobuje charakteristickú zmenu prúdu, ktorá je zaznamenaná a analyzovaná softvérom na určenie sekvencie [1].

6.1 Prekladanie DNA/Mra do signálu

Prekladanie DNA alebo RNA sekvencií do elektrického signálu v nanopórovom sekvenovaní [1] zahŕňa niekoľko kľúčových krokov:

- **Príprava vzorky:** DNA alebo RNA molekuly sú pripravené na sekvenovanie, často zahŕňajúce fragmentáciu a pridanie adaptérnych sekvencií.
- **Vedenie cez nanopór:** Molekuly sú vedené cez nanopór pomocou elektrického poľa, ktoré spôsobuje ich pohyb [1].
- **Detekcia prúdu:** Keď molekula prechádza cez nanopór, každá báza spôsobuje charakteristickú zmenu v elektrickom prúde, ktorý je zaznamenaný ako časová séria dát [1].
- **Analýza signálu:** Zaznamenaný elektrický signál je analyzovaný pomocou algoritmov na identifikáciu sekvencie nukleotidov na základe zmien prúdu [1].
- **Preklad do sekvencie:** Softvér prekladá analyzovaný signál späť do sekvencie DNA alebo RNA, čo umožňuje výskumníkom získať genetické informácie z pôvodnej molekuly [1].

Výstupom z procesu nanopórového sekvenovania je sekvencia nukleotidov (A, T, C, G pre DNA alebo A, U, C, G pre RNA) reprezentujúca genetickú informáciu pôvodnej molekuly [1]. Tento výstup je často vo forme textového súboru (napríklad FASTQ formát), ktorý obsahuje sekvencie spolu s kvalitatívnymi skóre pre každú bázu [1]. Vzhľadom na

technické obmedzenia a variabilitu v procese sekvenovania je bežné, že jednotlivé DNA alebo RNA retiazce sú prečítané niekoľkokrát (tzv. "coverage" alebo "depth of coverage") [1]. Toto opakované čítanie zvyšuje spoľahlivosť a presnosť výslednej sekvencie, pretože umožňuje korekciu chýb a identifikáciu variácií v genetickom materiáli [1, 2]. No napriek tomu, že sa retiazce čítajú viackrát, stále môže dôjsť k nepresnostiam v sekvencii kvôli šumu v signáli [1].

Retiazce DNA alebo RNA môžu byť čítané rôznou rýchlosťou počas nanopórového sekvenovania, čo môže ovplyvniť kvalitu a presnosť zaznamenaného signálu [1]. Rýchlosť prechodu molekuly cez nanopór je ovplyvnená viacerými faktormi, vrátane veľkosti molekuly, jej konformácie, interakcií s nanopórom a podmienok prostredia (napríklad teplota a iónová sila) [1].

Keďže DNA a RNA molekuly sú veľmi malé, signál zaznamenaný počas nanopórového sekvenovania odráža interakcie jednotlivých nukleotidov (báz) s nanopórom [1]. Každá báza má jedinečný tvar a elektrické vlastnosti, ktoré ovplyvňujú spôsob, akým mení elektrický prúd pri prechode cez nanopór [1]. Preto je možné získať signál pre každú jednotlivú bázu v molekule, čo umožňuje presné čítanie sekvencie [1].

7 Dorado Basecaller

Dorado je pokročilý basecaller vyvinutý spoločnosťou Oxford Nanopore Technologies (ONT) na prekladanie surového elektrického signálu získaného z nanopórového sekvenovania na sekvenciu nukleotidov (A, T, C, G pre DNA alebo A, U, C, G pre RNA). Je navrhnutý tak, aby poskytoval vysokú presnosť a rýchlosť pri spracovaní sekvenačných dát, čo je kľúčové pre rôzne aplikácie v oblasti genomiky a bioinformatiky.

7.1 Názov podkapitoly

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Integer eu lacus leo. Nulla egestas purus non dignissim tincidunt.

7.2 Cluster clover

Klastrovací algoritmus je metóda, ktorá rozdeľuje množinu dát do skupín (klastrov) tak, aby dáta v rámci jednej skupiny boli si navzájom podobné a dáta z rôznych skupín boli odlišné [3]. Tieto algoritmy sa často používajú v bioinformatike na analýzu sekvencií DNA alebo iných biologických dát.

Clover algoritmus je efektívny klastrovač navrhnutý špeciálne pre DNA sekvencie v oblasti DNA-based data storage. Využíva stromovú štruktúru na rýchle a presné zoskupovanie sekvencií podľa ich podobnosti, čím zvyšuje efektivitu a škálovateľnosť procesu [3]. Clover umožňuje efektívne spracovanie veľkých množín sekvencií a je vhodný pre moderné aplikácie v oblasti ukladania dát do DNA.

Clover algoritmus Kladruje sekvencie DNA na zaklade ako začínajú a to tak ze ich usporiada do stromovej struktury podobnemu trie.

clover berie data vo forme kde kazdy riadok bude obsahovat id a dna sekvenciu.

Nato aby som mohol spustiť Klastrovaci nástroj, musel som prekonvertovať data z bam do txt formátu.

Výpis 3: Bam to Txt Conversion

```
def ConvertBamToTxt(bam, out):  
    for i, read in enumerate(bam):  
        seq = read.query_sequence # the DNA sequence  
        out.write(f"{i} {seq}\n")
```

Nasledne som spustil Klastrovaci nástroj s takymto nastavenim:

Výpis 4: Running Clustering Tool

```
python -m clover.main -I output.txt -O example.txt -L 150 -P 2  
--no-tag
```

Pri spustení som použil vstupný súbor `output.txt` (-I) a výstupný súbor `example.txt` (-O). Parametre majú nasledujúci význam:

- -I [input_file]: vstupný súbor. Aktuálne sú podporované formáty txt, fasta a fastq. Každý riadok má tvar [index], [read].
- -O [output_file_name]: názov výstupného súboru. Výstupný súbor bude uložený v priečinku Clover.
- -L [int]: dĺžka čítania (length of read).
- -P [int]: voľba režimu spracovania. P=0 znamená jednovláknové/jeden proces; P=1 a P=2 znamenajú 4, resp. 16 procesov.
- -no-tag: tento prepínač je potrebné pridať, ak je vstupný súbor v „untagged“ formáte.

clover mi vrátil subor ktorý mal štruktúru polia ktorý obsahoval dvojice celých čísel, kde prvé číslo reprezentovalo ID sekvencie a druhé číslo reprezentovalo ID Prvej Sekvencie, ku ktorej bola sekvencia zaradená.

Výpis 5: Clustering Data

```
tuples = m.data  
data_sorted = sorted(tuples, key=lambda x: x[1])  
groups = []  
  
for k, g in itertools.groupby(data_sorted, key=lambda x: x[1]):  
    groups.append([k] + [a[0] for a in g])  
return groups
```

Uvedený skript načíta výstup z nástroja Clover a prevedie ho do dátovej štruktúry vhodnej na ďalšie spracovanie. Konkrétne spracuje dvojice identifikátorov tak, aby bolo možné jednoducho zistiť, do ktorého klastra jednotlivé sekvencie patria.

Potom som si vybral najvacsie klaster a pouzil ho na analyzu

Výpis 6: Picking the largest cluster

```
def pick_largest_cluster(m: TextFileM):  
    cluster = max(m.data, key=len)
```

Tento skript prejde všetky vytvorené klastre, spočíta ich veľkosti a vyberie najväčší klaster. Vybraný klaster som následne použil ako reprezentatívnu množinu sekvencií pre ďalšie kroky analýzy.

Následne som použil tento klaster na získanie dna sekvencií ktore som vybral pre ďalší program.

Výpis 7: Retrieving DNA sequences from a cluster

```
def retrieve_dna_lines(cluster_m: TextFileM, path):  
    cluster = cluster_m.data  
    result = []  
    with open(path, "r") as f:  
        lines = f.readlines()  
  
    for idx in cluster:  
        if idx < len(lines):  
            parts = lines[idx].split(" ", 1)  
            if idx != int(parts[0]):  
                print("IndexError")  
            if len(parts) > 1:  
                result.append(parts[1].strip())  
    return result
```

Posledný skript podľa ID sekvencií z vybraného klastra dohľadá zodpovedajúce DNA sekvencie a uloží ich vo formáte vhodnom pre nasledujúci nástroj. Tým sa uzatvára príprava dát po klastrovaní.

7.3 Viacnásobné zarovnanie sekvencií

Viacnásobné zarovnanie sekvencií (Multiple Sequence Alignment, MSA) je proces usporiadania troch alebo viacerých biologických sekvencií (DNA, RNA alebo proteínov) tak, aby boli identifikované podobné regióny medzi nimi. Tieto podobnosti môžu odhaliť štrukturálne, funkčné alebo evolučné vzťahy medzi sekvenciami.

7.3.1 Základný princíp

Pri viacnásobnom zarovnaní sekvencií hľadáme také usporiadanie, ktoré maximalizuje podobnosť medzi všetkými sekvenciami súčasne. Do sekvencií sú vkladane medzery (gap characters, značené pomlčkou '-'), aby sa zodpovedajúce pozície dostali do rovnakých stĺpcov.

subsubsection Príklad zarovnania

Majme tri jednoduché sekvencie:

- Sekvencia 1: ACGT
- Sekvencia 2: AGT
- Sekvencia 3: ACCT

Ich zarovnanie môže vyzerať nasledovne:

Seq1: A C G T
Seq2: A - G T
Seq3: A C C T

7.3.2 Význam a využitie

Viacnásobné zarovnanie má niekoľko dôležitých aplikácií:

- **Fylogenéza** – konštrukcia evolučných stromov
- **Identifikácia konzervovaných motívov** – nálezenie funkčne dôležitých oblastí
- **Predikcia štruktúry** – odvodenie sekundárnej a terciárnej štruktúry proteínov
- **Homológia** – určenie príbuznosti medzi sekvenciami

7.3.3 Zložitosť problému

Viacnásobné zarovnanie je výpočtovo náročný problém. Presné riešenie pomocou dynamického programovania má časovú zložitosť $O(L^n)$, kde L je dĺžka sekvencií a n je ich počet. Preto sa v praxi používajú heuristické algoritmy.

7.3.4 Skórovacia funkcia

Kvalita zarovnania sa hodnotí pomocou skórovacej funkcie, ktorá typicky obsahuje:

- **Match score** – bodovanie zhody medzi znakmi
- **Mismatch penalty** – penalizácia za nezhodu
- **Gap penalty** – penalizácia za medzery (môže byť lineárna alebo afinná)

7.3.5 Bežné algoritmy

Medzi najpoužívanejšie algoritmy pre MSA patria:

- **ClustalW/ClustalOmega** – progresívne zarovnanie pomocou sprievodného stromu
- **MUSCLE** – rýchly progresívny algoritmus s iteratívnym spresňovaním
- **T-Coffee** – kombinuje párové zarovnania do finálneho MSA
- **MAFFT** – využíva FFT pre rýchle nájdenie homológnych oblastí

8 Vytvorenie práce

V tejto časti popisujem konkrétne kroky, ktoré som vykonal počas riešenia práce, vrátane spracovania dát, aplikácie algoritmov a vyhodnotenia výsledkov.

9 Bio Informatics Analysis of Nanopore Sequencing Data Using Dorado Basecaller and Clover Clustering Algorithm

Najprv som stiahol potrebný dataset z verejného repozitára Potom som nan zavolať Dorado basecaller, ktorý som použil na prekladanie surových pod5 súborov do formátu BAM. To som spravil pomocou nasledujúceho príkazu v termináli:

```
dorado basecaller --input-format pod5 --output-format bam --input /cesta/k/data
```

tam som si musel stiahnuť a nainštalovať Dorado, potom na základe pod5 datasetu som stiahol dorado triedu, ktorá je určená na spracovanie daného datasetu. Na základe toho cez aký Nanopore bol dataset získaný. po spracovaní Dorado basecallera som získal BAM súbor, ktorý obsahoval preložené sekvencie po 1000000 sekvencií dĺžky 1000000 To trvalo približne X hodín, v závislosti od veľkosti datasetu a výpočtovej kapacity použitého hardvéru. Následne som použil algoritmus Clover, ktorý zoskupil sekvencie do jednotlivých klastrov na základe ich podobnosti. Problem je že Clover neberie ako vstup BAM súbory, ale potrebuje textový formát FASTA alebo FASTQ, takže som musel najprv previesť BAM súbory do text formátu pomocou nástroja samtools. Po prevedení som spustil Clover, ktorý zoskupil sekvencie do jednotlivých klastrov na základe ich podobnosti. Nástroj Clover my vrátil subor ktorý mal štruktúru polia ktorý obsahoval dvojice celých čísel, kde prvé číslo reprezentovalo ID sekvencie a druhé číslo reprezentovalo ID Sekvencie Prvej Sekvencie, do ktorého bola sekvencia zaradená. Zo všetkých vytvorených klastrov som vybral tie, ktoré boli dostatočne veľké na ďalšiu analýzu. Ale Ukazalo sa že dna v klastroch neboli zhodne ďalej ako pár nukleotidov, čo znamenalo že som mal dna vôbec neboli klastrované správne. Neskôr som zistil že clover zarovnáva iba podľa začiatku retazca a neberie do úvahy zhodu ďalej v retazci, čo znamenalo že som mal v jednom klustri sekvencie ktoré mali zhodu iba na začiatku a ďalej sa rozchádzali. Jedným klaster obsahoval viac ako 37000 sekvencií, čo bolo neobvykle veľké množstvo sekvencií v jednom klustri ktoré mali cez dĺžku ako 43 nukleotidov zhodne, čo bolo nepravdepodobné, že by sa stalo náhodou. Vznikla teória že som narazil na dna Primer Potom čo som vytvoril konzesus prvých 43 nukleotidov. Na základe tejto informácie som naprogramoval vlastný skript v jazyku Python, ktorý používal knižnicu Biopython, A rozbehol som ho na všetky vetvy a použil som ho na oddelenie dna primerov od zvyšku sekvencií. Potom som dane sekvencie znovu zoskupil pomocou Clover, ale tentokrát som použil iba zvyšné časti sekvencií bez dna primerov. Data odcistené od dna primerov sa znovu zoskupili do klastrov, ktoré teraz obsahovali sekvencie, ktoré mali zhodu nielen na začiatku, ale aj ďalej v retazci.

9.1 Hľadanie DNA reťazcov

Hľadanie DNA reťazcov v nanopórových dátach je komplexný proces, ktorý zahŕňa niekoľko krokov. Najprv sa surové dáta získané z nanopórového sekvenovania prekladajú pomocou basecallera Dorado do formátu BAM, ktorý umožňuje ďalšie spracovanie. Následne sa použije klastrovací algoritmus Clover na zoskupenie sekvencií do klastrov na základe ich podobnosti na začiatku reťazca. Zo všetkých vytvorených klastrov sa vyberieme ten najväčší, na ňom zavolám moj naivny multialignment algoritmus, ktorý vytvorí konsenzuálnu sekvenciu pre tento cluster. Tento konsenzus slúži ako náš "primer", ktorý sa bude používať na vyhľadávanie v jednotlivých readoch. Pre každý read sa potom vyhľadá lokálne zarovnanie s primerom a vyberie sa sekvencia, ktorá nasleduje za primerom. Tieto sekvencie sa následne zoskupia pomocou Cloveru, čím vzniknú nové klastre. Na každý z týchto klastrov sa opäť aplikuje multialignment, a zarovnané sekvencie sa použijú na vytvorenie konsenzuálnej sekvencie pre každý cluster. tak získame dlhé reťazce a z nich môžeme filtrovať tie ktoré sú dostatočne dlhé a dostatočne zoskupené.


10 Kritické zhodnotenie a zhrnutie

V práci som predstavil možnosti a výzvy spojené s ukladaním dát do DNA a spracovaním sekvenančných dát z nanopórového sekvenovania. Navrhnuté a implementované metódy prispievajú k efektívnejšiemu spracovaniu a analýze týchto dát. Cieľ bakalárskej práce bol splnený.

Cieľom tejto bakalárskej práce bolo spracovanie dát získaných z Nanopore sekvenovania DNA za účelom modelovania narušenia informácie uchováanej v DNA pamäti.

V rámci práce bol implementovaný celý pipeline spracovania dát — od stiahnutia surových signálov zo sekvenovacieho zariadenia, cez basecalling pomocou nástroja **Dorado**, až po zarovnanie a klastrovanie sekvencií pomocou algoritmu **Clover**. Na základe zarovnaných reťazcov bol navrhnutý a implementovaný vlastný multi-alignment algoritmus inšpirovaný beam search prístupom, ktorý umožňuje určenie konsenzu pre skupiny DNA sekvencií.

Graf „Dĺžka reťazca vs počet DNA reťazcov“ prezentuje rozloženie dĺžok zarovnaných DNA reťazcov a ich zastúpenie v spracovaných dátach.



Obr. 1: Dĺžka reťazca vs počet DNA reťazcov

Pri vyhodnotení výsledkov boli použité nasledovné kritériá:

- dĺžka reťazca nad 100 báзовých párov považovaná za dostatočnú,
- počet DNA reťazcov nad 10 ako prijateľný základ pre výpočet konsenzu,
- počet DNA reťazcov nad 50 ako veľmi silné zastúpenie zaručujúce spoľahlivý konsenzus.

Analýza ukázala, že v spracovaných dátach sa nachádzajú dostatočne dlhé reťazce s dostatočným zastúpením, čo umožňuje spoľahlivý výpočet konsenzu a následné modelovanie chybovosti Nanopore čítania. Získané výsledky tvoria základ pre ďalší výskum v oblasti DNA pamätí, konkrétne pre charakterizáciu chybových modelov pri Nanopore sekvenovaní.

Použitá literatura

1. ZHENG, Peijie; ZHOU, Chuntao; DING, Yuemin; LIU, Bin. Nanopore sequencing technology and its applications. *MedComm*. 2023, roč. 4, č. 4. Dostupné z doi: 10.1002/mco2.316. Published July 2023.
2. LOPEZ, Randolph; CHEN, Yuan-Jyue; ANG, Siena Dumas; YEKHANIN, Sergey; MAKARYCHEV, Konstantin; RACZ, Miklos Z; SEELIG, Georg; STRAUSS, Karin; CEZE, Luis. DNA assembly for nanopore data storage readout. *Nature Communications*. 2019, roč. 10, č. 1, s. 1–9. Dostupné z doi: 10.1038/s41467-019-10978-4.
3. QU, Guanjin; YAN, Zihui; WU, Huaming. Clover: tree structure-based efficient DNA clustering for DNA-based data storage. *Briefings in Bioinformatics*. 2022, roč. 23, č. 5, s. 1–16. Dostupné z doi: 10.1093/bib/bbac336. Corresponding author: Huaming Wu, Center for Applied Mathematics, Tianjin University, Tianjin, 300072, China. E-mail: whming@tju.edu.cn.