

**PANEURÓPSKA VYSOKÁ ŠKOLA
FAKULTA INFORMATIKY**

FI-123456-12345

Pomocne Algorithmy na tvorbu Dna Kanalov pre Sekvencovanie

Bakalárska práca

2026

Patrik Homola

**PANEURÓPSKA VYSOKÁ ŠKOLA
FAKULTA INFORMATIKY**

Pomocne Algorithmy na tvorbu Dna Kanalov pre Sekvencovanie

Bakalárska práca

Patrik Homola

Študijný program: Aplikovaná informatika

Študijný odbor: Informatika

Školiace pracovisko: Ústav aplikovanej informatiky

Školiteľ: doc. RNDr. Peter Farkas, PhD.

Konzultant: Mgr. Peter Jarnvars

Bratislava 2026



PANEURÓPSKA VYSOKÁ ŠKOLA

Fakulta informatiky

ZADANIE PRÁCE

Meno a priezvisko študenta:

Evidenčné číslo práce:

Študijný odbor:

Študijný program:

Forma a metóda štúdia:

Vedúci práce:

Ústav/katedra:

Dátum zadania práce:

Názov:

Anotácia: Cieľom práce je vytvorenie komplexného systému pre navigáciu v interiéroch s napojením na rozličné webové zdroje s možnosťou ich editovania a návrh shaderov pre ich zobrazenie. Súčasťou práce bude analýza použitia v reálnom nasadení vrátane implementácie a zobrazovania na rozličných dotykových zariadeniach.

.....
RNDr. Ján Lacko, PhD.
vedúci práce

.....
Ing. Juraj Štefanovič, PhD.
vedúci ústavu

Podakovanie:

Pri vypracovaní tejto práce by som sa rád poďakoval za odbornú pomoc pánovi doc. RNDr. Peter Farkas, PhD., ktorý mi poskytol mnoho cenných rád a konzultácií.

Podakovanie môžete napísať podľa seba.

Čestné prehlásenie:

Čestne vyhlasujem, že záverečnú prácu som vypracoval samostatne a že som uviedol všetku použitú literatúru.

.....

Patrik Homola

Abstrakt

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Integer eu lacus leo. Nulla egestas purus non dignissim tincidunt. In sit amet tellus bibendum, lobortis magna ut, sodales mi. Etiam vel eros efficitur purus ultrices vulputate et quis justo. Nunc ultrices tellus a dui mattis, eget laoreet arcu tempor. Donec vestibulum, magna ac fringilla lacinia, libero risus fringilla arcu, nec consectetur nibh justo vel sem. Quisque gravida sit amet elit ut aliquam.

Abstrakt obsahuje informáciu o cieľoch práce, jej stručnom obsahu a v závere abstraktu sa charakterizuje splnenie cieľa, výsledky a význam celej práce. Súčasťou abstraktu je 3 - 5 kľúčových slov.

Kľúčové slová: Kľúčové slovo 1, Kľúčové slovo 2, Kľúčové slovo 3

Abstract

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Integer eu lacus leo. Nulla egestas purus non dignissim tincidunt. In sit amet tellus bibendum, lobortis magna ut, sodales mi. Etiam vel eros efficitur purus ultrices vulputate et quis justo. Nunc ultrices tellus a dui mattis, eget laoreet arcu tempor. Donec vestibulum, magna ac fringilla lacinia, libero risus fringilla arcu, nec consectetur nibh justo vel sem. Quisque gravida sit amet elit ut aliquam.

Abstrakty v anglickom a slovenskom jazyku sa musia zhodovať.

Keywords: Keyword 1, Keyword 2, Keyword 3

Obsah

Obsah	6
Zoznam obrázkov	8
Zoznam skratiek a značiek	9
1 Úvod	10
2 Motivácia	11
3 Ciele a zadanie práce	13
3.1 Uloha	14
4 Návrh riešenia	15
5 Technologické pozadie	17
6 Nanopore	18
6.1 Prekladanie DNa/Mra do signálu	18
7 Dorado Basecaller	20
7.1 Názov podkapitoly	20
8 Metódy spracovania sekvencií	21
8.1 Cluster clover	22
8.2 Viacnásobné zarovnanie sekvencií	23
8.2.1 Základný princíp	23
8.2.2 Význam a využitie	23
8.2.3 Zložitosť problému	23
8.2.4 Skórovacia funkcia	24
8.2.5 Bežné algoritmy	24
9 Vlastná implementácia a experimenty	25
10 Bio Informatics Analysis of Nanopore Sequencing Data Using Dorado Basecaller and Clover Clustering Algorithm	26
10.1 Hľadanie DNA reťazcov	27
10.2 Vlastný algoritmus zarovnania viacerých sekvencií	28
10.2.1 Vysvetlenie Generovanie Kandidátov	30
11 Záver	31

Zoznam obrázkov

Zoznam skratiek a značiek

BPMN	Business Process Model and Notation Notácia pre modelovanie business procesov
DNA	Deoxyribonucleic Acid Deoxyribonucleic Acid - DNA je molekula nesúca genetické informácie používané v rastlinách, zvieratách a väčšine organizmov. Je tvorená dvoma reťazcami nukleotidov, ktoré tvoria dvojité špirálu.
FASTQ	Fast Quality Fast Quality - Formát súboru používaný na ukladanie sekvenčných dát spolu s kvalitatívnymi skóre pre každú bázu.
OCL	Object Constraint Language Jazyk pre špecifikáciu obmedzení, dotazov a vyhľadávacích operácií v UML
RNA	Ribonucleic Acid Ribonucleic Acid - RNA je molekula podobná DNA, ktorá hrá kľúčovú úlohu v procese prepisu a prekladu genetickej informácie. Na rozdiel od DNA je zvyčajne jednovláknová a obsahuje uracil namiesto thymínu.
SNR	Signal-to-Noise Ratio Signal-to-Noise Ratio - Poměr medzi úrovňou požadovaného signálu a úrovňou šumu, ktorý môže ovplyvniť kvalitu dát získaných z nanopórového sekvenovania.
UML	Unified Modeling Language Univerzálny jazyk pre vizuálne modelovanie systémov

1 Úvod

V tejto bakalárskej práci sa venujem problematike ukladania dát do DNA a spracovaniu sekvenačných dát získaných pomocou nanopórového sekvenovania. Práca je rozdelená do niekoľkých kapitol, ktoré postupne predstavujú motiváciu, teoretické východiská, návrh riešenia, implementáciu a vyhodnotenie výsledkov.

2 Motivácia

V dnešnej digitálnej dobe sa množstvo generovaných dát exponenciálne zvyšuje, čo vytvára potrebu efektívnych a trvalo udržateľných metód ich ukladania. Tradičné úložné médiá, ako sú pevné disky, SSD disky a magnetické pásky, majú obmedzenú životnosť a kapacitu, čo vedie k častým migráciám dát a zvýšeným nákladom na údržbu. Naopak, DNA ako médium pre ukladanie dát ponúka niekoľko významných výhod:

- **Vysoká hustota ukladania:** DNA má neuveriteľne vysokú hustotu ukladania dát, kde jeden gram DNA môže teoreticky uložiť až 215 petabajtov (215 miliónov gigabajtov) dát. To znamená, že obrovské množstvo informácií môže byť uložené v mimoriadne malom objeme.
- **Dlhodobá stabilita:** DNA je chemicky stabilná molekula, ktorá môže prežiť tisíce rokov za správnych podmienok. Na rozdiel od tradičných médií, ktoré sa môžu degradovať počas niekoľkých dekád, DNA môže uchovávať dáta po veľmi dlhú dobu bez straty integrity.
- **Energetická efektívnosť:** Ukladanie dát do DNA nevyžaduje neustálu energiu na udržiavanie dát, na rozdiel od elektronických úložísk, ktoré potrebujú napájanie na zachovanie informácií. To vedie k výrazným úsporám energie a znižuje ekologickú stopu dátových centier.
- **Ľahká replikácia a prenosnosť:** DNA môže byť ľahko kopírovaná pomocou biologických procesov, čo umožňuje jednoduché zálohovanie a prenos dát medzi rôznymi miestami bez potreby špecializovaného hardvéru.
- **Odolnosť voči technologickému zastaraniu:** Na rozdiel od tradičných úložných médií, ktoré môžu rýchlo zastarať v dôsledku technologického pokroku, DNA ako médium zostáva nezmenené a čitateľné pomocou základných biologických techník.

Napriek týmto výhodám, proces čítania DNA pomocou nanopórov prináša špecifické výzvy. Pri sekvenovaní DNA cez nanopór sa DNA molekula prechádza cez nanopór po jednotlivých nukleotidoch, pričom elektrický signál identifikuje bázy. Tento proces je však náchylný na chyby, keďže DNA sa môže pohybovať rýchlo alebo nepravidelne, čo vedie k nesprávnemu určeniu sekvencie nukleotidov. Tieto chyby v čítaní majú priamy vplyv na integritu uložených dát a vyžadujú sofistikované metódy kódovania a korekcie chýb. Avšak s pokračujúcim vývojom technológií nanopórového sekvenovania sa presnosť postupne zvyšuje, čo robí z DNA perspektívnu alternatívu k tradičným metódam ukladania dát.

Cieľom tejto práce je prispieť k zefektívneniu procesu ukladania dát do DNA vytvorením DNA kanála s lepšími vlastnosťami pre čítanie a zápis dát. Optimalizáciou týchto procesov môžeme zvýšiť rýchlosť a presnosť ukladania a načítavania informácií, čo je kľúčové pre praktické využitie DNA ako úložného média v budúcnosti.

DNA kanál predstavuje špecifický spôsob, akým sú dáta kódované a ukladané do DNA molekúl. Tento kanál zahŕňa výber vhodných sekvencií nukleotidov, ktoré minimalizujú chyby pri čítaní a zápise dát, ako aj optimalizáciu procesov syntézy a sekvenovania DNA.

3 Ciele a zadanie práce

3.1 Uloha

Cieľom tejto úlohy je simulovať chyby, ktoré vznikajú pri čítaní DNA pomocou nanopórového sekvenovania. Nanopórové sekvenovanie je inovatívna technológia, ktorá umožňuje rýchle a efektívne čítanie genetického materiálu. Úlohou je vytvoriť generátor, ktorý na základe pravdepodobnosti chyby náhodne pridáva chyby do reálneho DNA reťazca. Tento generátor by mal byť schopný simulovať rôzne typy chýb, ako sú záměny báz, vloženia alebo vynechania báz, ktoré sa môžu vyskytnúť počas procesu sekvenovania.

Táto simulácia bude slúžiť na testovanie a vyhodnocovanie algoritmov pre spracovanie sekvenačných dát, ktoré musia byť robustné voči týmto chybám. Cieľom je zlepšiť presnosť a spoľahlivosť analýzy genetických informácií získaných pomocou nanopórového sekvenovania.

4 Návrh riešenia

Navrhnutie riešenia úlohy simulácie chýb pri čítaní DNA pomocou nanopórového sekvenovania zahŕňa niekoľko kľúčových krokov. Cieľom je vytvoriť systém, ktorý dokáže generovať realistické chyby v DNA sekvenciách na základe pravdepodobností chýb pozorovaných v skutočných nanopórových dátach.

Aby sme mohli dosiahnuť tento cieľ, najprv je potrebné získať reálne DNA sekvencie a ich zodpovedajúce výstupy z nanopórového sekvenovania. Tieto dáta budú slúžiť ako základ pre analýzu a modelovanie chýb. Pre každý reálny DNA reťazec je potrebné získať dostatočné množstvo výstupných sekvencií, ktoré boli generované počas sekvenovania. Čím väčšie množstvo výstupov máme pre jeden vstupný reťazec, tým lepšie môžeme pochopiť variabilitu a pravdepodobnosti chýb, ktoré sa vyskytujú počas procesu sekvenovania.

Problém je že nevieme Ake je realne dna. Riesenie tohto problému spočíva v použití techník zhľukovania (clustering) na identifikáciu skupín výstupných sekvencií, ktoré pravdepodobne pochádzajú z rovnakého pôvodného DNA reťazca. Týmto spôsobom môžeme vytvoriť konsenzuálny reťazec pre každý zhľuk, ktorý bude slúžiť ako náš "reálny" vstupný reťazec. Čím väčší zhľuk najdeme, tým väčšia šanca že konsenzus bude reprezentovať realný vstup a tým lepšie dáta pre našu analýzu generované dna. Týmto spôsobom získame nielen reálny reťazec, ale aj informácie o tom, akými chybami sa tento reťazec líšil od jednotlivých výstupov. Pre každú bázu v reálnom reťazci tak môžeme vytvoriť mapu, ktorá ukazuje, na aký reťazec bola táto báza prečítaná v rôznych výstupoch.

Táto mapa nám umožní analyzovať pravdepodobnosti rôznych typov chýb (napríklad zámenky, vloženia, vynechania) pre každú bázu v reálnom reťazci. Na základe týchto informácií môžeme vytvoriť model, ktorý bude schopný simulovať tieto chyby pri generovaní nových DNA sekvencií.

5 Technologické pozadie

Táto časť predstavuje základné technológie a algoritmy použité v práci.

6 Nanopore

Nanopore sekvenovanie je technológia používaná na sekvenovanie DNA a RNA molekúl [1]. Táto metóda umožňuje čítanie genetického materiálu tým, že molekuly prechádzajú cez nanometrové póry (nanopóry), čo vedie k zmene elektrického prúdu, ktorý je následne analyzovaný na určenie sekvencie nukleotidov [1]. Je to revolučná technológia v oblasti genomiky, ktorá umožňuje rýchle a presné sekvenovanie s minimálnymi nákladmi a zariadeniami prenosných veľkostí [1]. Aplikácie nanopórového sekvenovania zahŕňajú diagnostiku chorôb, výskum genetických porúch a monitorovanie environmentálnych vzoriek [1].

Nanopórové sekvenovanie je obzvlášť užitočné pre jeho schopnosť čítať dlhé sekvencie DNA, čo zjednodušuje zostavovanie genómov a identifikáciu štruktúrnych variácií [1, 2]. Funguje na princípe detekcie zmien v elektrickom prúde, keď molekula prechádza cez nanopór, čo umožňuje priame čítanie sekvencií bez potreby amplifikácie alebo značenia [1]. DNA alebo RNA molekuly sú vedené cez nanopór pomocou elektrického poľa, pričom každá báza spôsobuje charakteristickú zmenu prúdu, ktorá je zaznamenaná a analyzovaná softvérom na určenie sekvencie [1].

6.1 Prekladanie DNA/Mra do signálu

Prekladanie DNA alebo RNA sekvencií do elektrického signálu v nanopórovom sekvenovaní [1] zahŕňa niekoľko kľúčových krokov:

- **Príprava vzorky:** DNA alebo RNA molekuly sú pripravené na sekvenovanie, často zahŕňajúce fragmentáciu a pridanie adaptérnych sekvencií.
- **Vedenie cez nanopór:** Molekuly sú vedené cez nanopór pomocou elektrického poľa, ktoré spôsobuje ich pohyb [1].
- **Detekcia prúdu:** Keď molekula prechádza cez nanopór, každá báza spôsobuje charakteristickú zmenu v elektrickom prúde, ktorý je zaznamenaný ako časová séria dát [1].
- **Analýza signálu:** Zaznamenaný elektrický signál je analyzovaný pomocou algoritmov na identifikáciu sekvencie nukleotidov na základe zmien prúdu [1].
- **Preklad do sekvencie:** Softvér prekladá analyzovaný signál späť do sekvencie DNA alebo RNA, čo umožňuje výskumníkom získať genetické informácie z pôvodnej molekuly [1].

Výstupom z procesu nanopórového sekvenovania je sekvencia nukleotidov (A, T, C, G pre DNA alebo A, U, C, G pre RNA) reprezentujúca genetickú informáciu pôvodnej molekuly [1]. Tento výstup je často vo forme textového súboru (napríklad FASTQ formát), ktorý obsahuje sekvencie spolu s kvalitatívnymi skóre pre každú bázu [1]. Vzhľadom na

technické obmedzenia a variabilitu v procese sekvenovania je bežné, že jednotlivé DNA alebo RNA retiazce sú prečítané niekoľkokrát (tzv. "coverage" alebo "depth of coverage") [1]. Toto opakované čítanie zvyšuje spoľahlivosť a presnosť výslednej sekvencie, pretože umožňuje korekciu chýb a identifikáciu variácií v genetickom materiáli [1, 2]. No napriek tomu, že sa retiazce čítajú viackrát, stále môže dôjsť k nepresnostiam v sekvencii kvôli šumu v signáli [1].

Retiazce DNA alebo RNA môžu byť čítané rôznou rýchlosťou počas nanopórového sekvenovania, čo môže ovplyvniť kvalitu a presnosť zaznamenaného signálu [1]. Rýchlosť prechodu molekuly cez nanopór je ovplyvnená viacerými faktormi, vrátane veľkosti molekuly, jej konformácie, interakcií s nanopórom a podmienok prostredia (napríklad teplota a iónová sila) [1].

Keďže DNA a RNA molekuly sú veľmi malé, signál zaznamenaný počas nanopórového sekvenovania odráža interakcie jednotlivých nukleotidov (báz) s nanopórom [1]. Každá báza má jedinečný tvar a elektrické vlastnosti, ktoré ovplyvňujú spôsob, akým mení elektrický prúd pri prechode cez nanopór [1]. Preto je možné získať signál pre každú jednotlivú bázu v molekule, čo umožňuje presné čítanie sekvencie [1].

7 Dorado Basecaller

Dorado je pokročilý basecaller vyvinutý spoločnosťou Oxford Nanopore Technologies (ONT) na prekladanie surového elektrického signálu získaného z nanopórového sekvenovania na sekvenciu nukleotidov (A, T, C, G pre DNA alebo A, U, C, G pre RNA). Je navrhnutý tak, aby poskytoval vysokú presnosť a rýchlosť pri spracovaní sekvenačných dát, čo je kľúčové pre rôzne aplikácie v oblasti genomiky a bioinformatiky.

7.1 Názov podkapitoly

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Integer eu lacus leo. Nulla egestas purus non dignissim tincidunt.

8 Metódy spracovania sekvencií

8.1 Cluster clover

Klastrovací algoritmus je metóda, ktorá rozdeľuje množinu dát do skupín (klastrov) tak, aby dáta v rámci jednej skupiny boli si navzájom podobné a dáta z rôznych skupín boli odlišné [3]. Tieto algoritmy sa často používajú v bioinformatike na analýzu sekvencií DNA alebo iných biologických dát.

Clover algoritmus je efektívny klastrovač navrhnutý špeciálne pre DNA sekvencie v oblasti DNA-based data storage. Využíva stromovú štruktúru na rýchle a presné zoskupovanie sekvencií podľa ich podobnosti, čím zvyšuje efektivitu a škálovateľnosť procesu [3]. Clover umožňuje efektívne spracovanie veľkých množín sekvencií a je vhodný pre moderné aplikácie v oblasti ukladania dát do DNA.

8.2 Viacnásobné zarovnanie sekvencií

Viacnásobné zarovnanie sekvencií (Multiple Sequence Alignment, MSA) je proces usporiadania troch alebo viacerých biologických sekvencií (DNA, RNA alebo proteínov) tak, aby boli identifikované podobné regióny medzi nimi. Tieto podobnosti môžu odhaliť štrukturálne, funkčné alebo evolučné vzťahy medzi sekvenciami.

8.2.1 Základný princíp

Pri viacnásobnom zarovnaní sekvencií hľadáme také usporiadanie, ktoré maximalizuje podobnosť medzi všetkými sekvenciami súčasne. Do sekvencií sú vkladane medzery (gap characters, značené pomlčkou '-'), aby sa zodpovedajúce pozície dostali do rovnakých stĺpcov.

subsubsection Príklad zarovnania

Majme tri jednoduché sekvencie:

- Sekvencia 1: ACGT
- Sekvencia 2: AGT
- Sekvencia 3: ACCT

Ich zarovnanie môže vyzerať nasledovne:

Seq1: A C G T
Seq2: A - G T
Seq3: A C C T

8.2.2 Význam a využitie

Viacnásobné zarovnanie má niekoľko dôležitých aplikácií:

- **Fylogenéza** – konštrukcia evolučných stromov
- **Identifikácia konzervovaných motívov** – nálezenie funkčne dôležitých oblastí
- **Predikcia štruktúry** – odvodenie sekundárnej a terciárnej štruktúry proteínov
- **Homológia** – určenie príbuznosti medzi sekvenciami

8.2.3 Zložitosť problému

Viacnásobné zarovnanie je výpočtovo náročný problém. Presné riešenie pomocou dynamickeho programovania má časovú zložitosť $O(L^n)$, kde L je dĺžka sekvencií a n je ich počet. Preto sa v praxi používajú heuristické algoritmy.

8.2.4 Skórovacia funkcia

Kvalita zarovnania sa hodnotí pomocou skórovacej funkcie, ktorá typicky obsahuje:

- **Match score** – bodovanie zhody medzi znakmi
- **Mismatch penalty** – penalizácia za nezhodu
- **Gap penalty** – penalizácia za medzery (môže byť lineárna alebo afinná)

8.2.5 Bežné algoritmy

Medzi najpoužívanejšie algoritmy pre MSA patria:

- **ClustalW/ClustalOmega** – progresívne zarovnanie pomocou sprievodného stromu
- **MUSCLE** – rýchly progresívny algoritmus s iteratívnym spresňovaním
- **T-Coffee** – kombinuje párové zarovnania do finálneho MSA
- **MAFFT** – využíva FFT pre rýchle nájdenie homológnych oblastí

9 Vlastná implementácia a experimenty

V tejto kapitole popisujem konkrétne kroky, ktoré som vykonal počas riešenia práce, vrátane spracovania dát, aplikácie algoritmov a vyhodnotenia výsledkov.

10 Bio Informatics Analysis of Nanopore Sequencing Data Using Dorado Basecaller and Clover Clustering Algorithm

Najprv som stiahol potrebný dataset z verejného repozitára Potom som nan zavolať Dorado basecaller, ktorý som použil na prekladanie surových pod5 súborov do formátu BAM. To som spravil pomocou nasledujúceho príkazu v termináli:

```
dorado basecaller --input-format pod5 --output-format bam --input /cesta/k/data
```

tam som si musel stiahnuť a nainštalovať Dorado, potom na základe pod5 datasetu som stiahol dorado triedu, ktorá je určená na spracovanie daného datasetu. Na základe toho cez aký Nanopore bol dataset získaný. po spracovaní Dorado basecallera som získal BAM súbor, ktorý obsahoval preložené sekvencie po 1000000 sekvencií dĺžky 1000000 To trvalo približne X hodín, v závislosti od veľkosti datasetu a výpočtovej kapacity použitého hardvéru. Následne som použil algoritmus Clover, ktorý zoskupil sekvencie do jednotlivých klastrov na základe ich podobnosti. Problem je že Clover neberie ako vstup BAM súbory, ale potrebuje textový formát FASTA alebo FASTQ, takže som musel najprv previesť BAM súbory do text formátu pomocou nástroja samtools. Po prevedení som spustil Clover, ktorý zoskupil sekvencie do jednotlivých klastrov na základe ich podobnosti. Nástroj Clover my vrátil subor ktorý mal štruktúru polia ktorý obsahoval dvojice celých čísel, kde prvé číslo reprezentovalo ID sekvencie a druhé číslo reprezentovalo ID Sekvencie Prvej Sekvencie, do ktorého bola sekvencia zaradená. Zo všetkých vytvorených klastrov som vybral tie, ktoré boli dostatočne veľké na ďalšiu analýzu. Ale Ukazalo sa že dna v klastroch neboli zhodne ďalej ako pár nukleotidov, čo znamenalo že som mal dna vôbec neboli klastrované správne. Neskôr som zistil že clover zaraďuje iba podľa začiatku retazca a neberie do úvahy zhodu ďalej v retazci, čo znamenalo že som mal v jednom klustri sekvencie ktoré mali zhodu iba na začiatku a ďalej sa rozchádzali. Jedným klaster obsahoval viac ako 37000 sekvencií, čo bolo neobvykle veľké množstvo sekvencií v jednom klustri ktoré mali cez dĺžku ako 43 nukleotidov zhodne, čo bolo nepravdepodobné, že by sa stalo náhodou. Vznikla teória že som narazil na dna Primer Potom čo som vytvoril konzesus prvých 43 nukleotidov. Na základe tejto informácie som naprogramoval vlastný skript v jazyku Python, ktorý používal knižnicu Biopython, A rozbehol som ho na všetky vetvy a použil som ho na oddelenie dna primerov od zvyšku sekvencií. Potom som dane sekvencie znovu zoskupil pomocou Clover, ale tentokrát som použil iba zvyšné časti sekvencií bez dna primerov. Data odcistené od dna primerov sa znovu zoskupili do klastrov, ktoré teraz obsahovali sekvencie, ktoré mali zhodu nielen na začiatku, ale aj ďalej v retazci.

10.1 Hľadanie DNA reťazcov

Hľadanie DNA reťazcov v nanopórových dátach je komplexný proces, ktorý zahŕňa niekoľko krokov. Najprv sa surové dáta získané z nanopórového sekvenovania prekladajú pomocou basecallera Dorado do formátu BAM, ktorý umožňuje ďalšie spracovanie. Následne sa použije klastrovací algoritmus Clover na zoskupenie sekvencií do klastrov na základe ich podobnosti na začiatku reťazca. Zo všetkých vytvorených klastrov sa vyberieme ten najväčší, na ňom zavoláme moj naivny multialignment algoritmus, ktorý vytvorí konsenzuálnu sekvenciu pre tento cluster. Tento konsenzus slúži ako náš "primer", ktorý sa bude používať na vyhľadávanie v jednotlivých readoch. Pre každý read sa potom vyhľadá lokálne zarovnanie s primerom a vyberie sa sekvencia, ktorá nasleduje za primerom. Tieto sekvencie sa následne zoskupia pomocou Cloveru, čím vzniknú nové klastre. Na každý z týchto klastrov sa opäť aplikuje multialignment, a zarovnané sekvencie sa použijú na vytvorenie konsenzuálnej sekvencie pre každý cluster. tak získame dlhé reťazce a z nich môžeme filtrovať tie ktoré sú dostatočne dlhé a dostatočne zoskupené.

10.2 Vlastný algoritmus zarovnania viacerých sekvencií

Multiple sequence alignment (MSA) je problém zarovnania viacerých sekvencií, ktorý sa často vyskytuje v bioinformatike. Cieľom MSA je nájsť optimálne zarovnanie medzi viacerými sekvenciami, ktoré minimalizuje počet nesúladov a medzier. V tejto časti popisujem vlastný algoritmus na zarovnanie viacerých sekvencií, ktorý som implementoval v Pythone.

Pre tento Algoritmus predpokladám, že máme k dispozícii sekvencie DNA z zhľukovania od algoritmu clover, ktorý zhľukuje sekvencie, podľa toho, ako začínajú. Takže môžeme predpokladať, že začiatok sekvencií v jednom zhľuku je rovnaký a zarovnanie začína od začiatku a ďalej sa rozvetvuje kvôli chybám, ktoré sa vyskytujú pri citaní dna. Algoritmus využíva prístup podobný beam search, kde pre každú sekvenciu udržiavame množinu možných zarovnaní (vetiev) a iteratívne ich rozširujeme o ďalší znak z konsenzuálnej sekvencie. Pri každom kroku vyberáme najčastejší znak (konsenzus) a generujeme nové vetvy pre každý možný typ chyby (zhoda, zámienka, vloženie, vynechanie). Vetvy sú následne filtrované na základe skóre, aby sme udržali len tie najpravdepodobnejšie zarovnania. Tento proces pokračuje, kým nedosiahneme koniec všetkých sekvencií alebo kým sa sekvencie nezacnú výrazne odlišovať od seba, čo indikuje, že neexistuje jasný konsenzus.

Algorithm 1 Stav jednej vetvy zarovnania

```
record AlignmentState
  score : aktuálne skóre vetvy
  dna : spracovávaná DNA sekvencia
  position : aktuálna pozícia v sekvencii
  backtrack : postupnosť symbolov {=, I, D, M}
function NEXTBASE(state)
  if state.position < |state.dna| then
    return state.dna[state.position]
  end if
  return None
end function
function UPDATESTATE(state,  $\Delta$ score, advance, symbol)
  state.score  $\leftarrow$  state.score +  $\Delta$ score
  if advance then
    state.position  $\leftarrow$  state.position + 1
  end if
  append symbol to state.backtrack
end function
```

Algorithm 2 Generovanie kandidátov pre jednu vetvu

```
function GENERATECANDIDATES(consensus, state)  
  if NEXTBASE(state) = consensus then  
    UPDATESTATE(state, MatchReward, true, =)  
    return [state]  
  end if  
  mismatch  $\leftarrow$  kópia state  
  UPDATESTATE(mismatch,  $-MismatchPenalty$ , true, M)  
  deletion  $\leftarrow$  kópia state  
  UPDATESTATE(deletion,  $-DeletionGapPenalty$ , false, D)  
  insertion  $\leftarrow$  kópia state  
  while NEXTBASE(insertion)  $\neq$  consensus do  
    UPDATESTATE(insertion,  $-InsertionGapPenalty$ , true, I)  
  end while  
  UPDATESTATE(insertion, MatchReward, true, =)  
  return [mismatch, insertion, deletion]  
end function
```

Algorithm 3 Multi-Alignment

Require: zoznam stavov *lines*

```
while true do  
  bestCandidates  $\leftarrow$  najlepšia vetva pre každú vstupnú sekvenciu v lines  
  consensus  $\leftarrow$  najčastejšia hodnota NEXTBASE(candidate) pre candidate  $\in$   
  bestCandidates  
  newLines  $\leftarrow$  []  
  for all line  $\in$  lines do  
    pridaj všetky prvky z GENERATECANDIDATES(consensus, line) do newLines  
  end for  
  lines  $\leftarrow$  newLines  
  odstráň vetvy, ktoré pre rovnakú sekvenciu a rovnakú pozíciu majú horšie skóre než  
  iná vetva  
  odstráň vetvy so skóre nižším než threshold_score  
  if menej než threshold_ratio z bestCandidates podporuje consensus then  
    return bestCandidates  
  end if  
end while
```

10.2.1 Vysvetlenie Generovanie Kandidátov

Príklad zarovnania DNA sekvencií s konzenzom

Konsenzus: TGAC----TGAC
Sekvencia₁ : TGACgagcTGAC
 ----A-----

Konsenzus: TGACGAGCTGAC
Sekvencia₁ : TGAC----TGAC
 ----A-----

Konsenzus: TGACGAGCTGAC
Sekvencia₁ : TGACtAGCTGAC
 ----A-----

11 Záver

V práci som predstavil možnosti a výzvy spojené s ukladaním dát do DNA a spracovaním sekvenáčnych dát z nanopórového sekvenovania. Navrhnuté a implementované metódy prispievajú k efektívnejšiemu spracovaniu a analýze týchto dát. Cieľ bakalárskej práce bol splnený.

Použitá literatura

1. ZHENG, Peijie; ZHOU, Chuntao; DING, Yuemin; LIU, Bin. Nanopore sequencing technology and its applications. *MedComm*. 2023, roč. 4, č. 4. Dostupné z doi: 10.1002/mco2.316. Published July 2023.
2. LOPEZ, Randolph; CHEN, Yuan-Jyue; ANG, Siena Dumas; YEKHANIN, Sergey; MAKARYCHEV, Konstantin; RACZ, Miklos Z; SEELIG, Georg; STRAUSS, Karin; CEZE, Luis. DNA assembly for nanopore data storage readout. *Nature Communications*. 2019, roč. 10, č. 1, s. 1–9. Dostupné z doi: 10.1038/s41467-019-10978-4.
3. QU, Guanjin; YAN, Zihui; WU, Huaming. Clover: tree structure-based efficient DNA clustering for DNA-based data storage. *Briefings in Bioinformatics*. 2022, roč. 23, č. 5, s. 1–16. Dostupné z doi: 10.1093/bib/bbac336. Corresponding author: Huaming Wu, Center for Applied Mathematics, Tianjin University, Tianjin, 300072, China. E-mail: whming@tju.edu.cn.